Apprentissage supervisé

Benoit Gaudou
Moncef Garouani

Source = Sylvain Cussat-Blanc, Benoit Gaudou

监督学习

贝努瓦·高杜
蒙塞夫·加鲁阿尼

来源 = Sylvain Cussat-Blanc，Benoit Gaudou

Apprentissage supervisé

- **Classification**
  - L'espace à prédire $\mathcal{Y}$ est un ensemble **discret non-ordonné**
  - Classification binaire : $card(\mathcal{Y}) = 2$
  - Classification multiclasse : $card(\mathcal{Y}) > 2$
  - Souvent, on évalue le modèle en calculant l'accuracy

- **Régression**
  - On parle de régression quand $\mathcal{Y}$ est un sous-ensemble de $\mathbb{R}^d$
  - Souvent, on évalue le modèle en calculant l'erreur quadratique: $(y - f(x))^2$

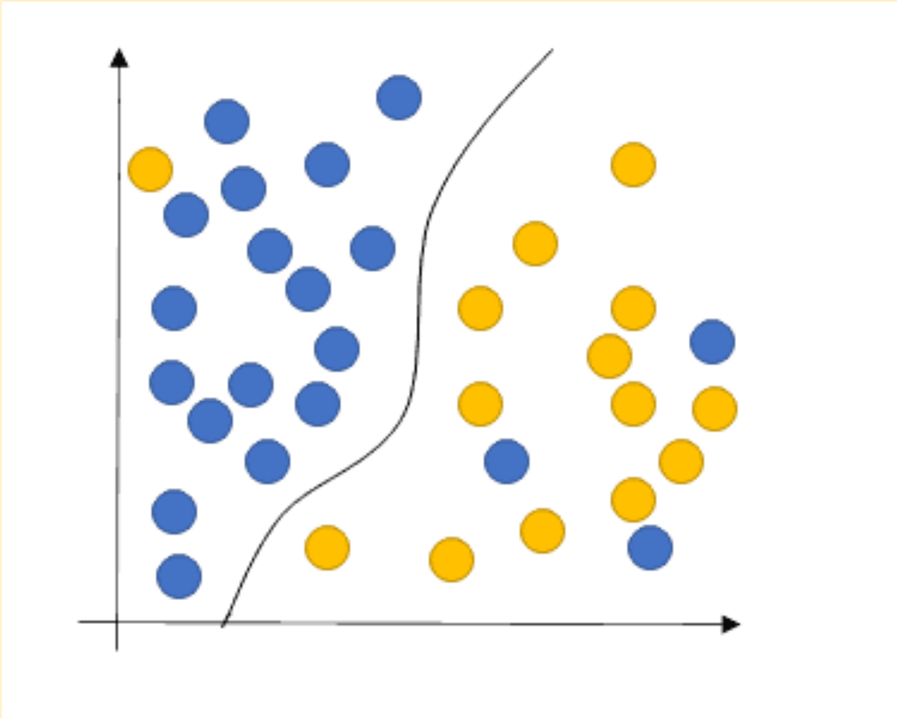

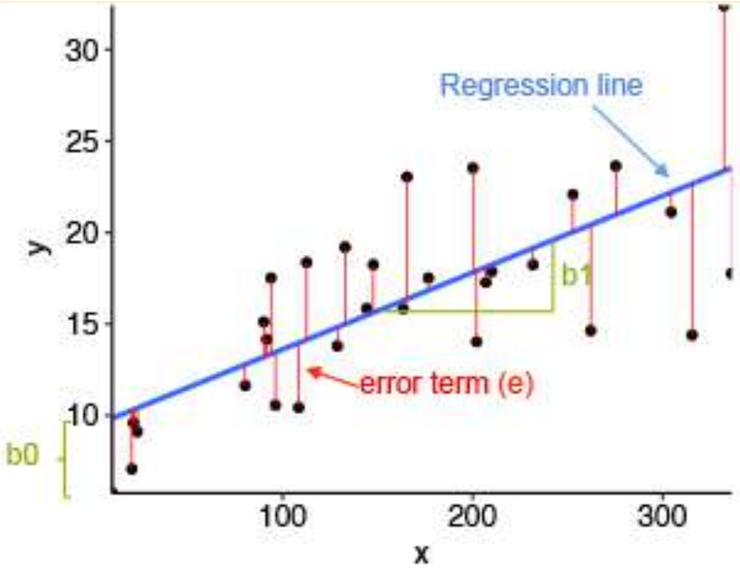

监督学习

- **分类**
  - 可预测空间□□是一个集合
    离散无序的
  - 分类二元：卡片(□□)=2
  - 分类多类：卡片(□□)>2
  - 通常，模型评估是通过计算准确率来进行的。
- **回归分析**
  - 当□□是ï ^{d}的一个子集时，我们称之为回归。
  - 通常，我们通过计算平方误差来评估模型：$(y - f(x))^2$

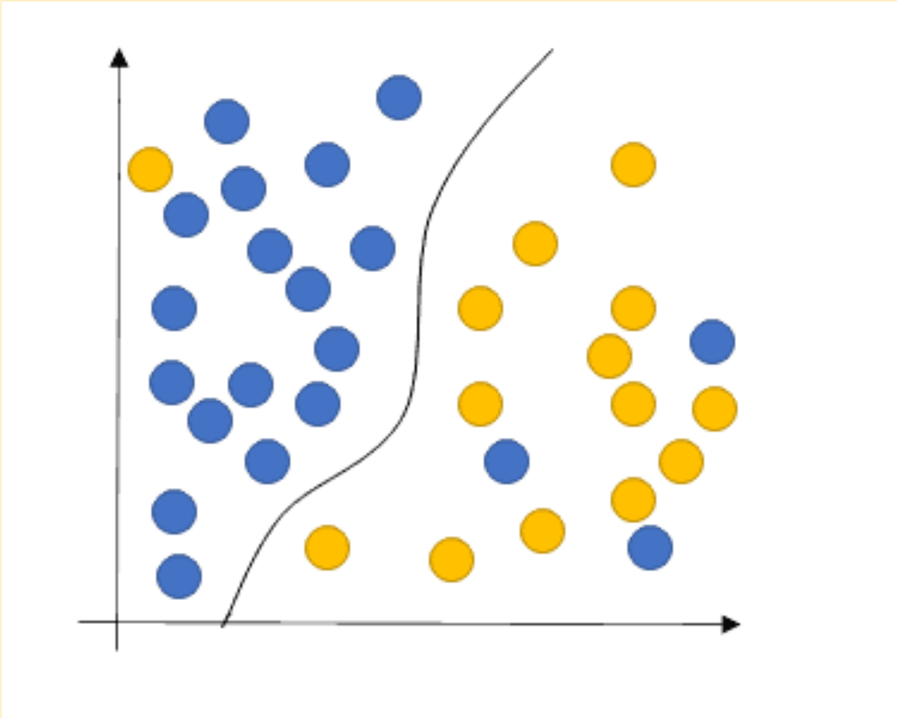

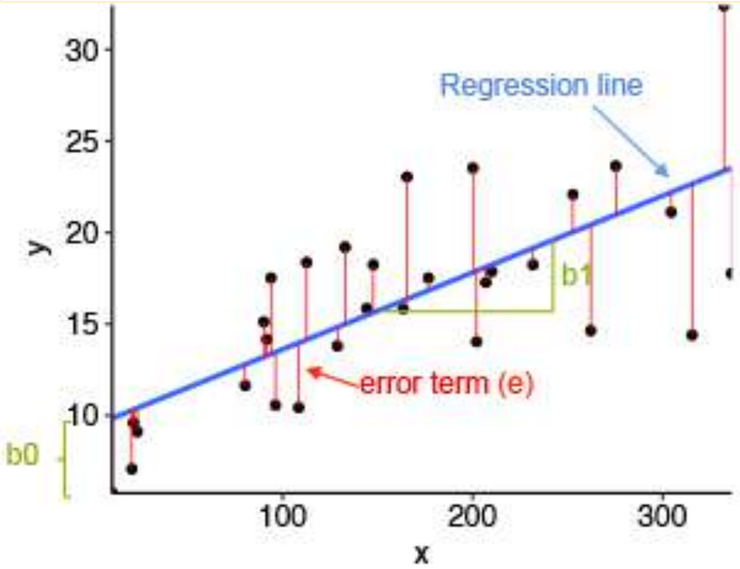

Principe

Fonction de perte (loss)

- Estime l'erreur de la prédiction $f(x)$ par rapport à la réalité terrain y

  Par convention $L(y, f(x)) = \begin{cases} 0 & \text{if } y = f(x) \\ > 0 & \text{if } y \neq f(x) \end{cases}$

- Risque réel : erreur de prédiction attendue

$$R_{true}(f) = \int_{\mathcal{X} \times \mathcal{Y}} L(y, f(x)) p(x, y) \mathrm{d}x \mathrm{d}y$$

- Objectif : Trouver la fonction qui minimise le risque réel

$$f^* = \arg\min_{f \in \mathcal{H}} R_{true}(f)$$

王子

损失函数

- 估计预测值 f(*x*) 与实际地面值*y*之间的预测误差

  按惯例 L(y，f (x)) = $\begin{cases} 0 & = f(x) \\ > 0 & \text{如果y if y} \neq f(x) \end{cases}$

- 实际风险：预期预测误差

$$T_{真值}(f) = \int_{\mathcal{X} \times \mathcal{Y}} L(y, f(x)) p(x, y) \square\square x \square\square y$$

- 目标：找出能够最小化实际风险的函数

$$f^* = \arg\min_{f \in \mathcal{H}} R_{true}(f)$$

Risque empirique

- Le risque réel est impossible à calculer car on ne connait pas la distribution réelle des données

- Utilisation du risque empirique qui estime la loss sur un dataset d'entrainement

$$R_{emp} = \frac{1}{n} \sum_{i=1}^{n} L(y_i, f(x_i))$$

经验风险

- 实际风险无法计算，因为无法获知数据的真实分布情况。
- 使用经验风险来估计训练数据集上的损失

$$Remp=\frac{1}{n}\sum_{i=1}^{个} L(yi，f(xi))$$

Quelques fonctions de perte

- Erreur 0-1 (plutôt pour classification)

$$L(Y, f(X)) = \begin{cases} 0 & \text{if } y = f(x) \\ 1 & \text{otherwise} \end{cases}$$

- Erreur quadratique (plutôt pour régression)

$$L(Y, f(X) = (Y - f(X))^2$$

- Erreur l1 (erreur absolue - régression)

$$L(Y, f(X)) = |Y - f(X)|$$

- Erreur de Hinge (plutôt pour classification)

$$L(Y, f(X)) = \max(0, 1 - yf(x))$$

几种损失函数

- 错误　0-1（更适用于分类）

  $L(Y, f(X)) = \begin{cases} 0 & \text{如果} y \text{oth} = f(x) \\ 1 & \text{erwise} \end{cases}$

- 错误　二次方（更适用于回归分析）$L(Y, f(X)) = (Y - f(X))^2$

- 错误　L1（绝对误差 - 回归）$L(Y, f(X)) = | Y - f(X) |$

- 错误　铰链（更适用于分类）$L(Y, f(X)) = \max(0, 1 - yf(x))$

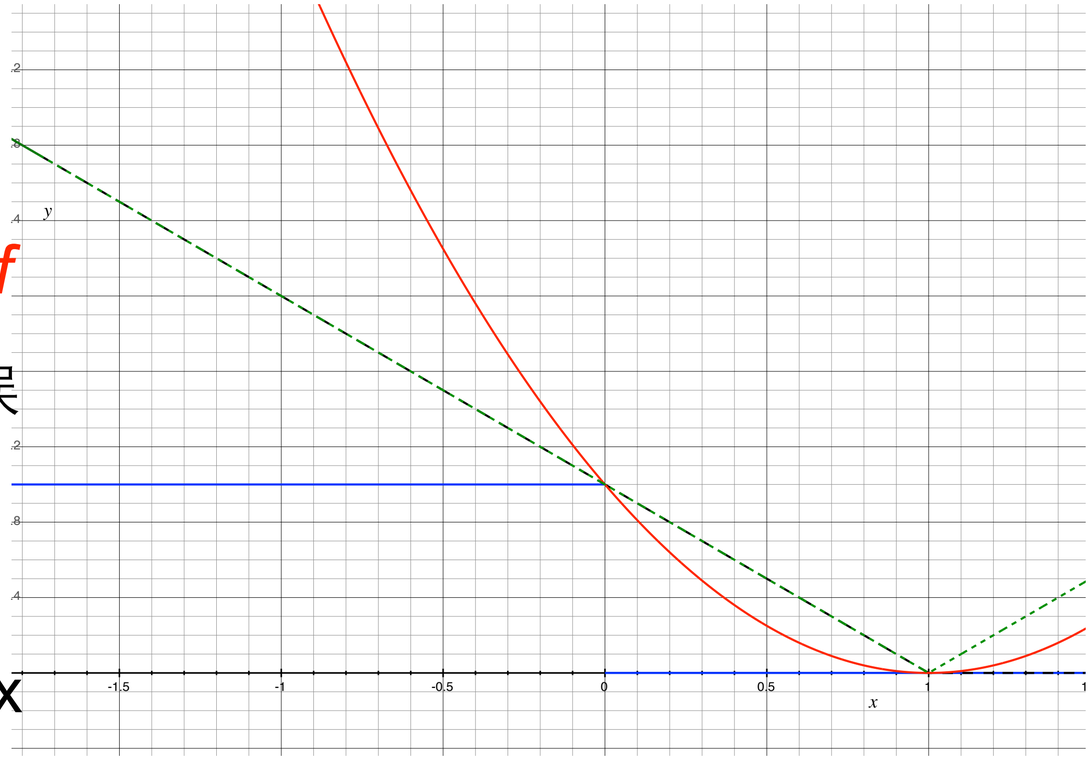

K Plus Proches Voisins

K Plus 邻近邻居

Principe

Classification

- Calculer les distances d'un point à classifier avec les points du dataset d'entrainement
- Sélectionner les k plus proches
- Compter le nombre de points dans chacune des classes
- Choisir la classe ayant le **plus grand nombre de votes**
- Classifier le point dans cette classe

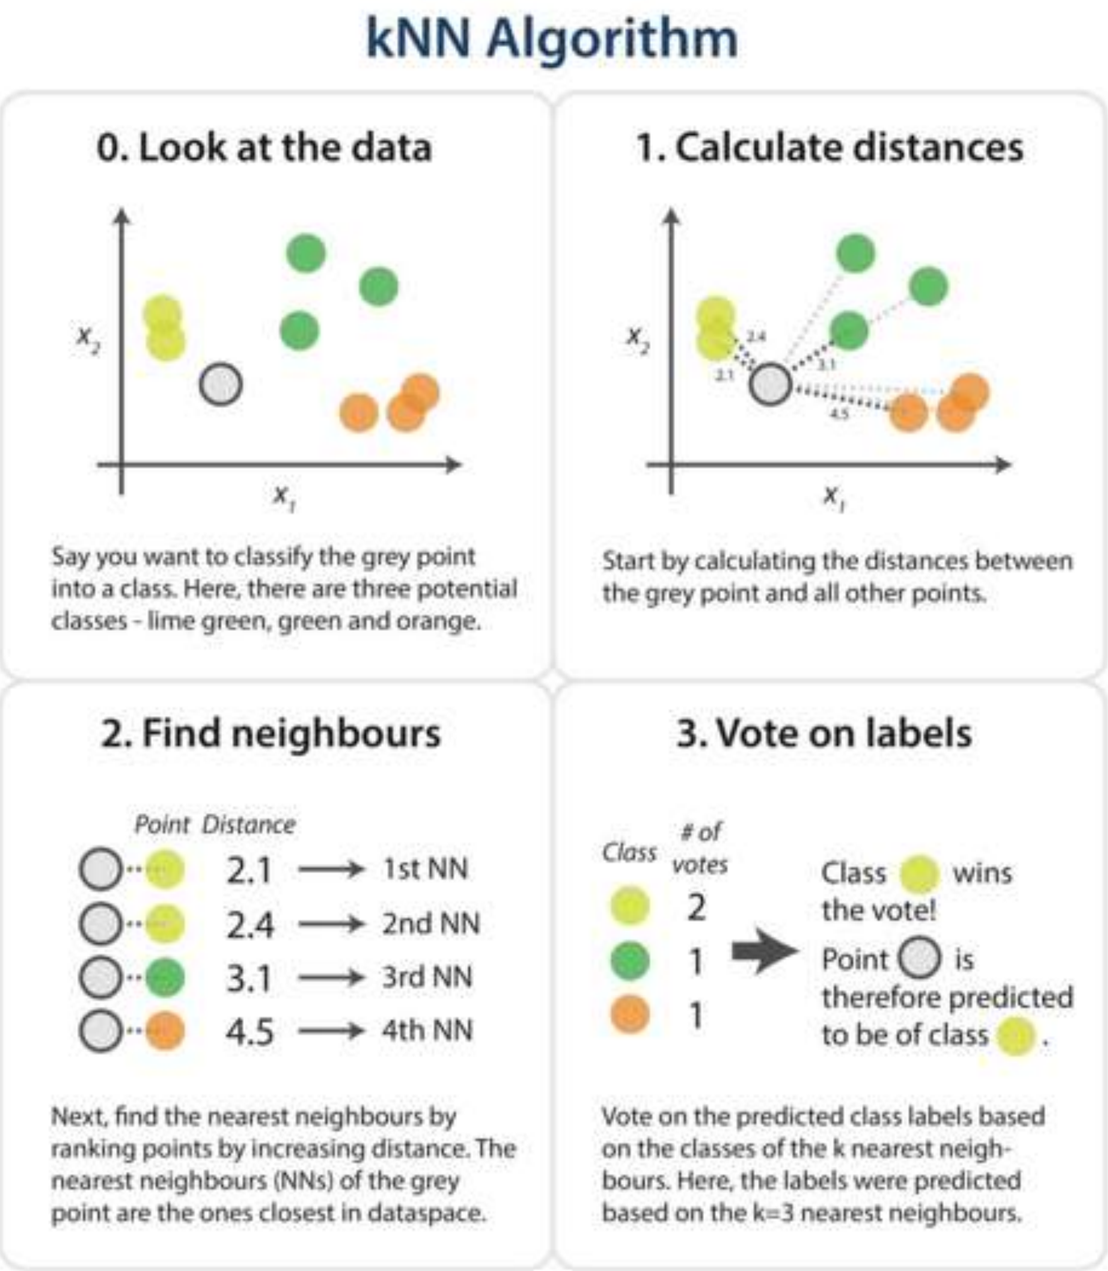

王子

分类

- 计算待分类点与训练数据集各点之间的距离
- 选择最近的k个
- 统计各类别中的点数
- 选择**得票数最多的班级**
- 将该点归类到该类别中

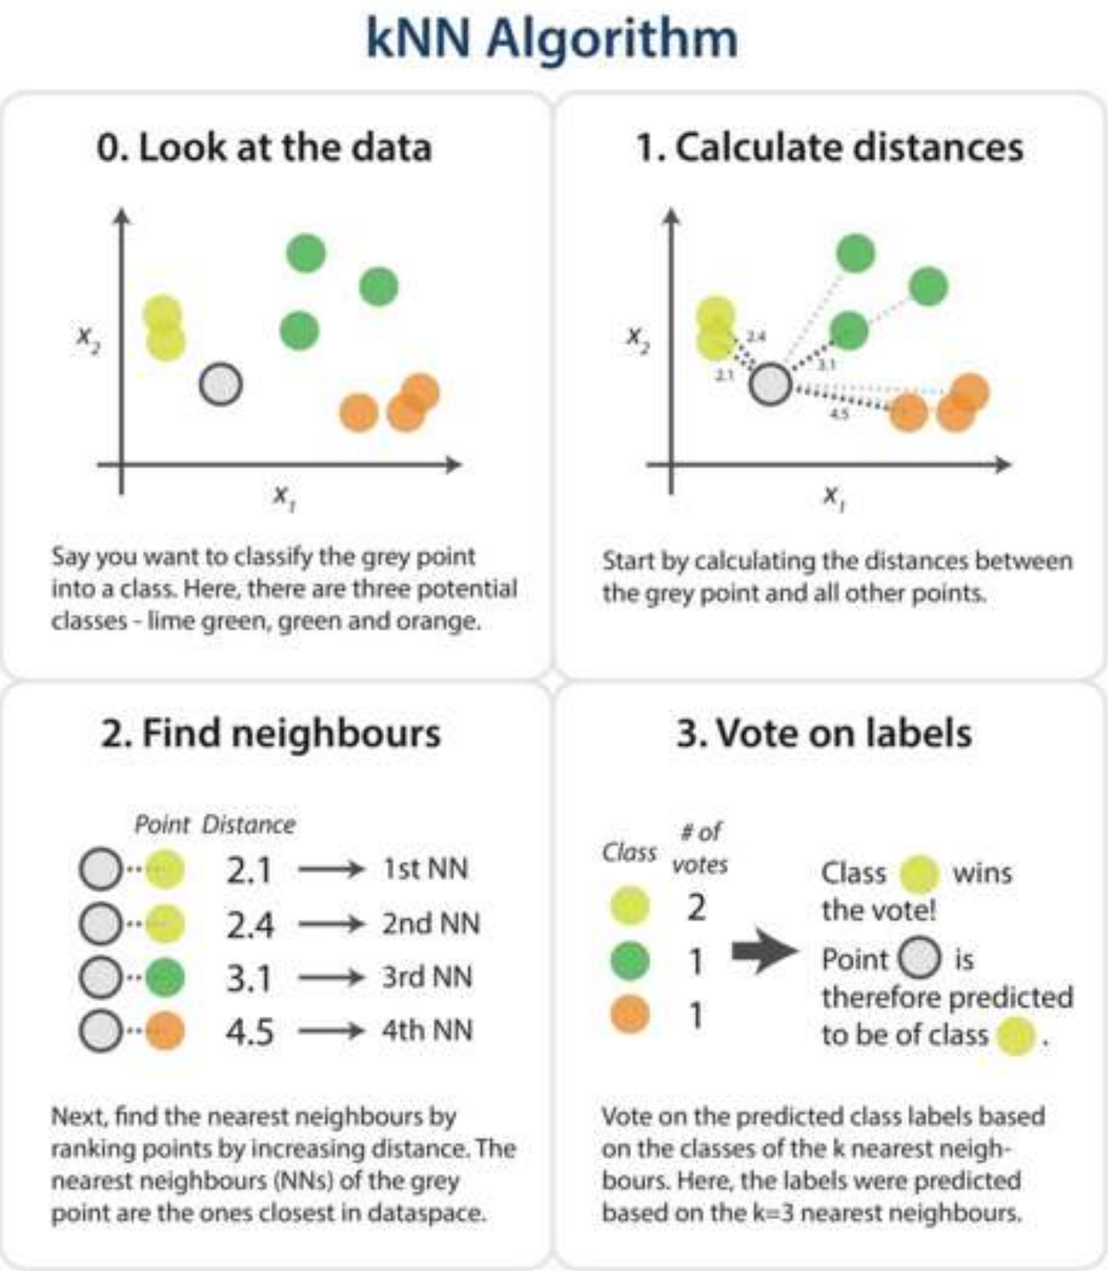

Principe

Régression

- Calculer les distances d'un point à classifier avec les points du dataset d'entrainement
- Sélectionner les k plus proches
- Prédiction = **Moyenne des valeurs de ces k points**

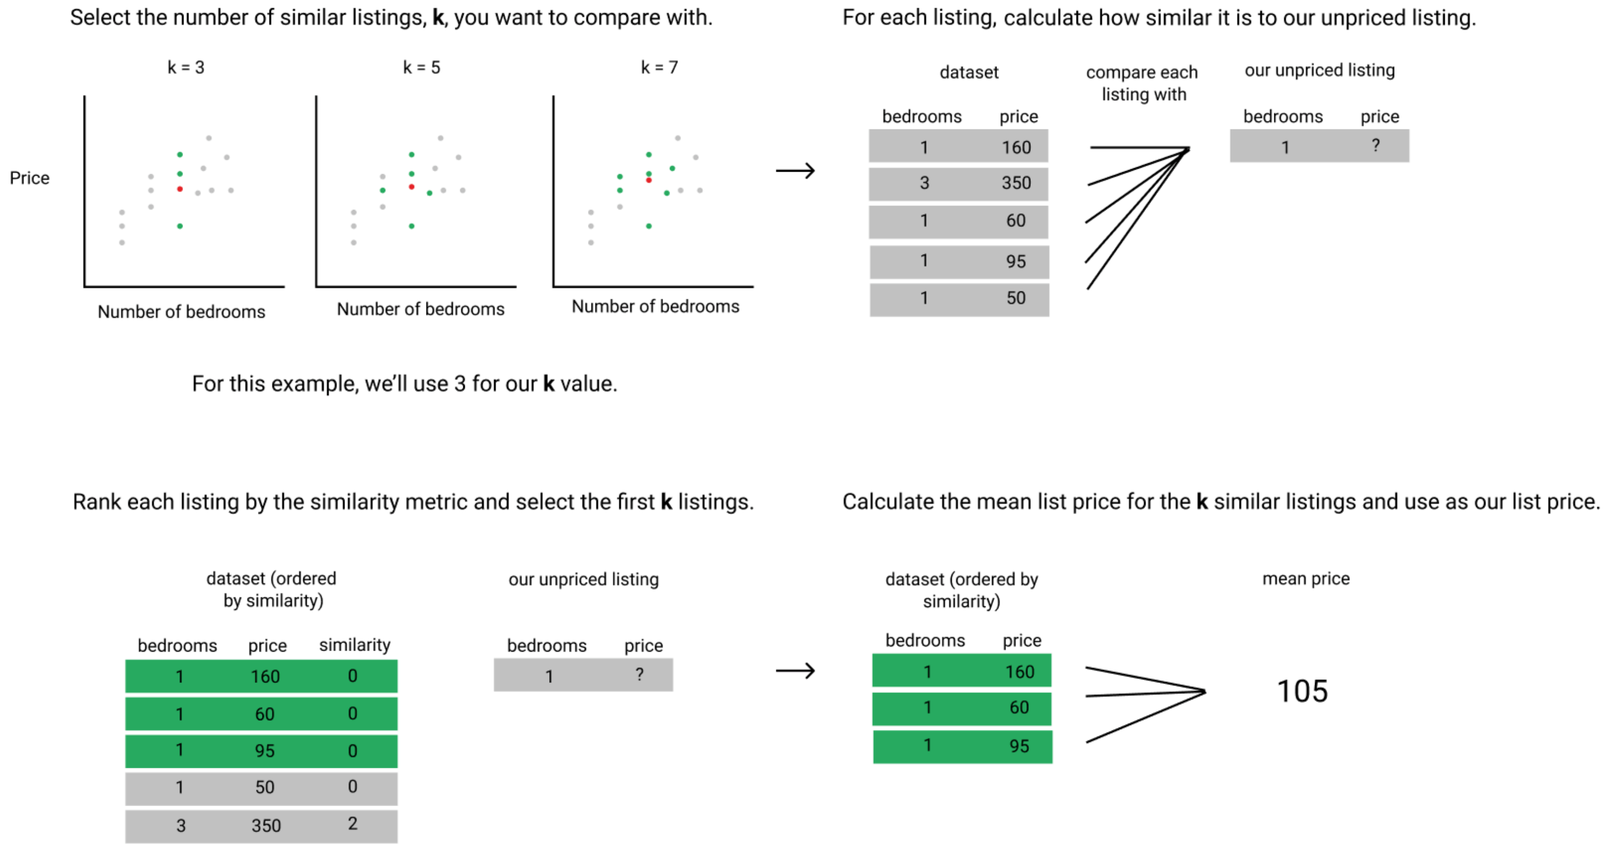

王子
回归分析

- 计算待分类点与训练数据集各点之间的距离
- 选择最近的k个
- 预测值 =**这k个点的数值平均值**

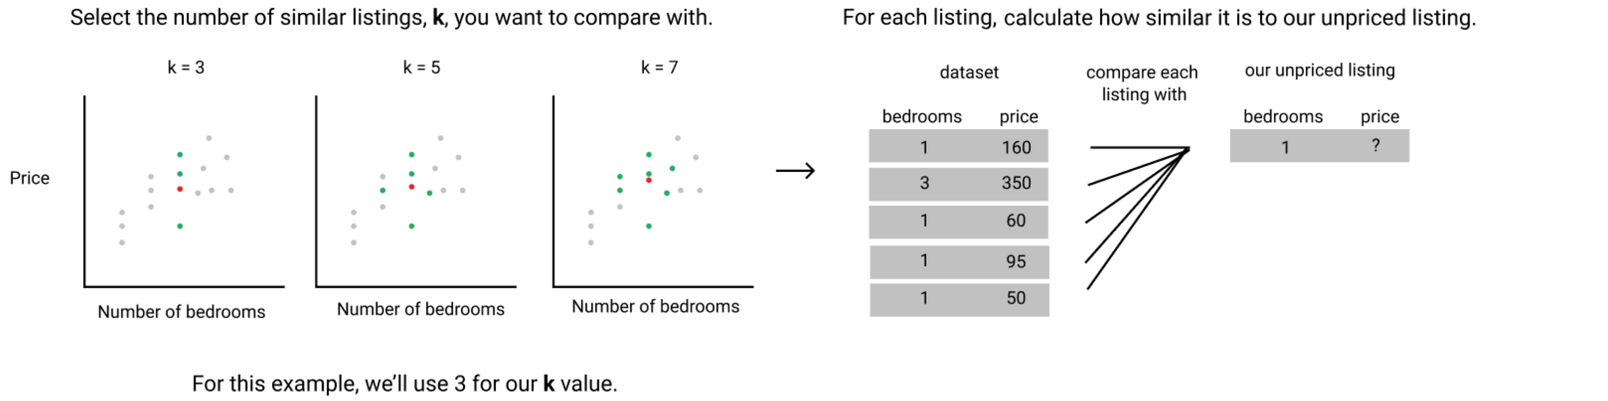

Entrainement d’un modèle

Utilisation de Scikit-learn

- L’entrainement d’un modèle suit les étapes suivantes
  - Séparation du dataset en 2 sous-jeux de données (training et test)
  - Création d’un objet modèle (*`clf`*)
  - Entrainement du modèle sur le dataset de train (`clf.fit(X_train, y_train)`)
  - Prédiction : (`y_pred = clf.predict(X_train)`)
  - Evaluation : comparaison de *`clf.predict(X_test)`* et *`y_test`*

Lien vers le notebook

https://scikit-learn.org/

模型训练
使用Scikit-learn

- 模型训练需遵循以下步骤
  - 数据集的划分（训练集与测试集）
  - 创建模型对象（*clf*）
  - 在训练数据集上训练模型（`clf.fit`（X_train，y_train））
  - 预测值：(y_pred =*clf.predict(X_train)*)
  - 评估：比较*clf.predict(X_test)*与*y_test*

笔记本链接https://scikit-learn.org/

Selection de modèles

Train/test split
Validation croisée

模型选择

训练集/测试集分割

交叉验证

Sur-apprentissage (overfitting)

Illustration

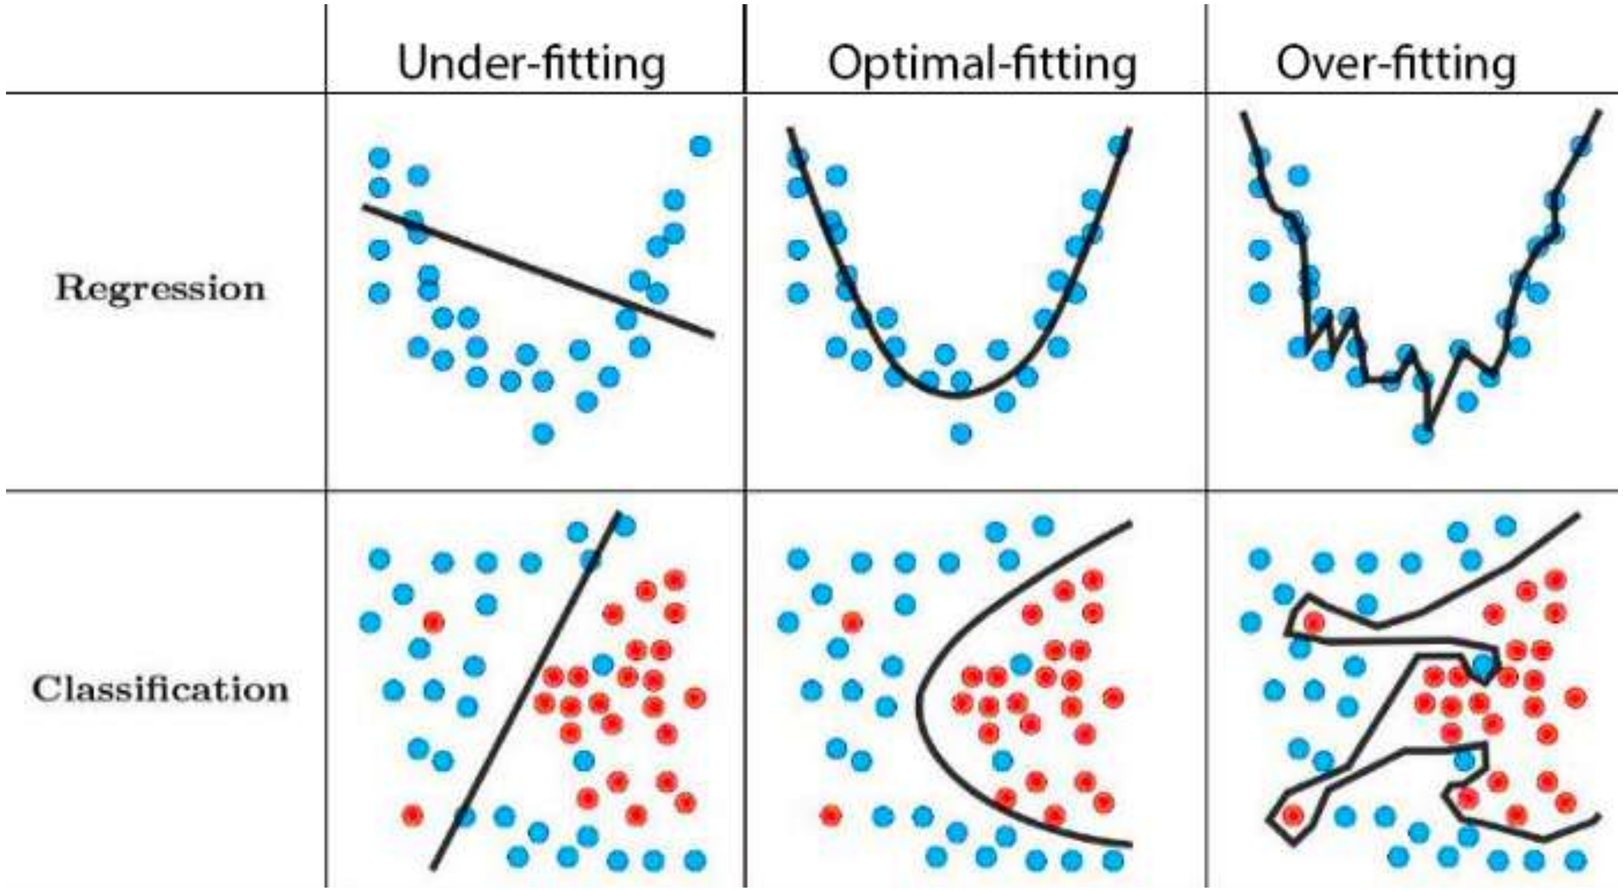

过拟合

插图

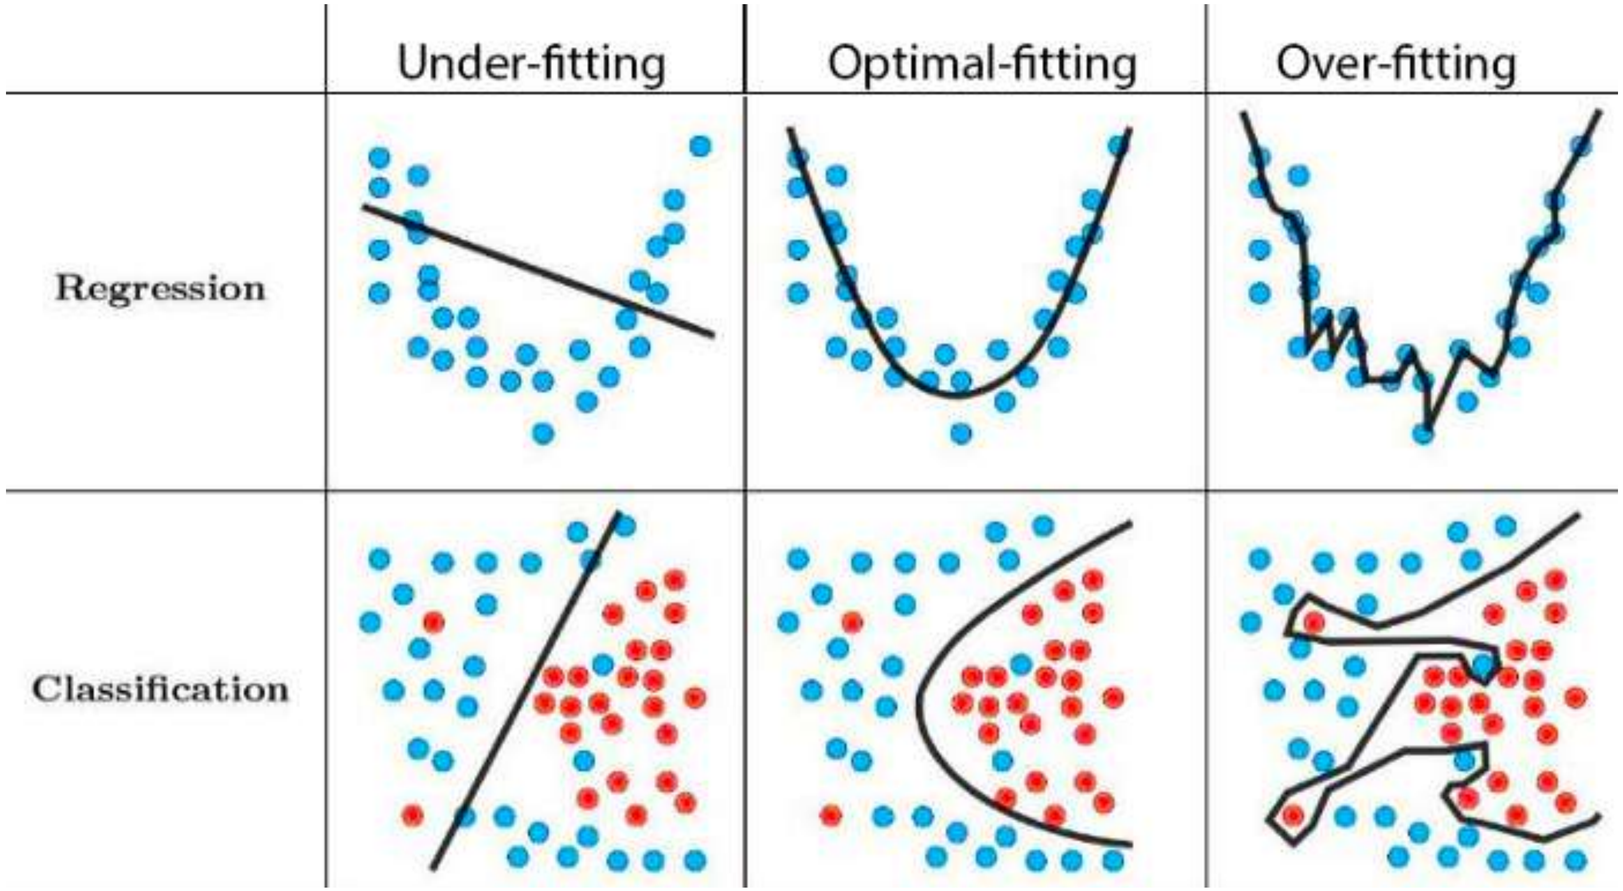
Under-fitting
Optimal-fitting
Over-fitting
Regression
Classification

Sur-apprentissage (overfitting)

- Le risque empirique n'est pas suffisant pour sélectionner le modèle : si $\mathscr{H}$ est trop grand, $R_{emp}(f) \to 0$ mais le risque réel R_{true} est grand

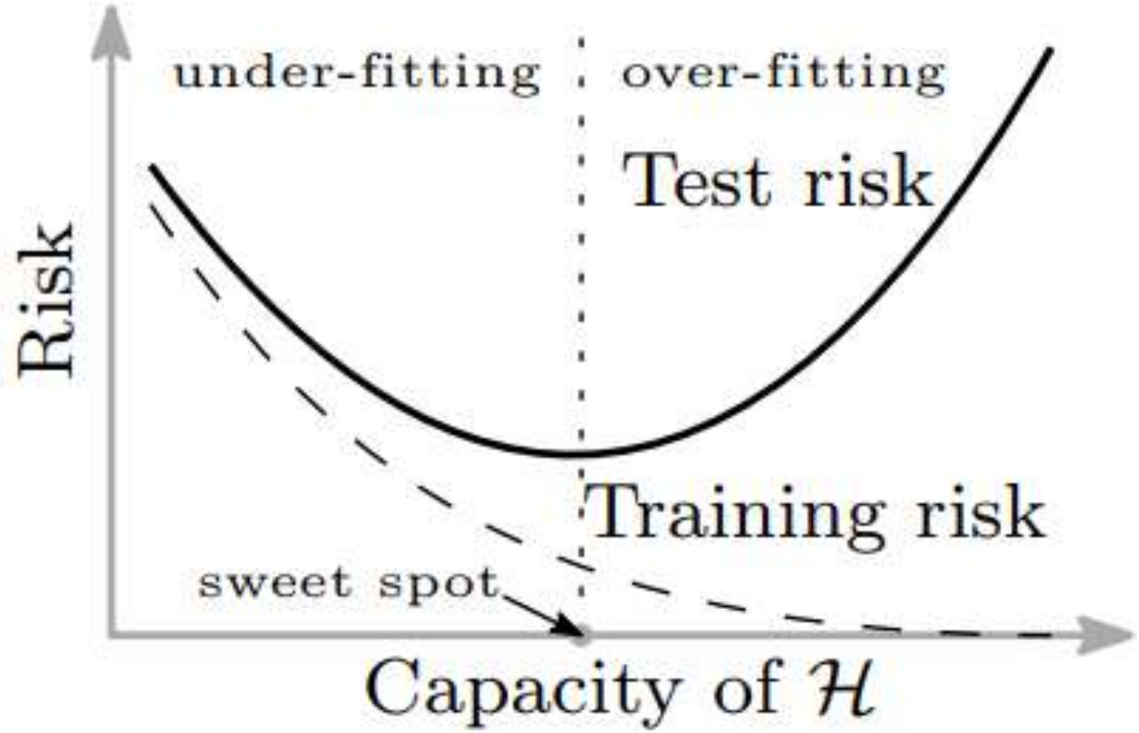

过拟合

- 经验风险不足以用于模型选择：若λ 过大，$R_{emp}(f) \to 0$，但实际风险R_{true}较大

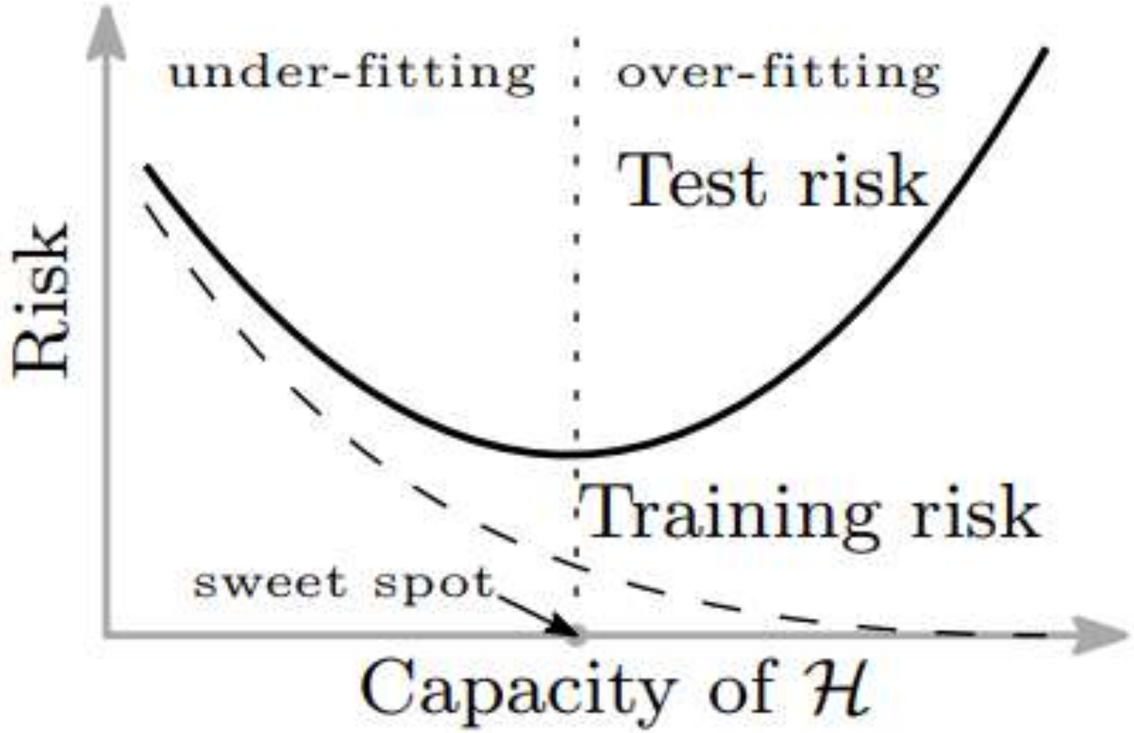

Train/validation/test split

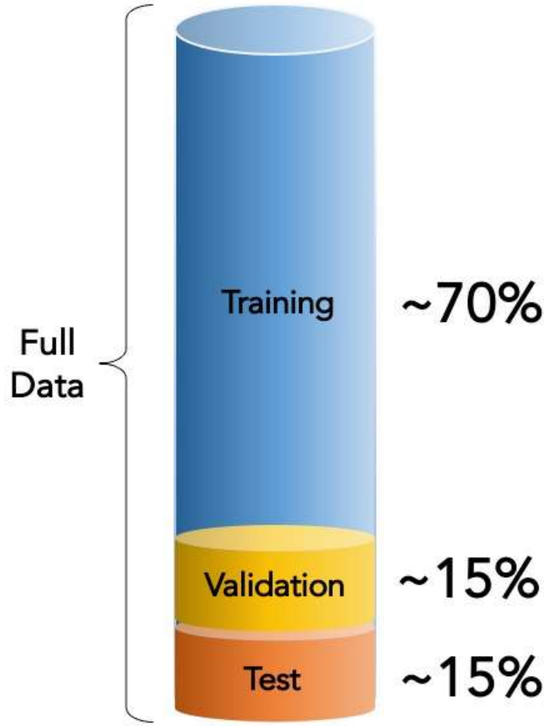

- **Si le nombre d'exemples est suffisamment grand**
  - Découper le dataset en 3 ensemble $\mathscr{D}_N = \mathscr{D}_{train} \cup \mathscr{D}_{test} \cup \mathscr{D}_{val}$
  - Entrainer plusieurs modèles f_α sur $\mathscr{D}_{train}$
  - Evaluer f_α sur $\mathscr{D}_{Val}$ en calculant leur risque empirique $R_{val}(f_\alpha) = \frac{1}{N_{Val}} \sum_{i \in \mathscr{D}_{Val}} L(y_i, f_\alpha(x_i))$
  - Sélectionner le modèle qui minimise le risque empirique $f_{best} = \arg\min_{f_\alpha} R_{Val}(f_\alpha)$
  - Tester la capacité de généralisation de f_{best} sur $\mathscr{D}_{Test}$

https://mlu-explain.github.io/train-test-validation/

训练集/验证集/测试集分割

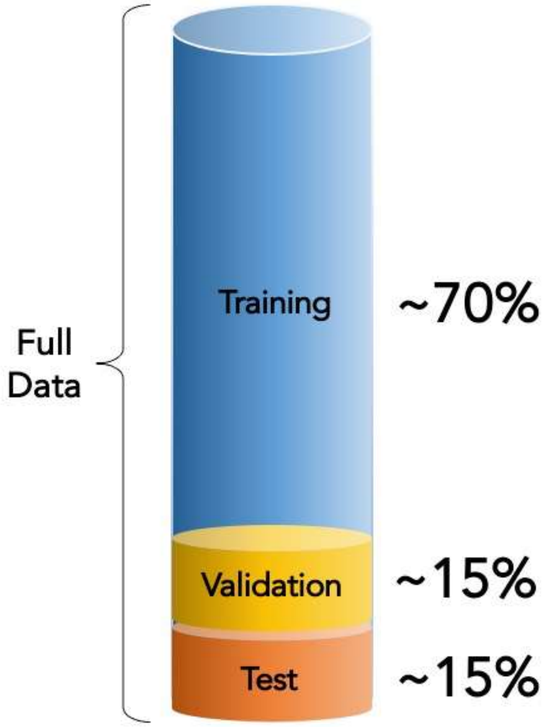

- **如果样本量足够大**
  - 将数据集划分为3个集合□□ $_N$=□□ $_{train}$ □□□□ $_{test}$ □□□□ $_{val}$
  - 训练多个les f_α模型在□□ $_{训练集}$上
  - Evaluer f_α在□□ *Valen*上计算其风险empirique $R_{val}(f_\alpha) = \frac{1}{N_{Val}} \sum_{i \in \mathcal{D}_{Val}} \mathrm{L}(y_i, f_\alpha(x_i))$
  - 选择使风险最小化的模型empirique f_{best}= arg min $R_{Val}(f_\alpha)$ α
  - 测试泛化能力de f_{best}在□□ $_{Test}$上的表现

https://mlu-explain.github.io/train-test-validation/

Sélection de modèle

Validation croisée

- **Si le nombre d'exemples est plus faible, estimation de l'erreur par re-sampling**
  - Découper $\mathscr{D}_N$ en K ensembles de tailles égales
  - Pour chaque $k = 1..K$
    - Entrainer un modèle sur les $K-1$ autres datasets
    - Evaluer le modèle sur le dataset $\mathscr{D}_k$
  - Calculer la moyenne des K erreur obtenues

Lien vers le notebook

模型选择
交叉验证

- **若样本量较少，则采用重采样法进行误差估计**
  - 将□□ $_N$分割为K个等大小的集合
  - 对于每个k=1..K
    - 在K −1个其他数据集上训练模型
    - 在数据集□□ $_k$上评估模型
  - 计算获得的K误差平均值

笔记本电脑链接

Evaluation des modèles

模型评估

Comment savoir si nous avons obtenu un bon modèle?

- Vous avez fait apprendre beaucoup de modèles sur vos données.

- Vos modèles donnent de bons résultats sur les données d'entrainement!
  - Mais comment obtenir un bon pouvoir de généralisation ?
    - **Ex : Validation croisée**
  - Comment évaluer les performances de vos modèles ?
    - **Indicateurs de performances**
  - Comment choisir le "meilleur" ?
    - **.....**

Source : [Biernart&Lutz, 2015]

如何判断我们是否获得了良好的模型?

- 您已让大量模型从您的数据中学习。

- 您的模型在训练数据上表现优异!
  - 但如何才能获得良好的泛化能力呢?
    - **例如：交叉验证**
  - 如何评估模型的性能表现?
    - **绩效指标**
  - 如何选择“最佳”方案?
    - **.....**

来源：[Biernart&Lutz，2015]

Evaluer les modèles de classification

Précision (Accuracy)

评估分类模型

精确度

Précision (Accuracy)

- Métrique de base
- Proportion de bonnes prédictions sur l'ensemble des prédictions

$$Acc(y_{true}, y_{pred}) = \frac{1}{n} \sum_{i=0}^{n} \begin{cases} 1 & \text{if } y_{pred}[i] = y_{true}[i] \\ 0 & \text{if } y_{pred}[i] \neq y_{true}[i] \end{cases}$$

- Permet de comparer différents modèles entre eux
- Donne un bon aperçu de la qualité du modèle, **quand le dataset est équilibré (*balanced*)**, c'est-à-dire autant d'éléments dans chaque classe.
- Dans le cas contraire, il peut être intéressant d'aller plus loin et de regarder le **matrice de confusion**.

Lien vers le notebook

精确度

- 基本度量
- 整体预测中正确预测的比例

$$Acc(y_{true}, ypred) = \frac{1}{n}\sum_{i=0}^{n}\begin{cases} 1 & \text{如果} y_{pred}[i] = y_{true}[i] \\ 0 & \text{如果} y_{pred}[i] \neq y_{true}[i] \end{cases}$$

- 可实现不同模型间的相互比较
- 当数据集达到平衡状态（**balanced**），即每个类别中的样本数量相等时，该模型的质量表现良好。
- 否则，深入研究并查看**混淆矩阵**可能会更有意义。笔记本链接

Evaluer les modèles de classification

Matrice de confusion

评估分类模型

混淆矩阵

Définition d'une matrice de confusion

- Une **matrice de confusion** (*confusion matrix*, ou *tableau de contingence*) met en regard des données prédites et les données observées.

- Soit un modèle de classification binaire (entre "+" et "-"), testant un dataset de test de 1000 observations.

		Observations		
		+	-	Total
Prédictions	+	250	150	400
	-	50	550	600
	Total	300	700	1000

Source : [Biernart&Lutz, 2015] - [Tufféry, 2011]

混淆矩阵的定义

- 一个**混淆矩阵**（*混淆矩阵*，或*列联表*）用于将预测数据与观测数据进行对应分析。

- 采用二元分类模型（+/-），对包含1000个观测值的测试数据集进行测试。

		Observations		
		+	-	Total
Prédictions	+	250	150	400
	-	50	550	600
	Total	300	700	1000

来源：[Biernart&Lutz，2015] - [Tufféry，2011]

Définition d'une matrice de confusion

- Dans la **matrice :**
  - **250 + 550 = 800 classifications (prédictions) sont correctes** (prédiction + et observation + OU prédiction - et observation -)
  - **50 + 150 = 200 classifications (prédictions) sont fausses** (prédiction + et observation - OU prédiction - et observation +)

		Observations		
		+	-	Total
Prédictions	+	250	150	400
	-	50	550	600
	Total	300	700	1000

Source : [Biernart&Lutz, 2015] - [Tufféry, 2011]

混淆矩阵的定义

- 在矩阵中：
  - **250 + 550 = 800个分类（预测值）正确**（预测值+观测值+或预测值-观测值）
  - **50 + 150 = 200个分类（预测值）为错误分类**（预测值+观测值-或预测值-观测值+）

		Observations		
		+	-	Total
Prédictions	+	250	150	400
	-	50	550	600
	Total	300	700	1000

来源：[Biernart&Lutz，2015] - [Tufféry，2011]

Premières métriques simples

- **Taux d'erreur** *(ERR, Error Rate)* = (50+150) / 1000 = 20% = 0,2
  (taux de prédictions fausses)

- **Accuracy** = (250 + 550) / 1000 = 0,8
  = 1 – ERR
  (taux de prédictions correctes)

		Observations		
		+	-	Total
Prédictions	+	250	150	400
	-	50	550	600
	Total	300	700	1000

Source : [Biernart&Lutz, 2015] - [Tufféry, 2011]

基本的计量指标

- **错误率***(ERR，Error Rate)*= (50+150) / 1000 = 20% = 0.2（错误预测率）
- **准确度 = (**250 + 550) / 1000 = 0.8
  = 1 – ERR（正确预测率）

		Observations		
		+	-	Total
Prédictions	+	250	150	400
	-	50	550	600
	Total	300	700	1000

来源：[Biernart&Lutz，2015] - [Tufféry，2011]

Matrice de confusion - Vocabulaire

		Observations		
		+	-	Total
Prédictions	+	Vrais positifs (VP)	Faux positifs (FP)	Total des positifs prédits (VP + FP)
	-	Faux négatifs (FN)	Vrais négatifs (VN)	Total des négatifs prédits (FN + VN)
	Total	Total des vrais positifs observés (VP + FN)	Total des vrais négatifs observés (FP + VN)	Taille totale de l'échantillon (N)

Source : [Biernart&Lutz, 2015] - [Tufféry, 2011]

混淆矩阵 - 词汇表

		Observations		
		+	-	Total
Prédictions	+	Vrais positifs (VP)	Faux positifs (FP)	Total des positifs prédits (VP + FP)
	-	Faux négatifs (FN)	Vrais négatifs (VN)	Total des négatifs prédits (FN + VN)
	Total	Total des vrais positifs observés (VP + FN)	Total des vrais négatifs observés (FP + VN)	Taille totale de l'échantillon (N)

来源：[Biernart&Lutz，2015] - [Tufféry，2011]

Matrice de confusion - Vocabulaire

- **VP** (***Vrai Positif*** *; TP, True Positives*) : **prédiction positive et correcte**.
  Les cas où la prédiction est positive, et où la valeur réelle est effectivement positive.
  Exemple : le médecin vous annonce que vous êtes malade, et vous êtes bel et bien malade.

- **VN** *(**Vrai Négatif**; TN, True Negatives)* : **prédiction négative et correcte**.
  Les cas où la prédiction est négative, et où la valeur réelle est effectivement négative.
  Exemple : le médecin vous annonce que vous n'êtes pas malade, et vous n'êtes effectivement pas malade.

- **FP** *(**Faux Positif; False Positive**)* : **prédiction positive incorrecte**.
  Les cas où la prédiction est positive, mais où la valeur réelle est négative.
  Exemple : le médecin vous annonce que vous êtes malade, mais vous n'êtes pas malade.

- **FN** (***Faux Négatif; False Negative***) : **prédiction négative incorrecte**.
  Les cas où la prédiction est négative, mais où la valeur réelle est positive.
  Exemple : le médecin vous annonce que vous n'êtes pas malade, mais vous êtes malade.

混淆矩阵 - 词汇表

- **VP（*真阳性；TP，真阳性*）：正确且准确的预测。**
  预测结果为阳性且实际值确实为正的情况。
  例如：医生告诉你生病了，而你确实病了。

- **VN（*真阴性；TN，真阴性*）：阴性且正确的预测。**
  预测结果为阴性且实际数值确实为负值的情况。例如：医生告知您并未患病，而您确实没有生病。

- **FP(*假阳性；False Positive*) :错误的阳性预测**。指预测结果为阳性，但实际值为阴性的案例。
  例如：医生告诉您生病了，但实际上您并没有生病。

- **FN（*假阴性；False Negative*）：错误的阴性预测**。指预测结果为阴性，但实际值为阳性的案例。
  例如：医生告诉您其实并未患病，但您却感到身体不适。

Matrice de confusion - Métriques

- **Taux d'erreur (ERR) =** $\dfrac{FP + FN}{N}$
- **Accuracy =** $\dfrac{VP + VN}{N}$
- **Taux de vrais positifs :** $\dfrac{VP}{VP + FN}$ aussi appelé ***rappel*** (***recall***) ou ***sensibilité*** ;
- **Précision :** $\dfrac{VP}{VP + FP}$
- Dans l'exemple précédent,
  - rappel = 250 / (250+50) = 0.83
  - Precision = 250 / (250+150) = 0.63

		Observations		
		+	-	Total
Prédictions	+	Vrais positifs (VP)	Faux positifs (FP)	Total des positifs prédits (VP + FP)
	-	Faux négatifs (FN)	Vrais négatifs (VN)	Total des négatifs prédits (FN + VN)
	Total	Total des vrais positifs observés (VP + FN)	Total des vrais négatifs observés (FP + VN)	Taille totale de l'échantillon (N)

Source : [Biernart&Lutz, 2015] - [Tufféry, 2011]

混淆矩阵-度量

- **误差率（ERR）=** $\frac{\text{腓肠肌+腓神经}}{N}$
- **准确度 =** $\frac{VP + VN}{N}$
- **真阳性率：** $\frac{\text{副总裁}}{VP + FN}$ 也称为***回忆(recall)***或***敏感性；***
- **精确度：** $\frac{\text{副总裁}}{VP + FP}$
- 在前面的例子中，
  - 下降率 = 250 / (250+50) = 0.83
  - 精度 = 250 / (250+150) = 0.63来源：

		Observations		
		+	-	Total
Prédictions	+	Vrais positifs (VP)	Faux positifs (FP)	Total des positifs prédits (VP + FP)
	-	Faux négatifs (FN)	Vrais négatifs (VN)	Total des négatifs prédits (FN + VN)
	Total	Total des vrais positifs observés (VP + FN)	Total des vrais négatifs observés (FP + VN)	Taille totale de l'échantillon (N)

[Biernart&Lutz，2015] - [Tufféry，2011]

Score F1

- Remarque : dans tous les modèles, il y a souvent un équilibre à trouver entre précision et rappel (difficile de maximiser les deux en même temps).

- **F1 score** : métrique agrégée à partir de la précision et du rappel (moyenne harmonique de la **précision** et du **rappel**).

$$F1 = \frac{2}{\frac{1}{precision} + \frac{1}{rappel}} = \frac{2 * precision * rappel}{precision + rappel}$$

Lien vers le notebook

F1评分

- 需要注意的是：在所有模型中，通常都需要在精度与召回率之间找到平衡点（两者难以同时实现最大化）。

- **F1分数**：由精确度和召回率计算得出的聚合指标（**精确度**与**召回率**的调和平均值）。

$$F1 = \frac{2}{\frac{1}{\text{精度}} + \frac{1}{\text{下降}}} = \frac{2 * \text{精度} * \text{rappel}}{\text{精度} + \text{下降}}$$

Métriques pour les régressions

回归分析指标

Notations

- **Rappel :**
  On parle de **régression** quand les valeurs à prédire sont des **nombres réels**. Le but n'est donc pas de trouver la valeur exacte mais de s'en rapprocher le plus possible.

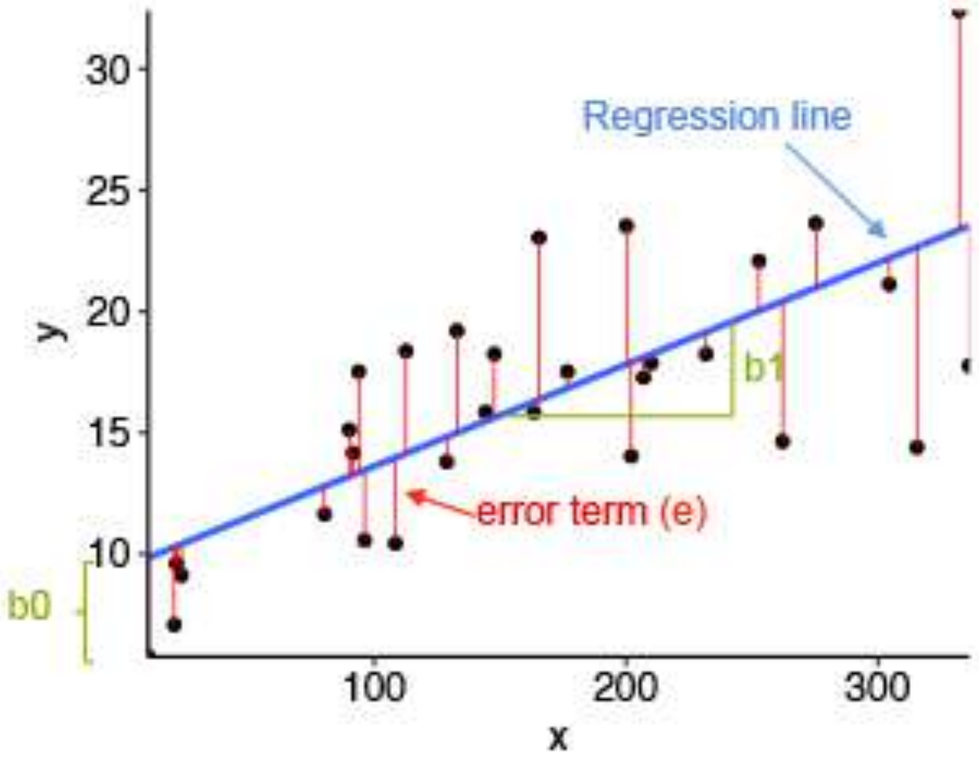

符号说明

- **提醒：**
  当需要预测的数值为**实数**时，我们称之为**回归分析**。因此其目的并非求得精确值，而是尽可能接近真实值。

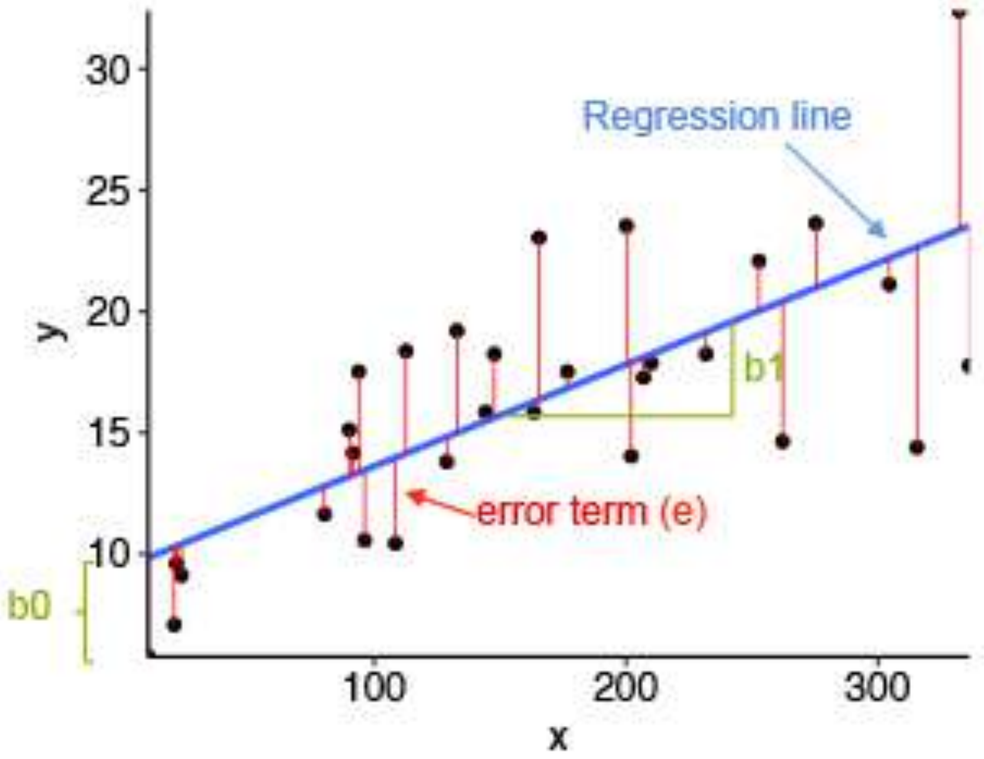

Notations

- **Notations**
  - la **valeur observée** d'une série à prédire : y_i ;
  - la **valeur prédite** par le modèle pour cette même valeur observée $\widehat{y_i}$;
  - une **prévision naïve de référence**, qui est la moyenne de la valeur observée $\overline{y}$.
- Elles permettent de calculer, pour tout i des m observations :
  - l'**erreur de prédiction** du modèle : $y_i - \widehat{y_i}$;
  - l'**erreur de prédiction naïve** : $y_i - \overline{y}$.

符号说明

- **符号说明**

  - 待预测序列的**观测值**：y_i；
  - 模型对该观测值y_i所预测的**值**；
  - 一个**基准朴素预测**，即观测值y的平均值。

- 它们可用于计算所有m个观测值中任意i的值：

  - 模型预测误差：$y_i - \hat{y}_i$；
  - **l简单预测误差：**$y_i - y$。

Exemples de métriques

- **Erreur moyenne absolue (MAE, Mean Absolute Error) :**

$$\frac{1}{m}\sum_{i=1}^{m} |\, y_i - \widehat{y_i} \,|$$

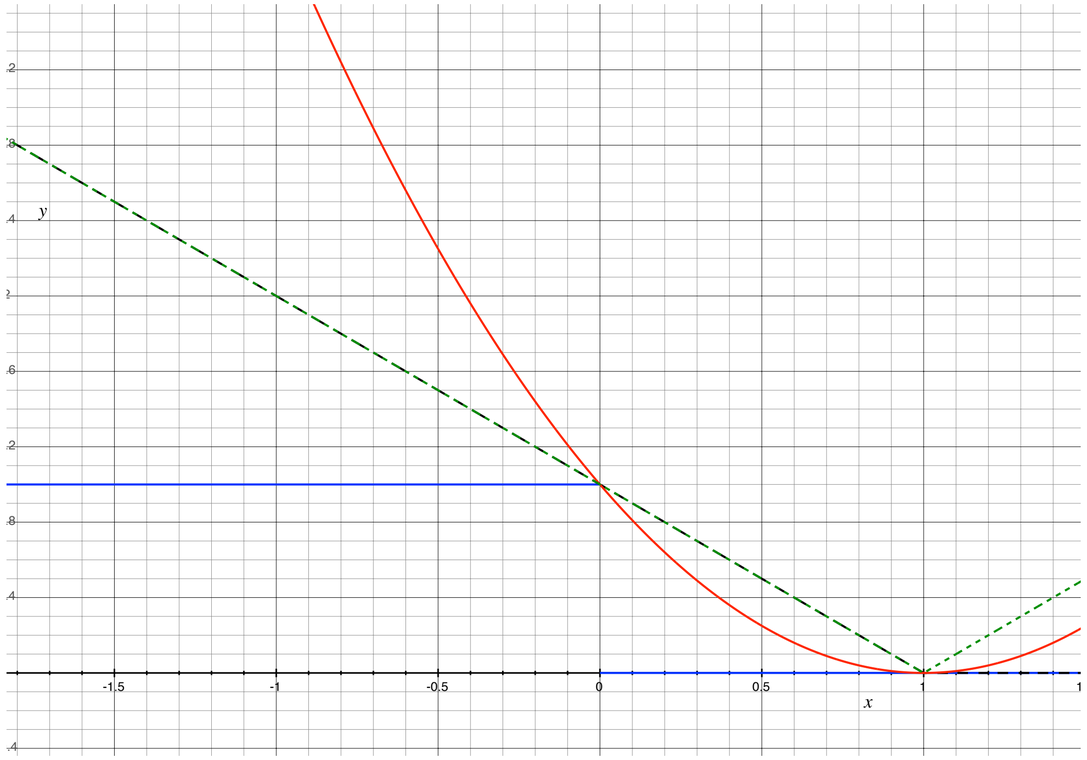

度量示例

- 平均绝对误差（MAE，Mean Absolute Error）：

$$\frac{1}{m}\sum_{i=1}^{m}|y_i-\hat{y}_i|$$

Exemples de métriques

- **Erreur quadratique moyenne (MSE, Mean Square Error) :**

$$\frac{1}{m}\sum_{i=1}^{m}(y_i - \widehat{y_i})^2$$

- **Racine carrée de la moyenne du carré des erreurs (RMSE, Root Mean Squared Error)**

$$\sqrt{\frac{1}{m}\sum_{i=1}^{m}(y_i - \widehat{y_i})^2}$$

度量示例

- 均方误差（MSE，Mean Square Error）：

$$\frac{1}{m}\sum_{i=1}^{m}(y_i-\widehat{y_i})^2$$

- 均方根误差（RMSE）的平方根

$$\sqrt{\frac{1}{m}\sum_{i=1}^{m}(y_i-\widehat{y_i})^2}$$

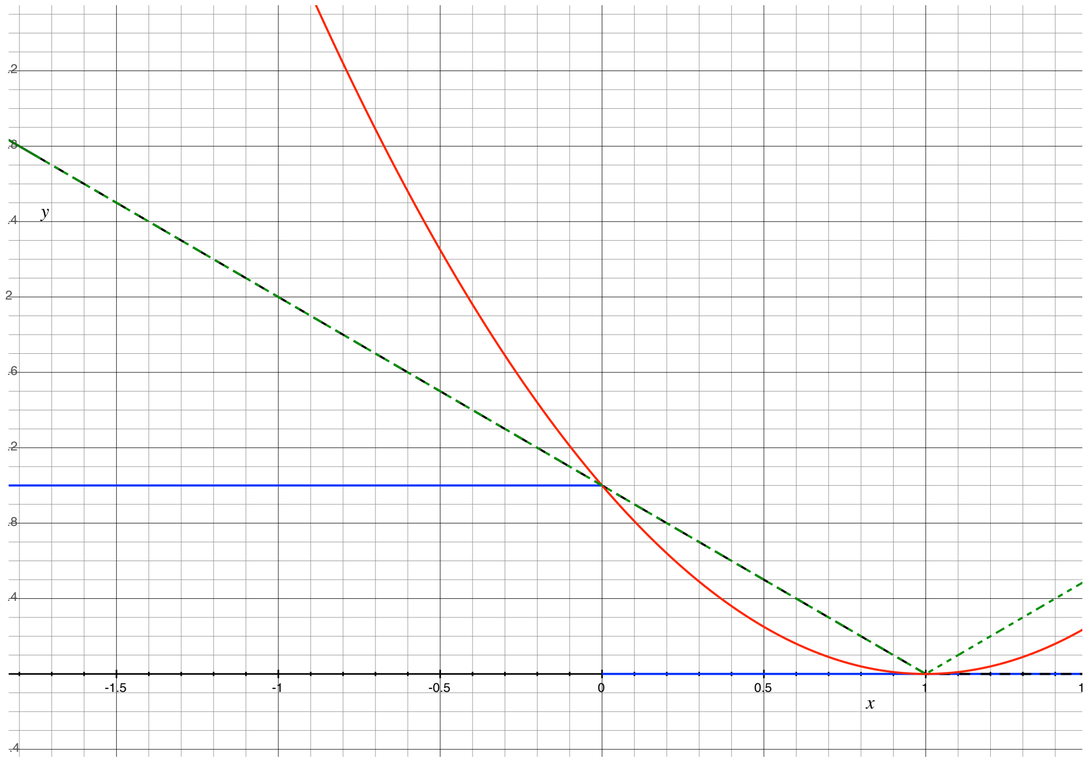

Exemples de métriques

- **le coefficient de détermination (R^2) :**

$$1 - \frac{\sum_{i=1}^{m} (y_i - \widehat{y_i})^2}{\sum_{i=1}^{m} (y_i - \overline{y})^2}$$

- On peut voir le R2 comme l'erreur du modèle divisé par l'erreur d'un modèle basique qui prédit tout le temps la moyenne de la variable à prédire.
- Utile pour **comparer 2 modèles**, mais pas pour interpréter 1 seul modèle.

度量示例

- **决定系数（R ²）：**

$$1 \text{ 减 } \frac{\sum_{i=1}^{m}(y_i - \widehat{y_i})^2}{\sum_{i=1}^{m}(y_i - y)^2}$$

- R^2可视为模型误差与基础模型误差的比值，其中基础模型始终预测被预测变量的均值。
- 适用于**比较两种模型**，但无法用于单独解读单一模型。

Comparaison

- Pas de meilleure métrique, elles permettent d'évaluer des modèles selon différentes dimensions !
- **Interprétation :**
  - MAE et RMSE ont une erreur dans l'unité et l'ordre de grandeur de la valeur observée (facilement interprétable)
  - MSE a une erreur dans le carré de l'ordre de grandeur de la valeur observée
- **Outliers :**
  - MSE et RMSE a tendance à plus pénaliser les grandes erreurs
    => très sensibles aux outliers
  - MAE pénalise autant les petites que les grandes erreurs

比较

- 这些指标并非最优选择，但它们能帮助我们从不同维度对模型进行评估!

- **解释：**
  - MAE和RMSE在观测值的单位和数量级上存在误差（易于解释）
  - MSE在观测值的数量级平方项中存在误差

- **异常值：**
  - 均方误差（MSE）和均方根误差（RMSE）往往对较大误差值的惩罚更为严格，因此对异常值（outliers）具有高度敏感性。
  - MAE对小错误和大错误同样进行惩罚

Régression logistique

逻辑回归

Régression linéaire

Principe

- Objectifs : trouver une corrélation linéaire entre une target à prédire et un ensemble de features
- Hypothèses :
  - Les targets doivent être une combinaison linéaire des features
  - Les features doivent être normalement distribuées
- 2 types de régressions linéaires :
  - Simple : 1 seule feature
  - Multiple : plusieurs features

线性回归

王子

- 目标：建立待预测目标与特征集之间的线性相关性

- 假设：
  - 目标必须是特征的线性组合
  - 特征应呈正态分布

- 两种线性回归类型：
  - 简单：仅含1个特征
  - 多发性：多种特征

Régression linéaire simple linéaire

- Trouver les coefficients a et b qui minimisent l'erreur entre une target $Y \in \mathbb{R}^N$ dépendant linéairement d'une observation $X \in \mathbb{R}^{N\text{x}1}$ indépendante

$$Y = aX + b$$

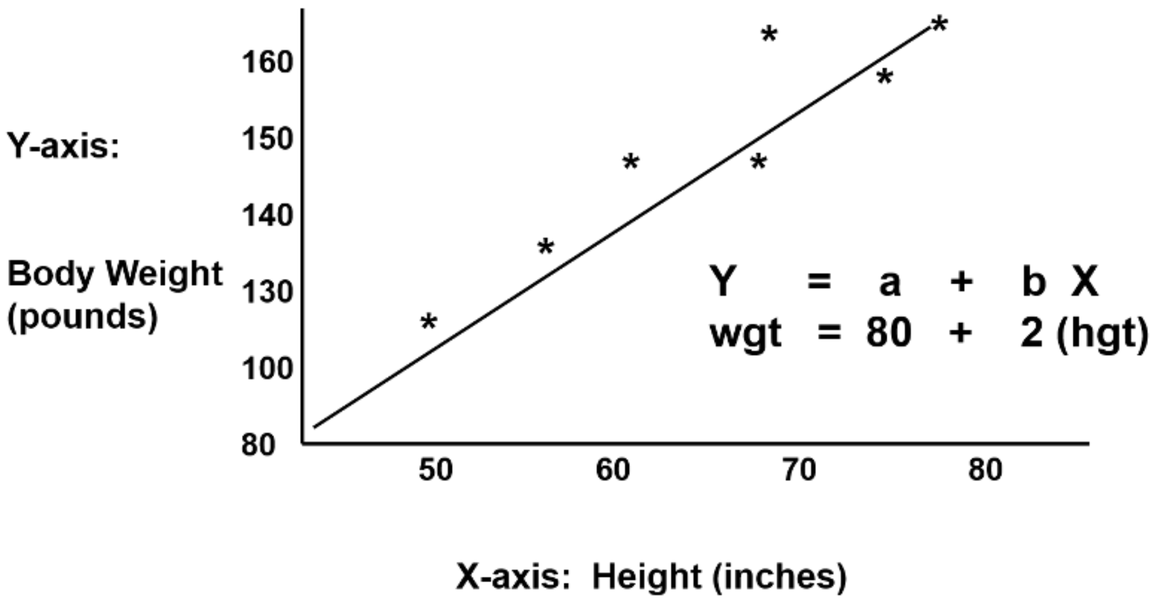

简单线性回归

- 寻找使目标$Y \in \mathbb{R}^N$与观测值$X \in \mathbb{R}^{N\times 1}$线性相关时误差最小化的系数$a$和$b$

$$Y = aX + b$$

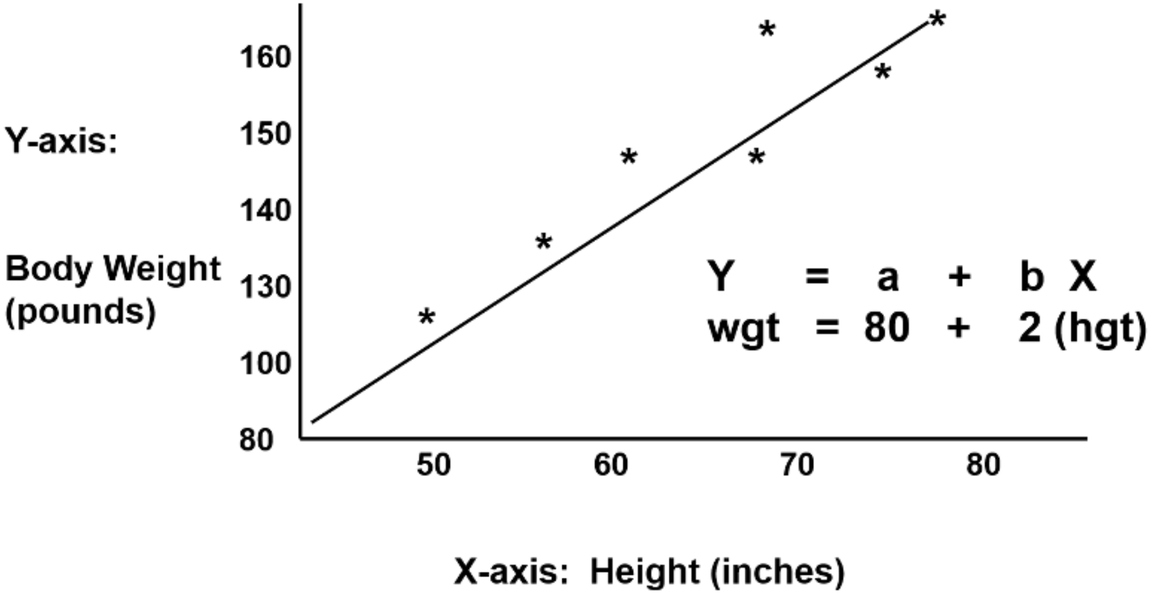

Régression linéaire multiple

- Généralisation de la régression linéaire simple à plusieurs features $X \in \mathbb{R}^{N\text{x}d}$

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_3 + \ldots \beta_d X_d + \epsilon$$

- Les coefficients β_i sont obtenus par descente de gradient (vu avec M. Berro) ou par résolution des équations.

Lien vers le notebook

多元线性回归

- 将简单线性回归推广到多特征空间$X \in \mathbb{R}^{N \times d}$

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_3 + \ldots \beta_d X_d + \epsilon$$

- 系数β_i可通过梯度下降法（参考M. Berro的研究）或方程求解法获得。

笔记本电脑链接

Régression logistique

Principe

- Application de la régression linéaire à la classification binaire
- Utilisation d'une fonction sigmoid (logistic) pour prédire la probabilité d'appartenance à une classe
- Fonction logistique : $y = \dfrac{1}{1 + e^{-x}} \in [0,1]$
  - Si la probabilité est >0.5, on prédit la classe 1
  - Sinon, on prédit la classe 0

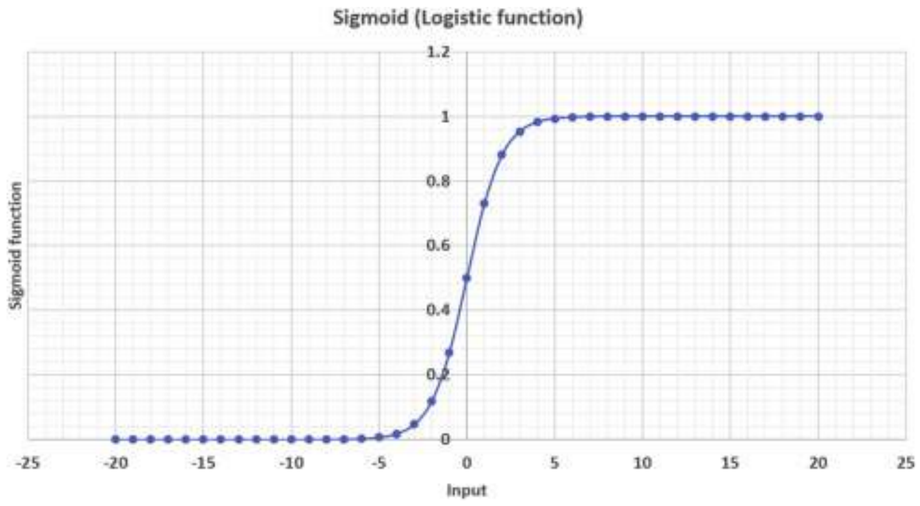

https://www.sciencedirect.com/topics/computer-science/logistic-regression

逻辑回归

王子

- 线性回归在二分类中的应用
- 采用S型（逻辑）函数预测类别归属概率

- 逻辑函数：$y=\dfrac{1}{1+e^{-x}} \in [0,1]$
- 若概率大于0.5，则预测该类别 1
- 否则，人们就会预测阶级问题。 0

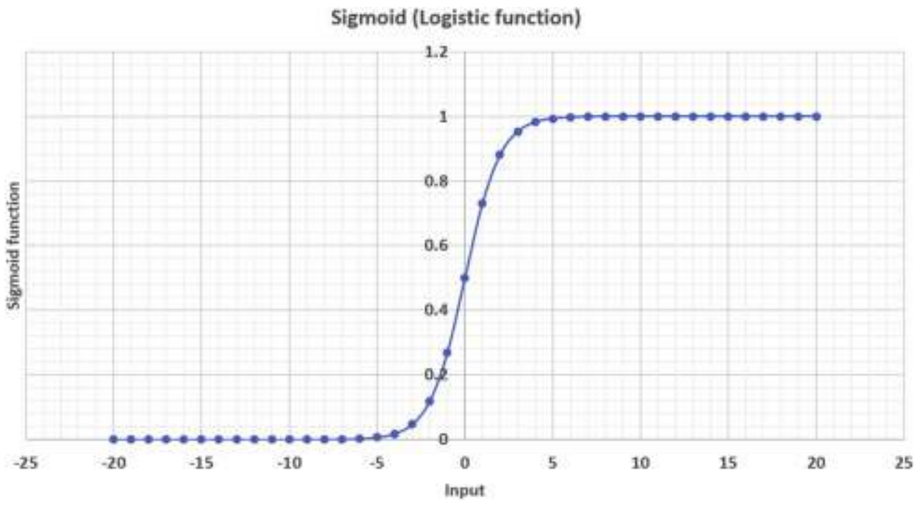

https://www.sciencedirect.com/topics/computer-science/logistic-regression

Régression logistique

- La régression logistique est une forme paramétrique d'une distribution de probabilité $P(Y|X)$ où $Y \in \mathbb{R}^N$ est l'espace à prédire et $X \in \mathbb{R}^{N\text{x}d}$ l'espace des features

- Le modèle paramétrique peut être écrit :

$$P(Y = 1 \,|\, X) = \frac{1}{1 + exp\left(\beta_0 + \sum_{i=1}^{d} \beta_i X_i\right)}$$

et

$$P(Y = 0 \,|\, X) = \frac{exp\left(\beta_0 + \sum_{i=1}^{d} \beta_i X_i\right)}{1 + exp\left(\beta_0 + \sum_{i=1}^{d} \beta_i X_i\right)}$$

- Les coefficients β_i sont optimisés pour maximiser la vraisemblance conditionnelle des données, c'est à dire la probabilité d'apparition d'une observation Y dans le dataset

逻辑回归

- 逻辑回归是一种参数化的概率分布$P(Y|X)$ 的形式，其中$Y \in$ ï ^{N}是待预测空间，$X \in$ ï $^{N\text{x}d}$ 是特征空间。
- 参数化模型可表示为：

$$P(Y=1\,|\,X) = \frac{1}{1+exp\left(\beta_0 + \sum_{i=1}^{d}\beta_i X_i\right)}$$

乙

$$P(Y=0\,|\,X) = \frac{exp\left(\beta_0 + \sum_{i=1}^{d}\beta_i X_i\right)}{1+exp\left(\beta_0 + \sum_{i=1}^{d}\beta_i X_i\right)}$$

- cients β_i经过优化处理，旨在最大化数据条件似然度——即数据集中观测值Y出现的概率。

Régression logistique

Cas multiclasse

- Stratégie du “One-vs-rest”
  - On cherche un modèle qui sépare 1 classe de toutes les autres classes du dataset
  - Séparation de 3 classes [rouge, vert, bleu]
    - 1 modèle logistique de “rouge” vs [vert+bleu]
    - 1 modèle logistique de “vert” vs [rouge+bleu]
    - 1 modèle logistique de “bleu” vs [rouge+vert]
  - On obtient une segmentation de l’espace en assemblant les différents modèles

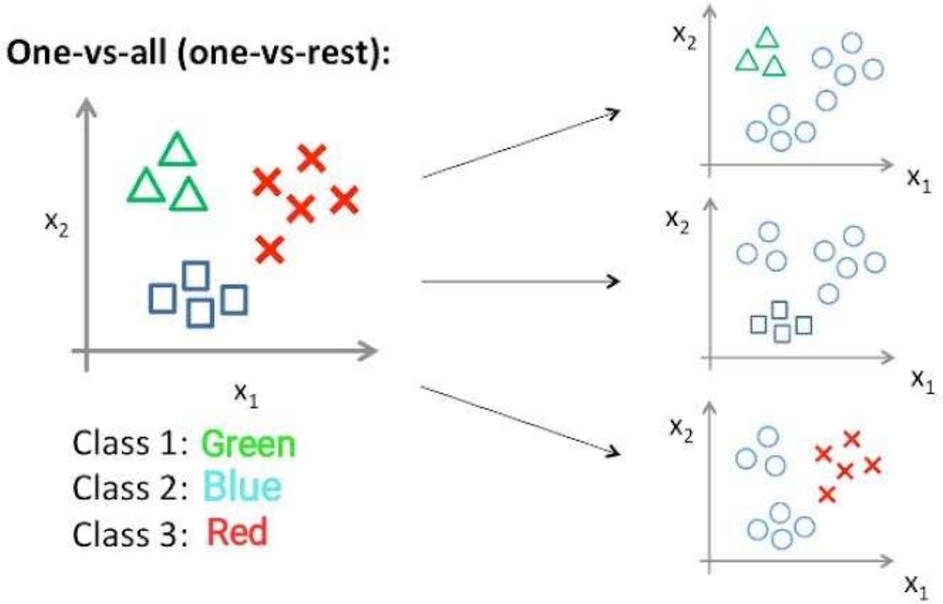

https://antonhaugen.medium.com/introducing-mllibs-one-vs-rest-classifier-402eeab22493

Lien vers le notebook

逻辑回归
多类病例

- “一对多”战略
  - 我们正在寻找一种能够将数据集中某一类与其他所有类别区分开来的模型
  - 3类分离[红、绿、蓝]
    - 1个红色对[绿色+蓝色]的逻辑模型
    - 绿色物流模型对比[红色+蓝色]模型
    - 1个蓝色逻辑模型对比[红色+绿色]
  - 通过组装不同模型可实现空间分割

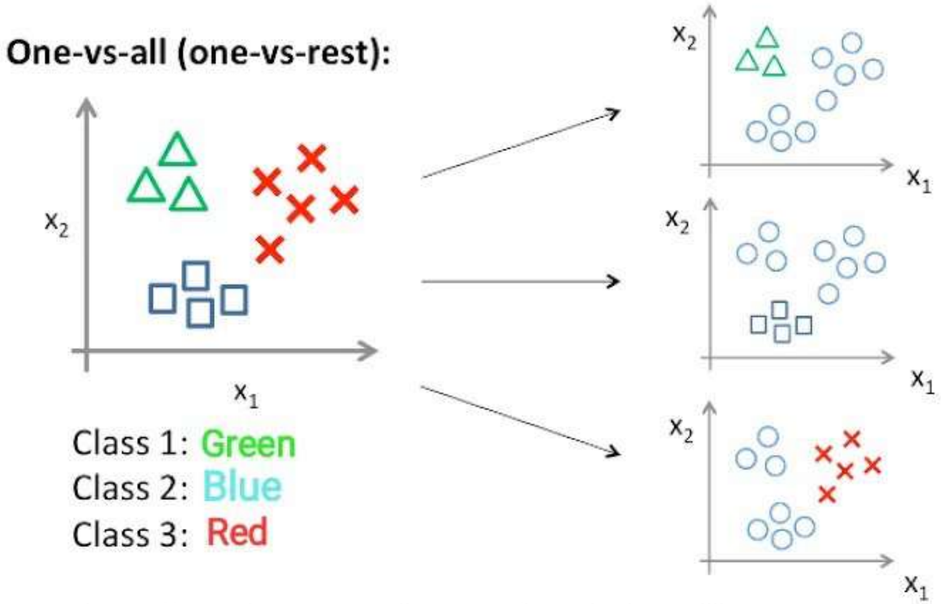

https://antonhaugen.medium.com/introducing-mllibs-one-vs rest-classifier-402eeab22493

笔记本电脑链接

Regression logistique: Avantages et inconvénients

Avantages

- Facile à interpréter
- Efficacité computationnelle
- Peu sensible au sur-apprentissage
- Pas besoin de normalisation

Inconvénients

- Hypothèse de linéarité
- Sensibilité au déséquilibre de classe
- Performance limitée sur les données complexes
- Sensibilité aux données aberrantes

逻辑回归：优势与劣势

优势

- 易于理解
- 计算效率
- 对过学习现象不敏感
- 无需标准化处理

缺点

- 线性假设
- 阶级失衡敏感性
- 复杂数据的性能限制
- 对异常数据的敏感性

Support Vector Machine

支持向量机

Introduction

- Le **Support Vector Machine** ou SVM est un puissant algorithme capable de trouver des patterns fortement non linéaires. Il repose sur deux idées essentielles :
  - la **maximisation de la marge** entre la frontière de décision et les exemples les plus proches, qu'on appelle les **vecteurs de support** ;
  - et le choix d'un **hyperplan séparateur dans un nouvel espace de combinaisons non linéaires entre les variables**, dans lequel une séparation linéaire des individus sera possible.

Source : [Biernart&Lutz, 2015]

导言

- **支持向量机**（SVM）是一种强大的算法，能够识别高度非线性的模式。其核心原理基于两个关键概念：
  - **最大化决策边界与最近样本之间的间隔**，这些最近样本被称为**支持向量**；
  - 以及在变量之间新的非线性组合空间中选择**一个超平面分离器，**其中个体之间可以实现线性分离。

来源：[Biernart&Lutz，2015]

Introduction : discrimination linéaire

- Soit le cas le plus simple : classification **binaire** de m observations (en **2 dimensions**) **linéairement séparables.**

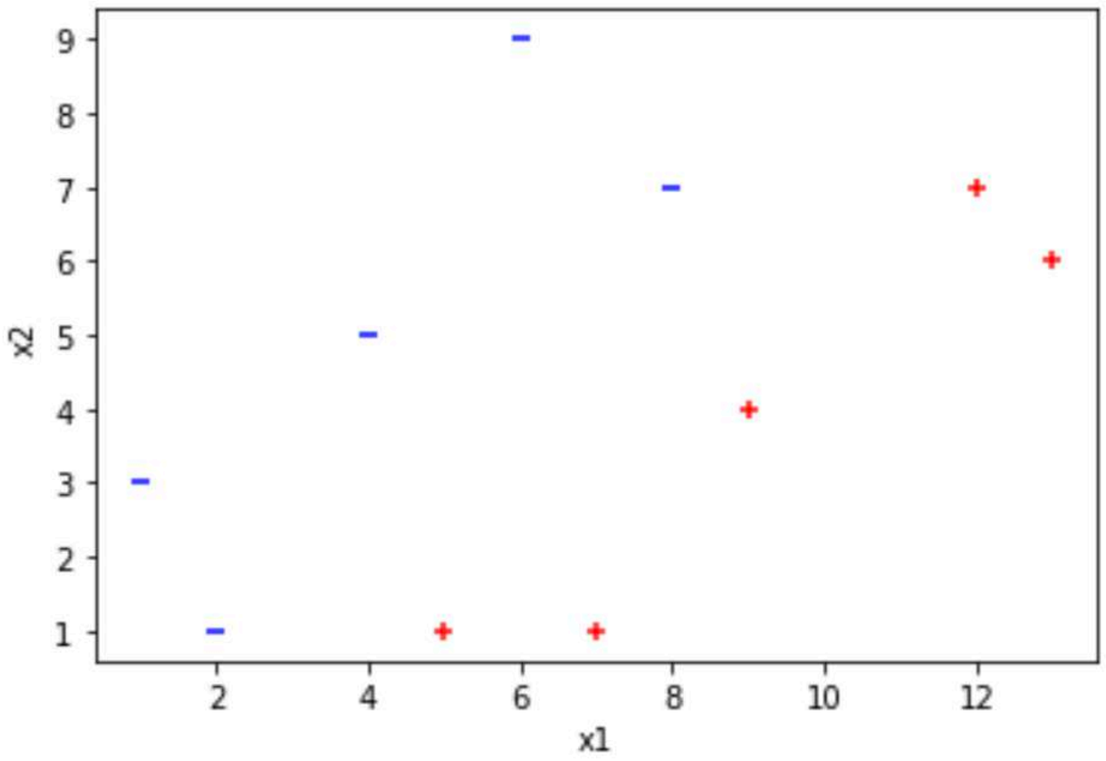

引言：线性判别

- 最简单的情况是：对m个观测值（在**2维**空间中）进行**二分类**，且这些观测值具有**线性可分性**。

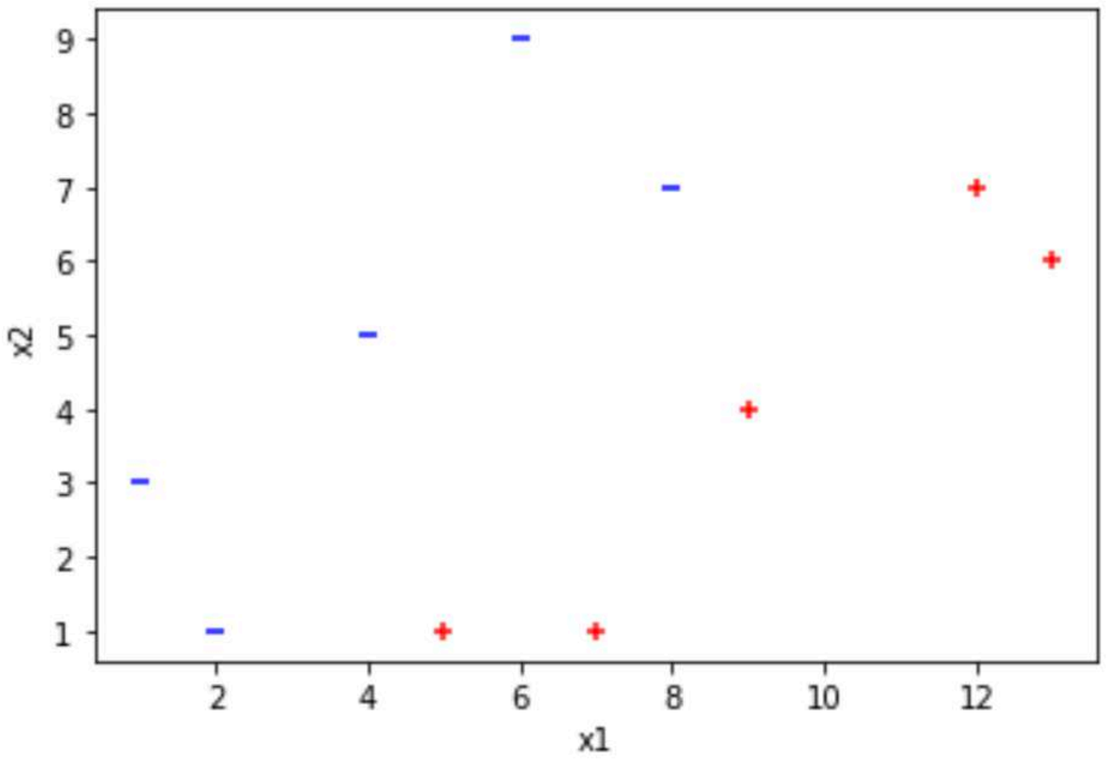

Introduction : discrimination linéaire

- Soit le cas le plus simple : classification **binaire** de m observations (en **2 dimensions**) **linéairement séparables.**

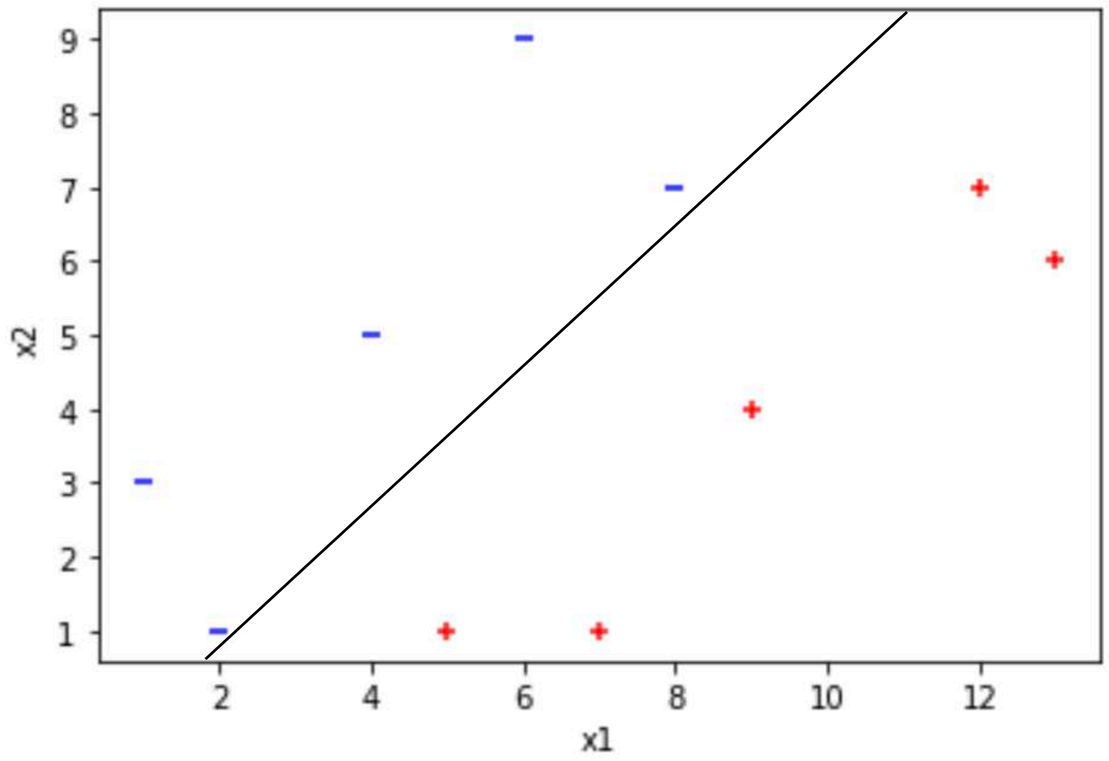

引言：线性判别

- 最简单的情况是：对m个观测值（在**2维**空间中）进行**二分类**，且这些观测值具有**线性可分性**。

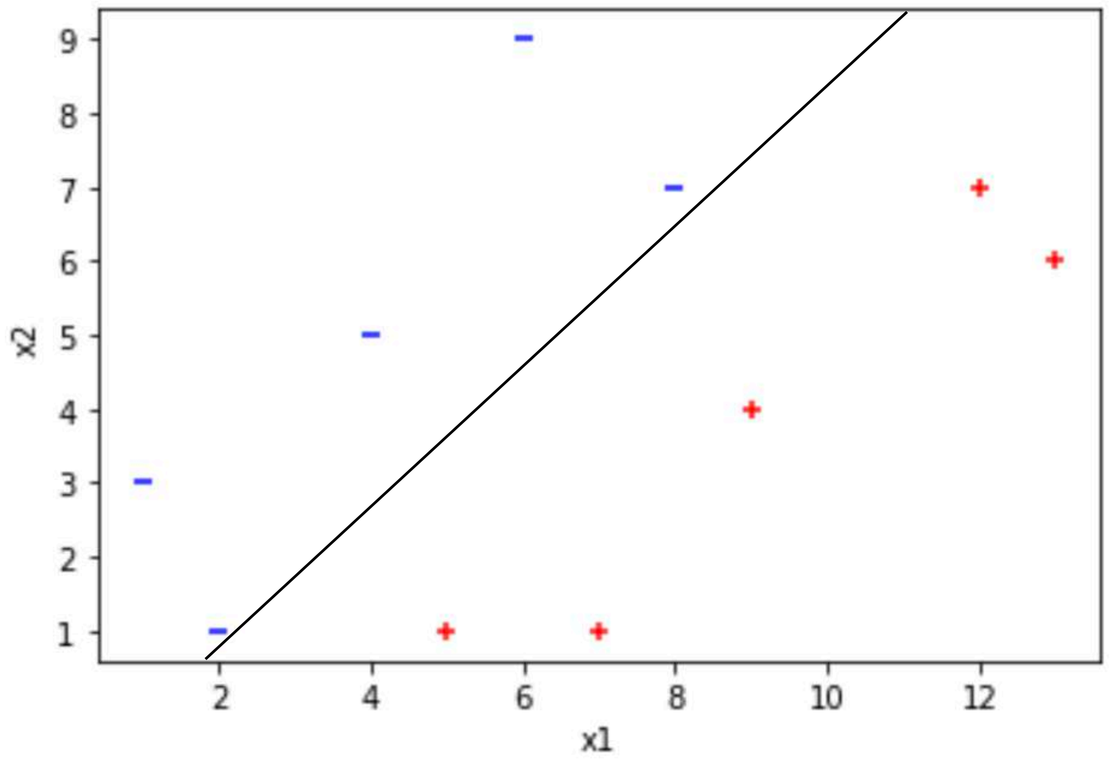

Introduction : discrimination linéaire

- Soit le cas le plus simple : classification **binaire** de m observations (en **2 dimensions**) **linéairement séparables.**

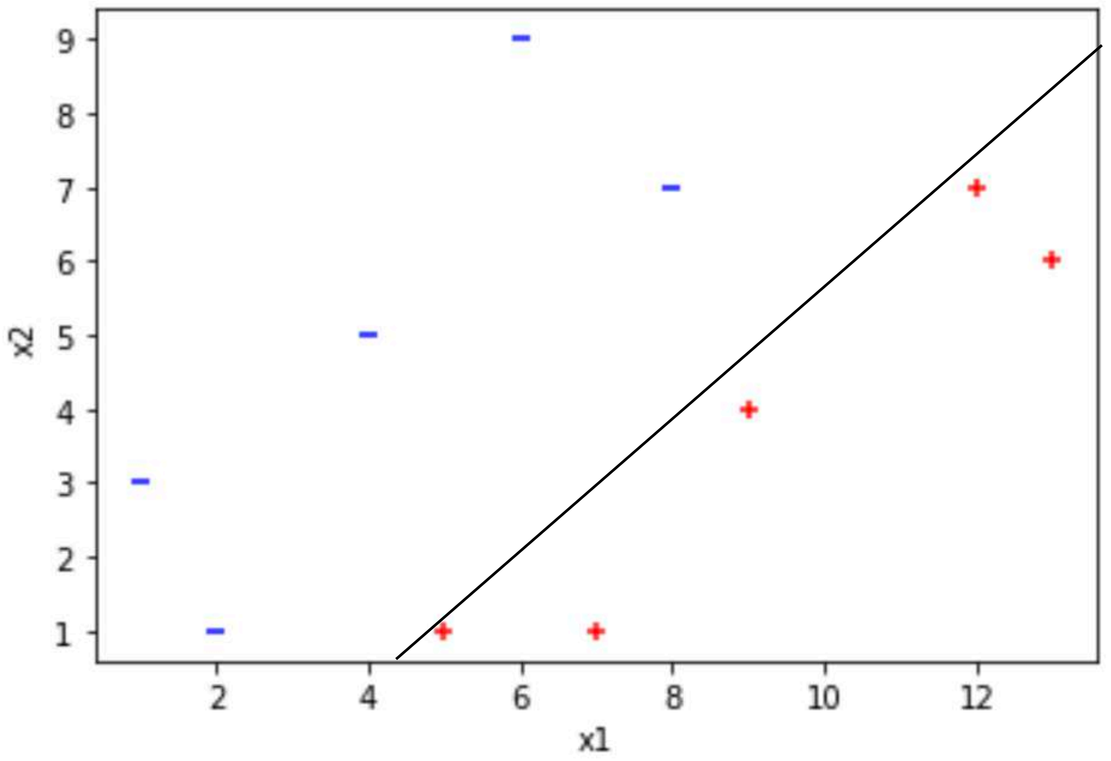

引言：线性判别

- 最简单的情况是：对m个观测值（在**2维**空间中）进行**二分类**，且这些观测值具有**线性可分性**。

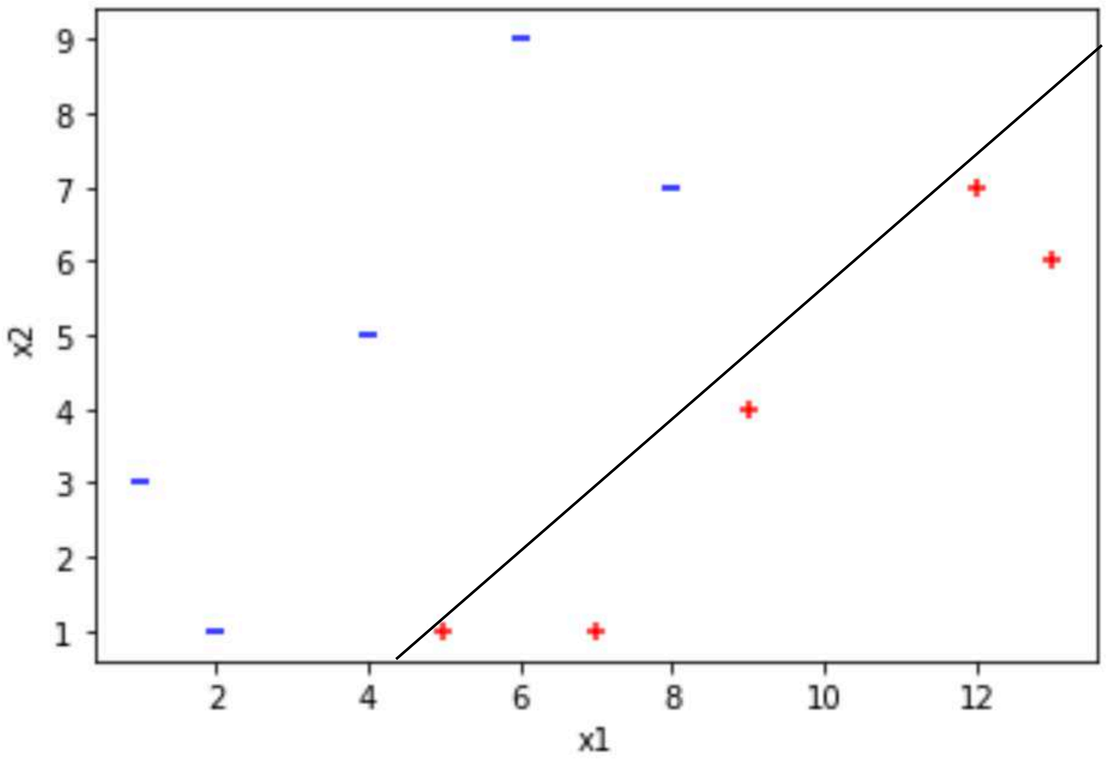

Introduction : discrimination linéaire

- Soit le cas le plus simple : classification **binaire** de m observations (en **2 dimensions**) **linéairement séparables.**

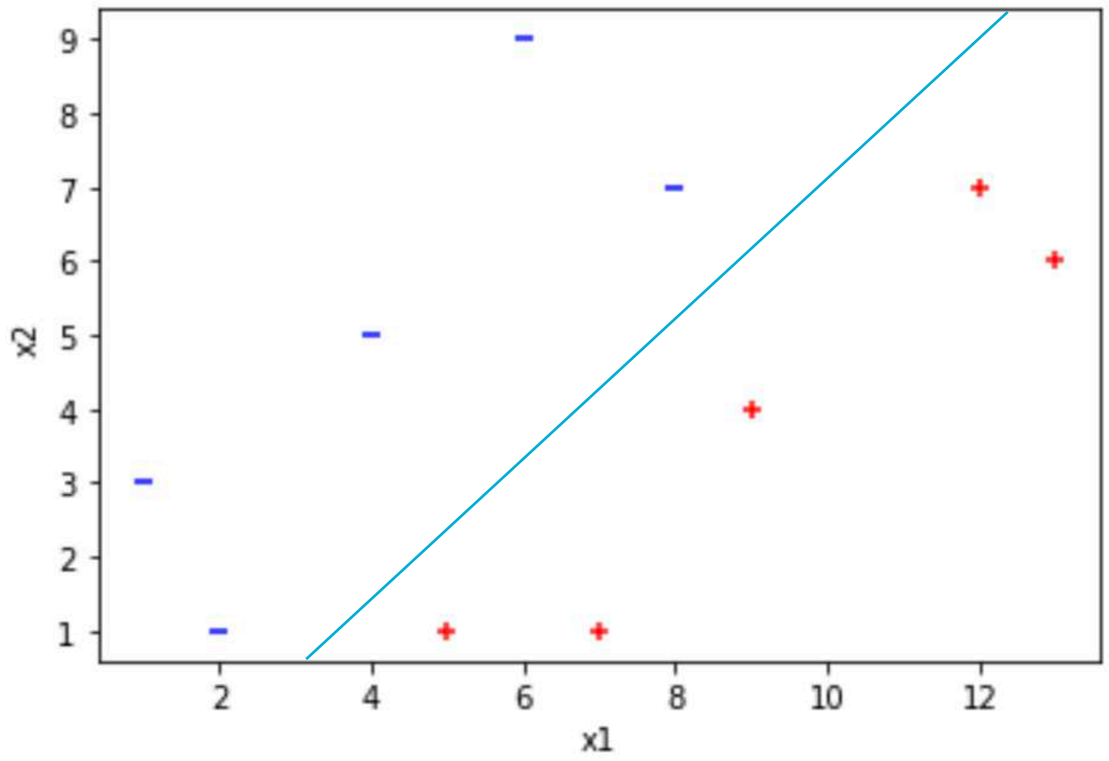

引言：线性判别

- 最简单的情况是：对m个观测值（在**2维**空间中）进行**二分类**，且这些观测值具有**线性可分性**。

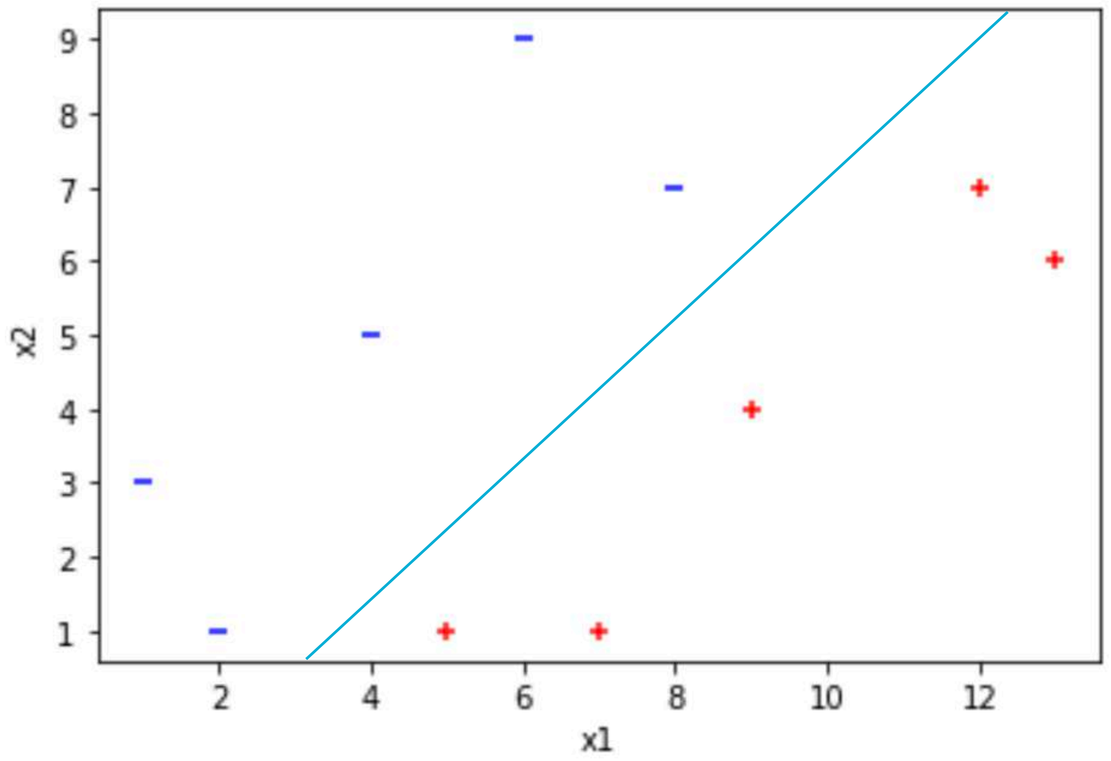

Introduction : discrimination linéaire

- Soit le cas le plus simple : classification **binaire** de m observations (en **2 dimensions**) **linéairement séparables.**

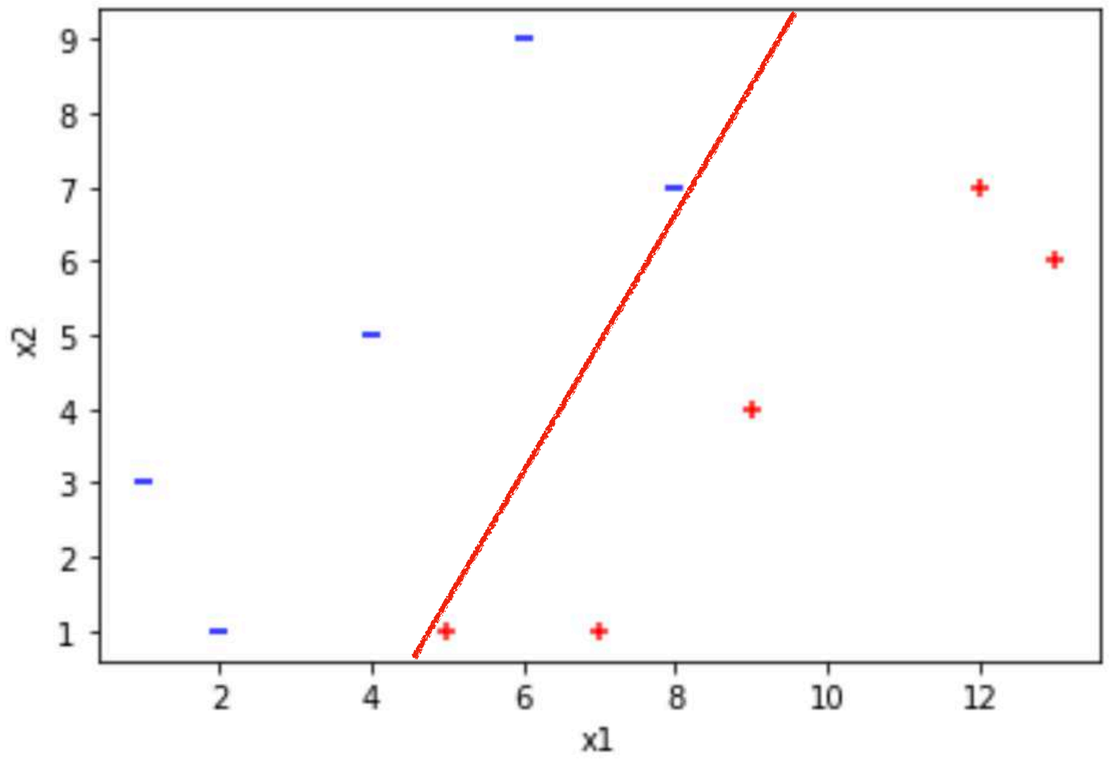

引言：线性判别

- 最简单的情况是：对m个观测值（在**2维**空间中）进行**二分类**，且这些观测值具有**线性可分性**。

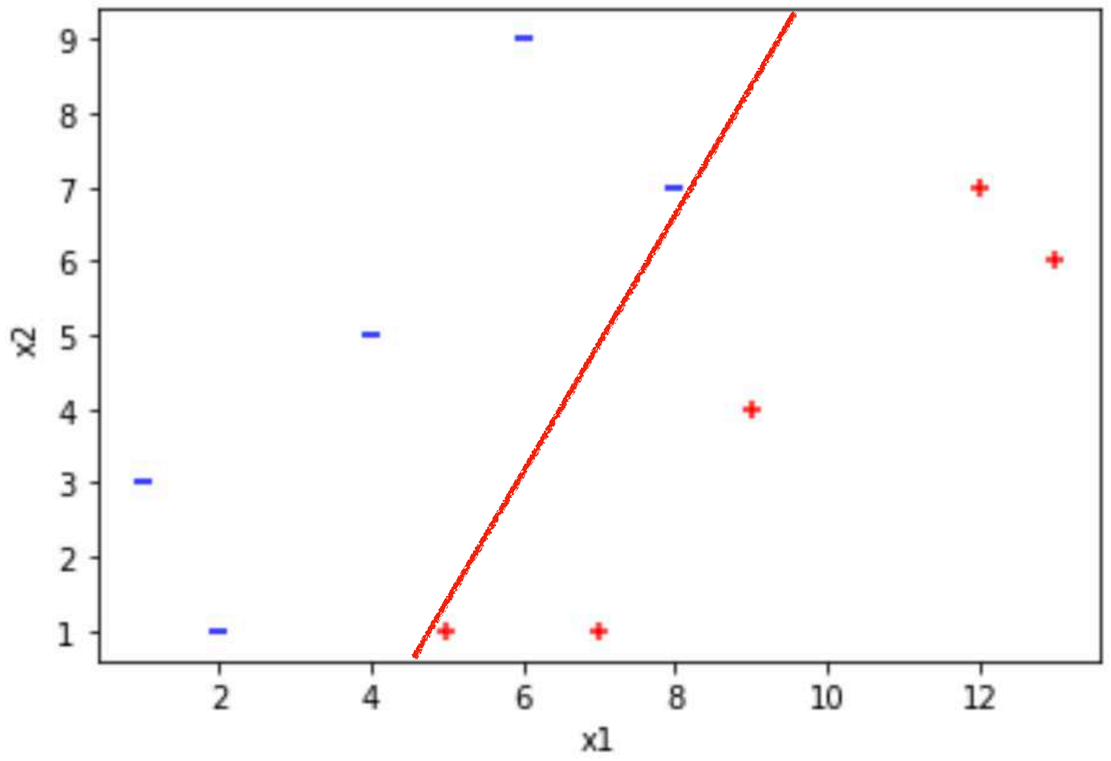

Introduction : discrimination linéaire

- Soit le cas le plus simple : classification **binaire** de m observations (en **2 dimensions**) **linéairement séparables.**

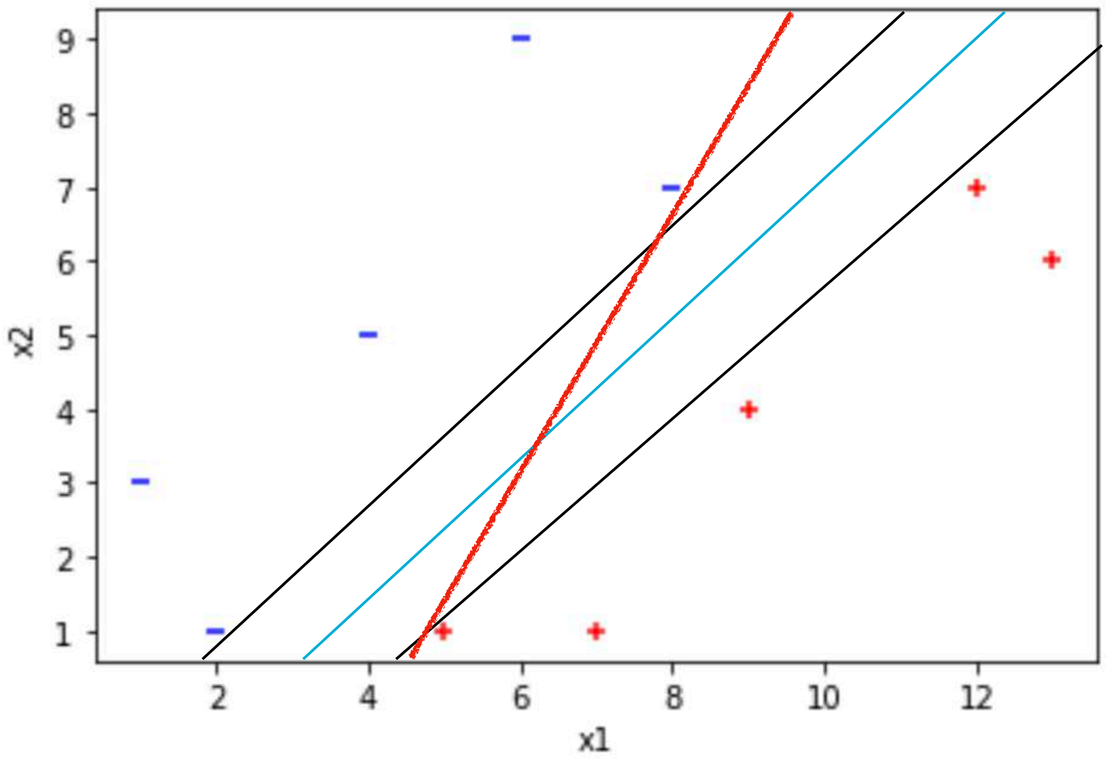

- **Que dire de ces 4 modèles ?**
- Note :
  - en 2 dimensions, le séparateur est une droite ;
  - en 3 dimensions, un plan ;
  - en N dimensions, un **hyperplan** (espace de N-1 dimensions)

引言：线性判别

- 最简单的情况是：对m个观测值（在**2维**空间中）进行**二分类**，且这些观测值具有**线性可分性。**

- **这4款型号究竟如何?**
- 注：
  - 在二维空间中，分隔线是一条直线；
  - 三维空间中的一平面；
  - 在N维空间中，一个**超平面**（N-1维空间）

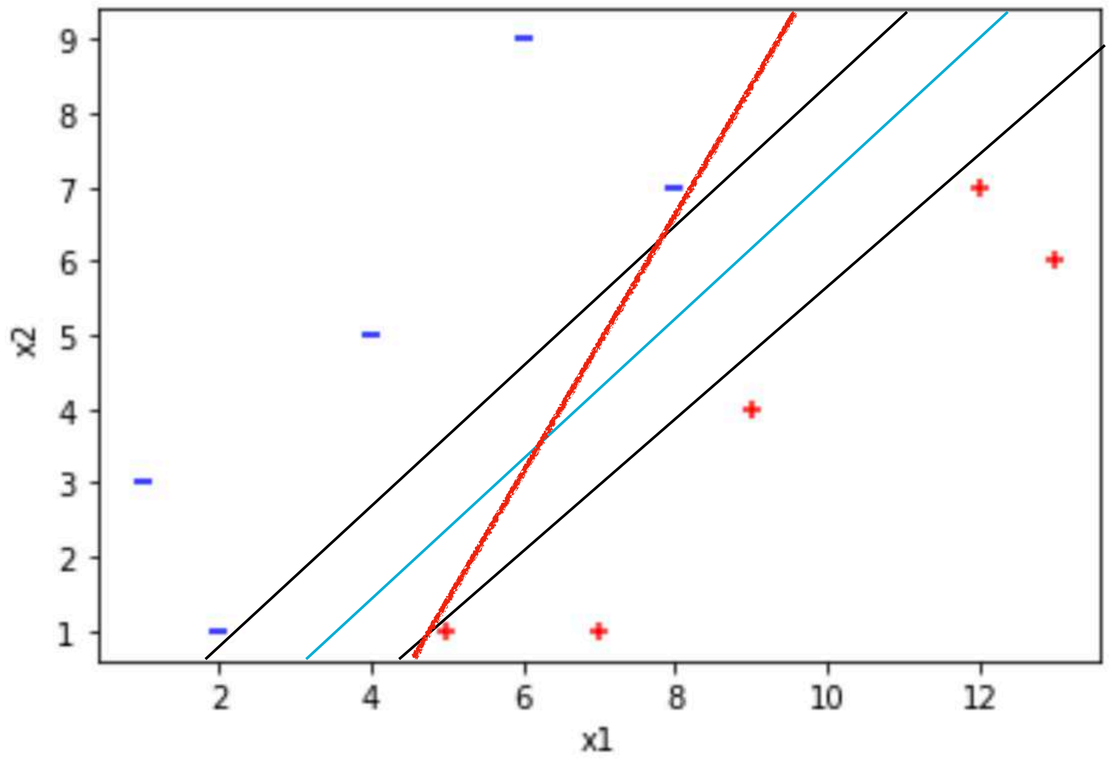

Introduction : discrimination linéaire

- Ces 4 modèles qui offrent le même score de classification.
- Il en existe une infinité d'autres possibles.
- Ce qui les différencie, c'est leur **capacité à généraliser** : si le nombre d'observations augmente, intuitivement le modèle bleu devrait produire moins de faux négatifs ou positifs.
- Ce qui les différencie est leur **marge**.

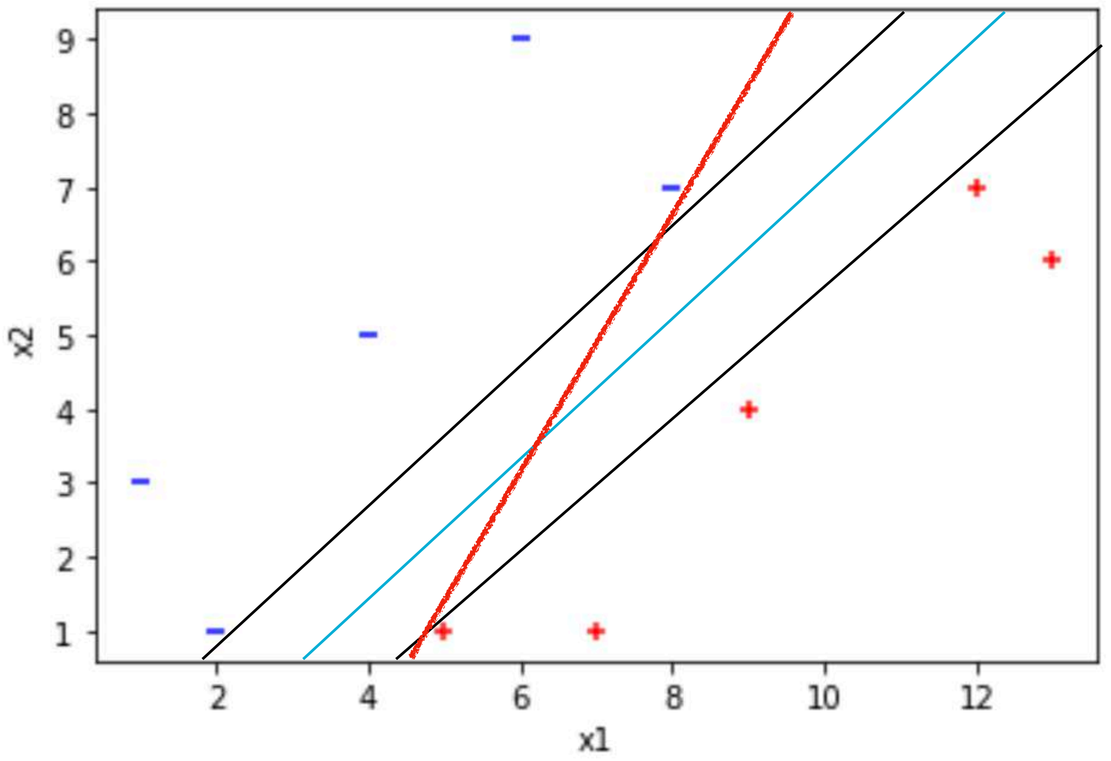

引言：线性判别

- 这4个模型的分类得分相同。
- 还有无数其他可能性。
- 它们之间的区别在于**泛化能力**：当观测数据量增加时，从直觉上说蓝色模型产生的假阴性或假阳性结果应该会减少。
- 它们的区别在于它们的**利润率**。

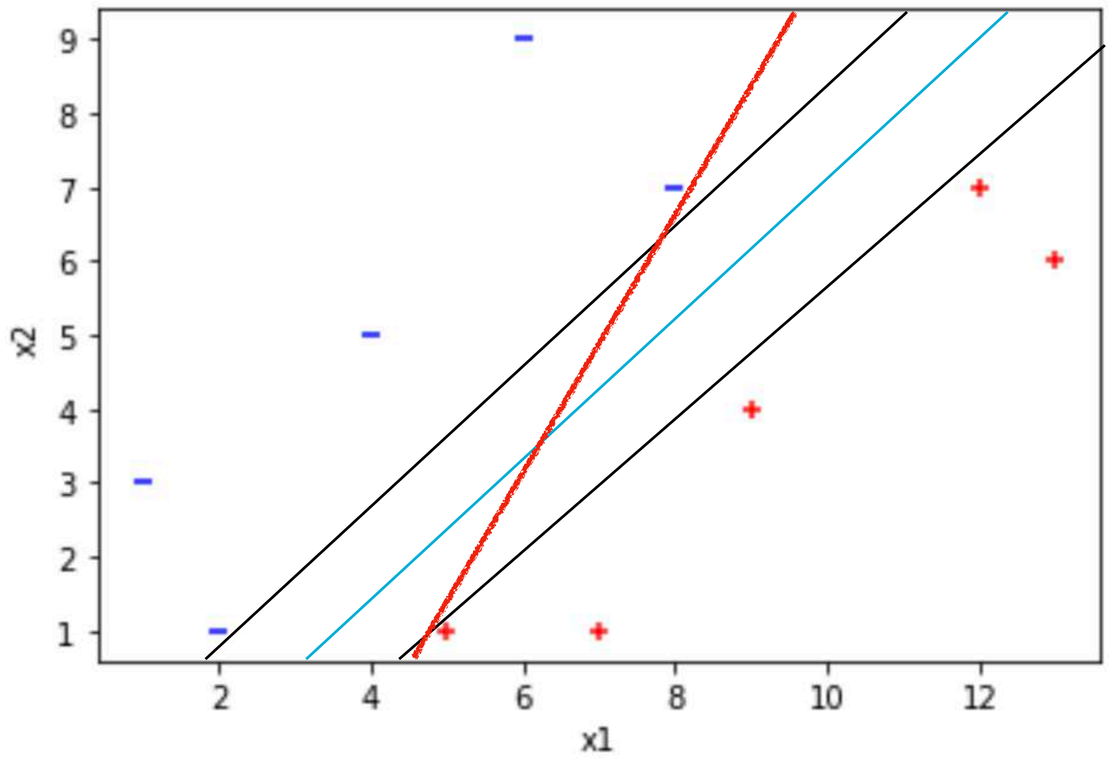

Introduction à la notion de marge

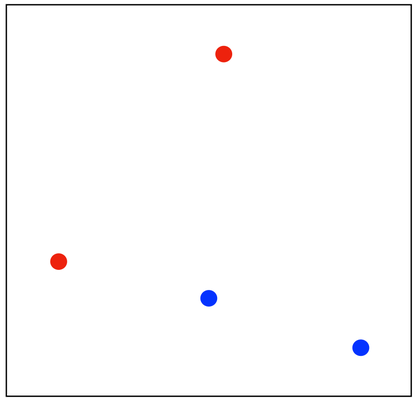

- Considérons différents séparateurs

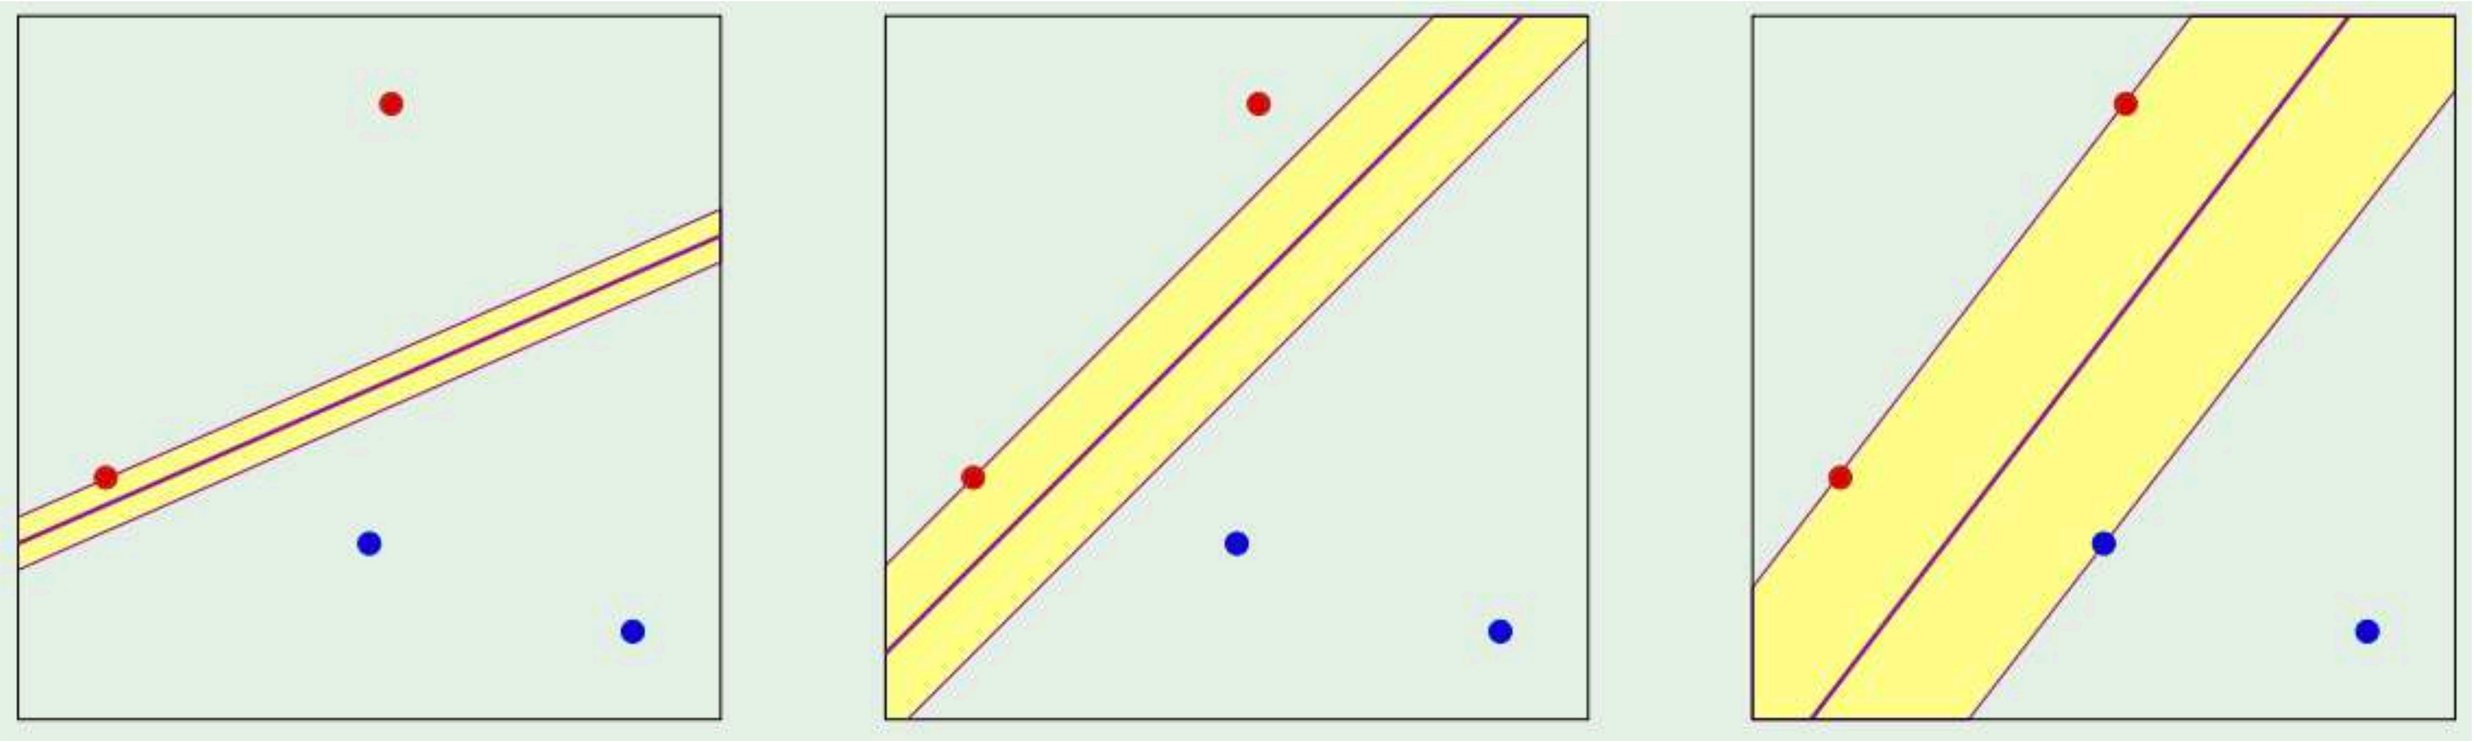

Source : [Abu-Mostafa,2012]

边际概念导论

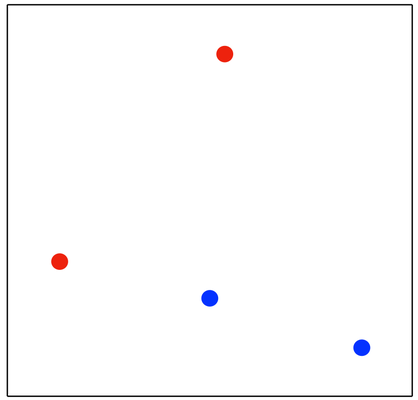

- 考虑不同的分隔符

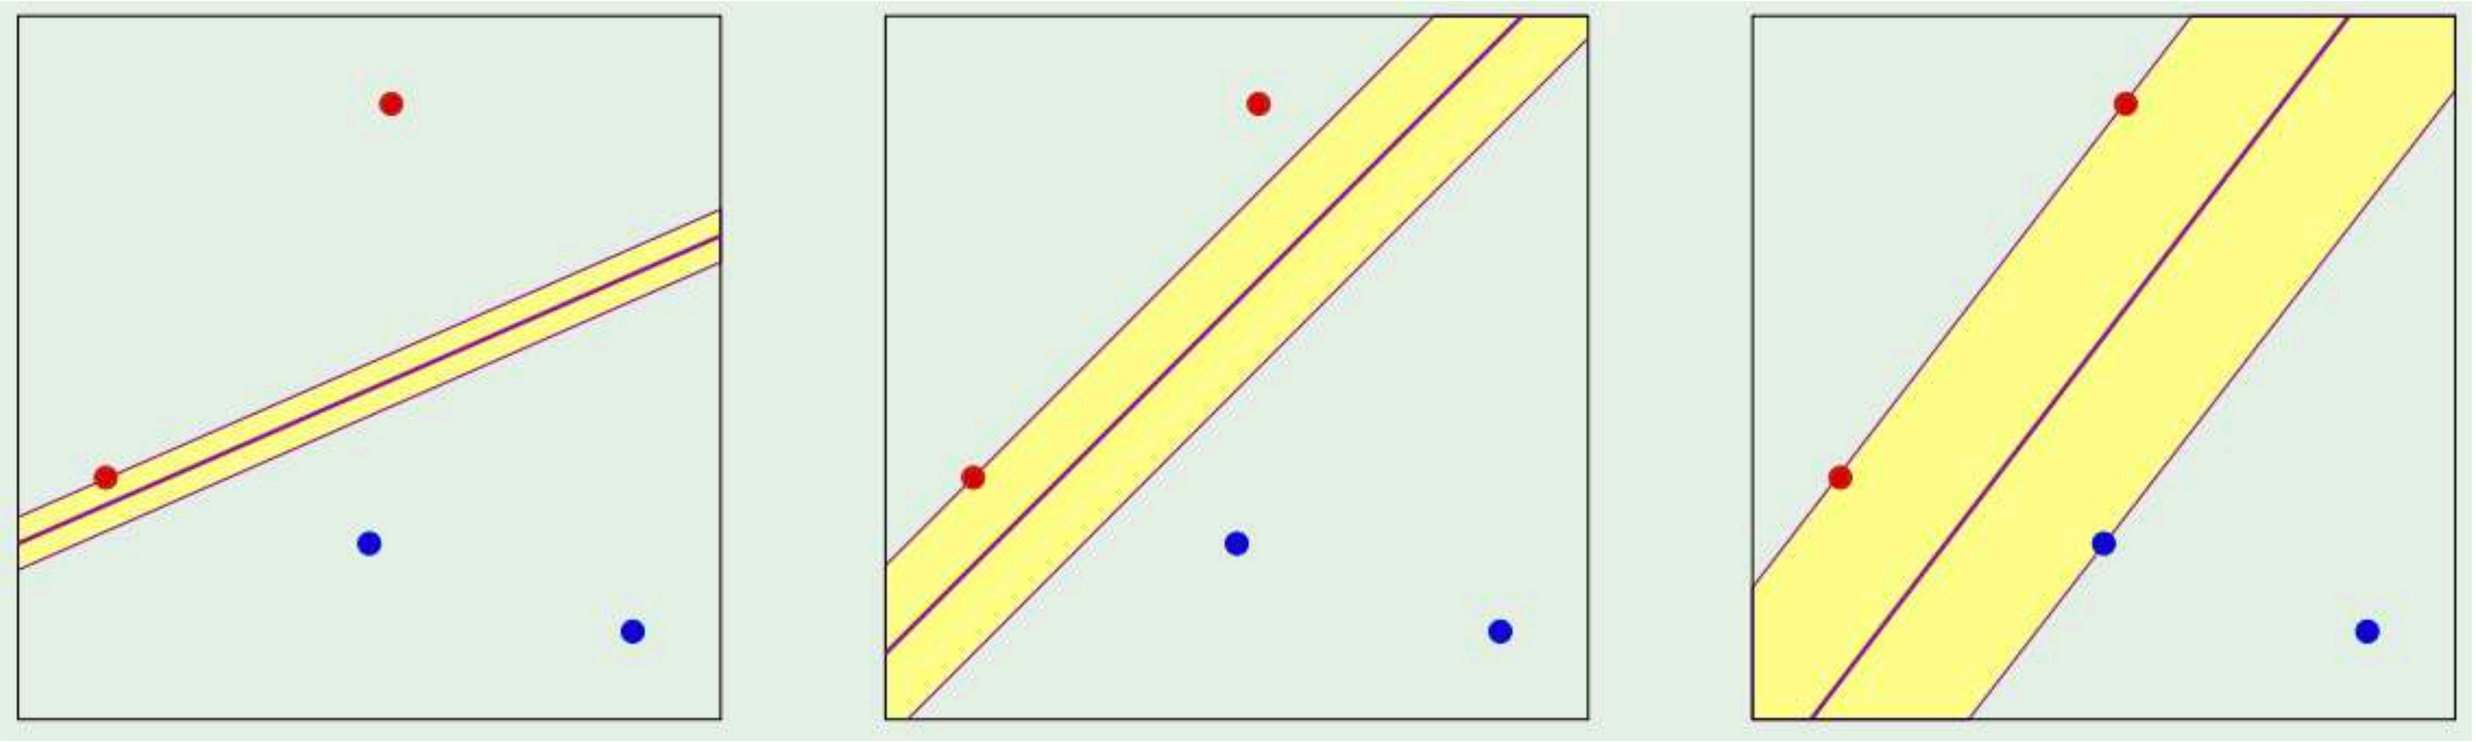

来源：[阿布-穆斯塔法，2012]

Introduction à la notion de marge

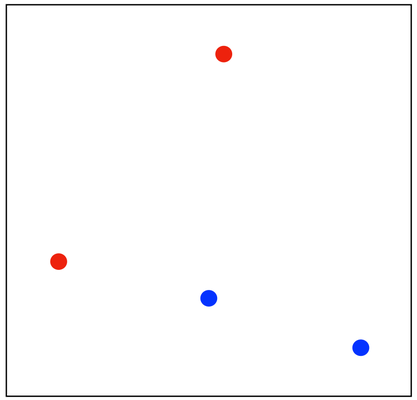

- Considérons différents séparateurs

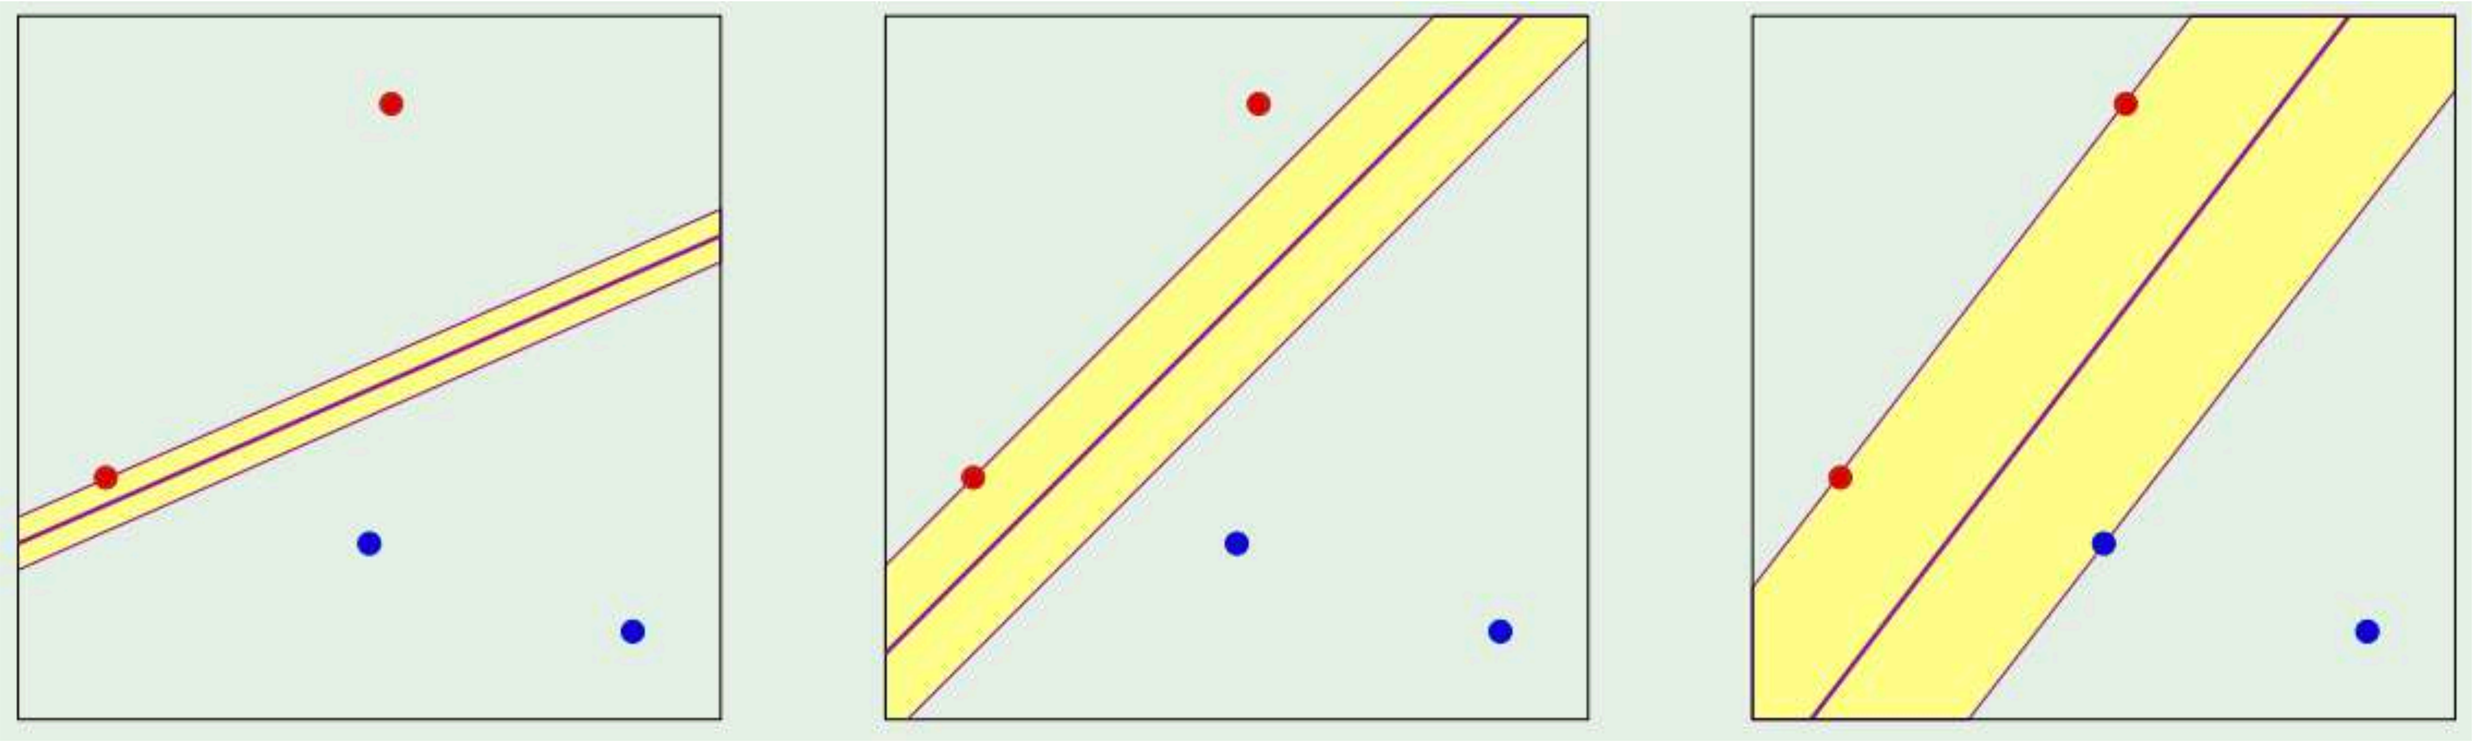

- La droite (ou plus généralement l'Hyperplan) optimal doit **maximiser la distance** entre la frontière de séparation et les points de chaque classe qui lui sont le plus proche [HTF, page 132]

Source : [Abu-Mostafa,2012]

边际概念导论

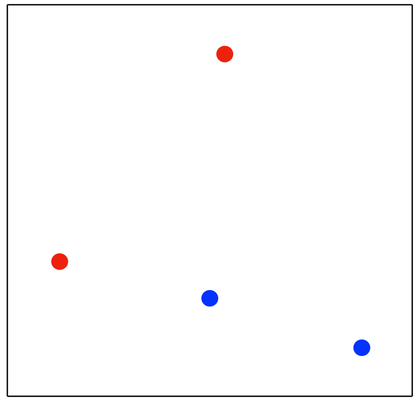

- 考虑不同的分隔符

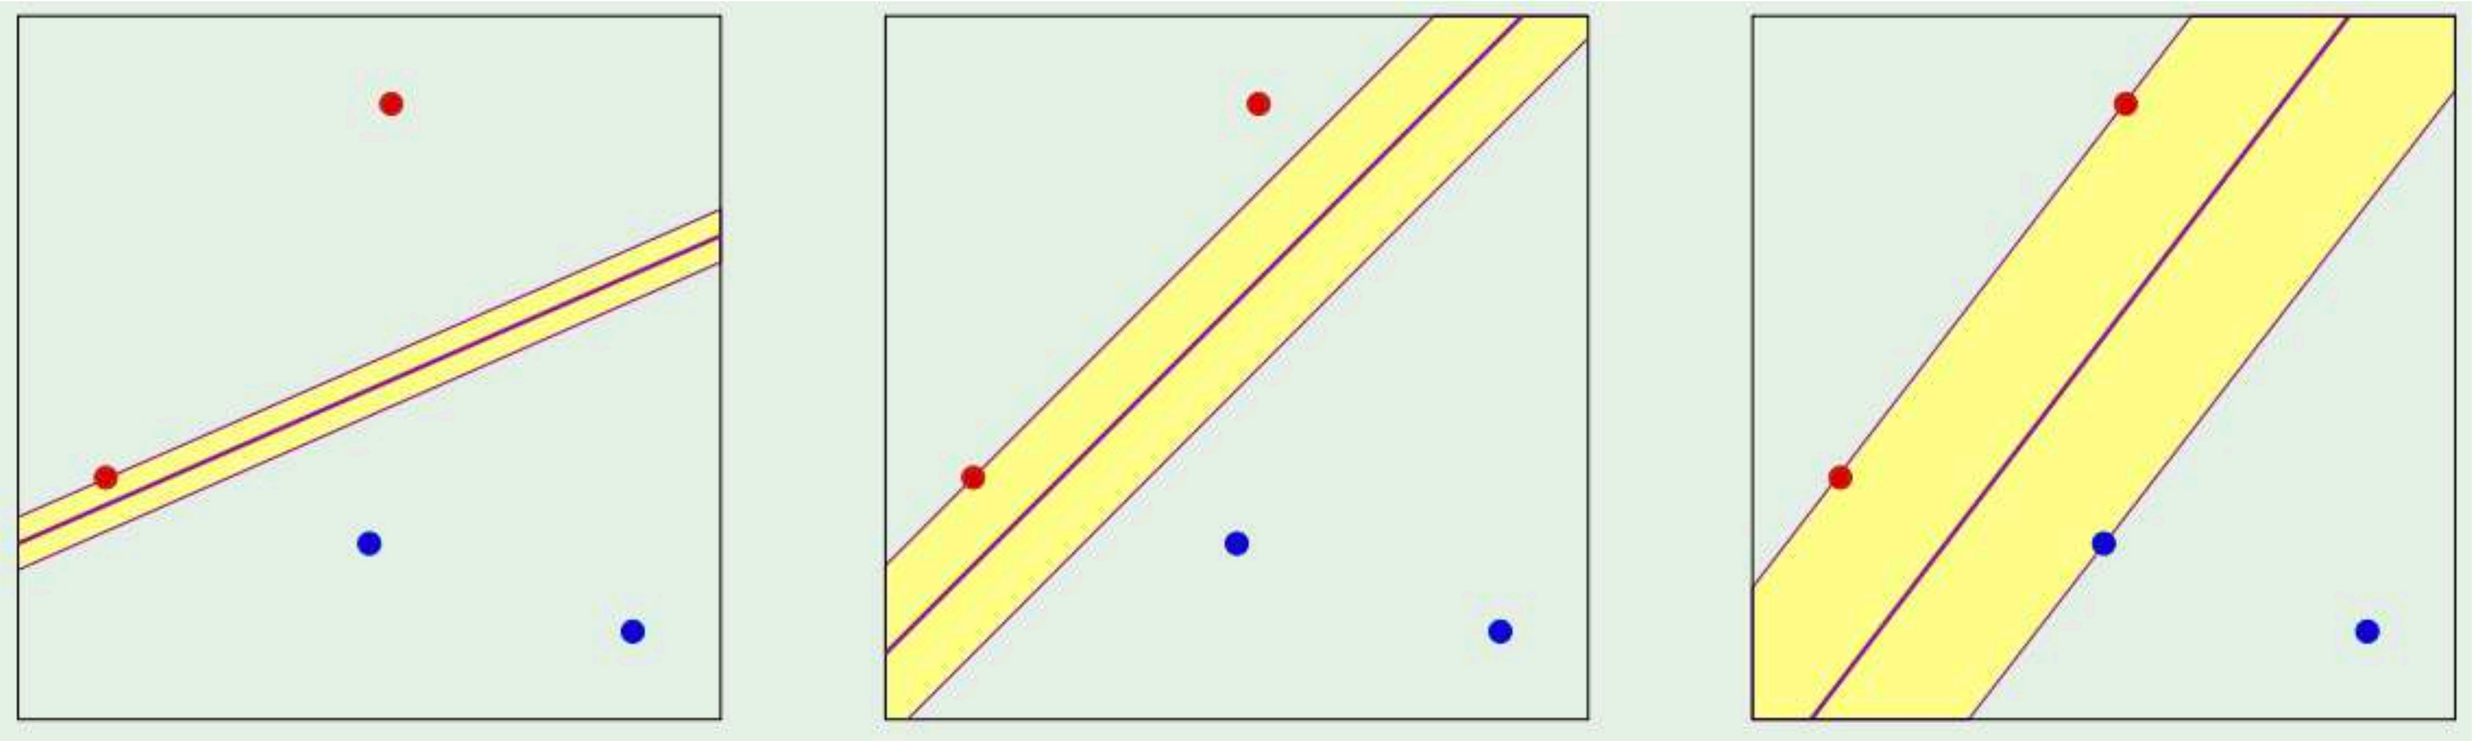

- 最优的直线（或更广义的超平面）应**最大化**直线与目标点之间的距离分界线及其最接近的各类别点[HTF，第132页]

来源：[阿布-穆斯塔法，2012]

Maximisation de la marge

- Les points où «s'appuient» les droites «marges» sont les **«vecteurs de support»**.
  Si on les retire de l'échantillon, la solution est modifiée.

- Plusieurs zones sont définies dans l'espace de représentation
  - f(x) = 0, on est sur la frontière
  - f(x) > 0, on classe «+»
  - f(x) < 0, on classe «-»
  - f(x) = +1 ou -1, on est sur les droites délimitant des vecteurs de support

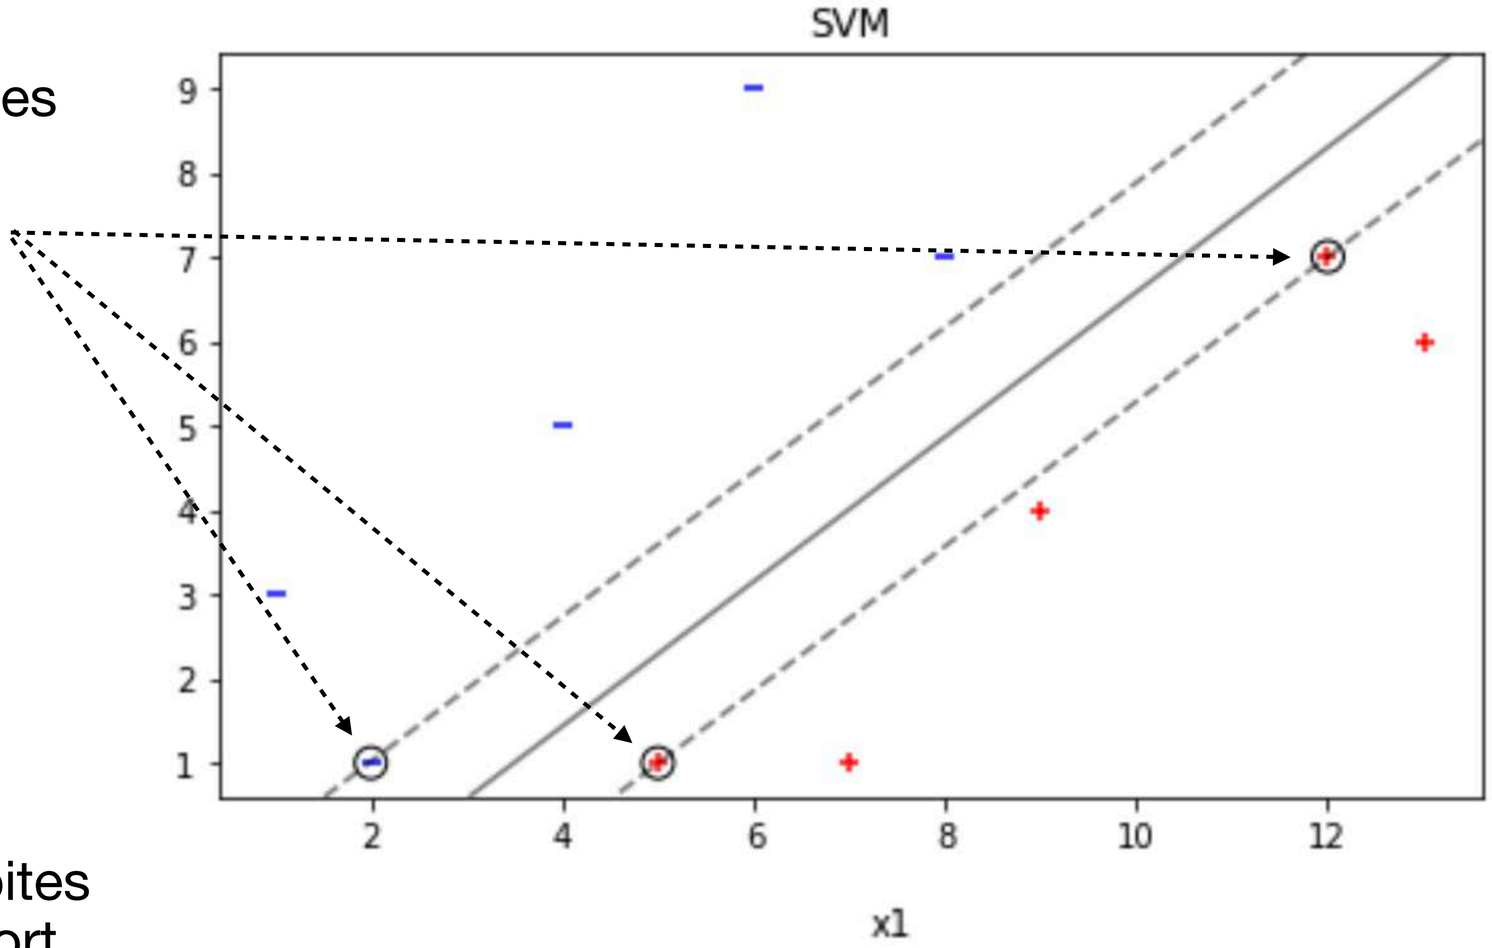

Source : [Rakotomalala]

利润最大化

- “边缘”直线所“支撑”的点即为**“支撑向量”**。
  若将它们从样本中移除，溶液的性质会发生改变。
- 在表示空间中定义了多个区域
  - 当f(x) = 0时，我们处于边界上
  - f(x) > 0，属于“+”类
  - f(x) < 0，类别为“-”
  - 当f(x)等于+1或-1时，我们位于界定支撑向量的直线之上

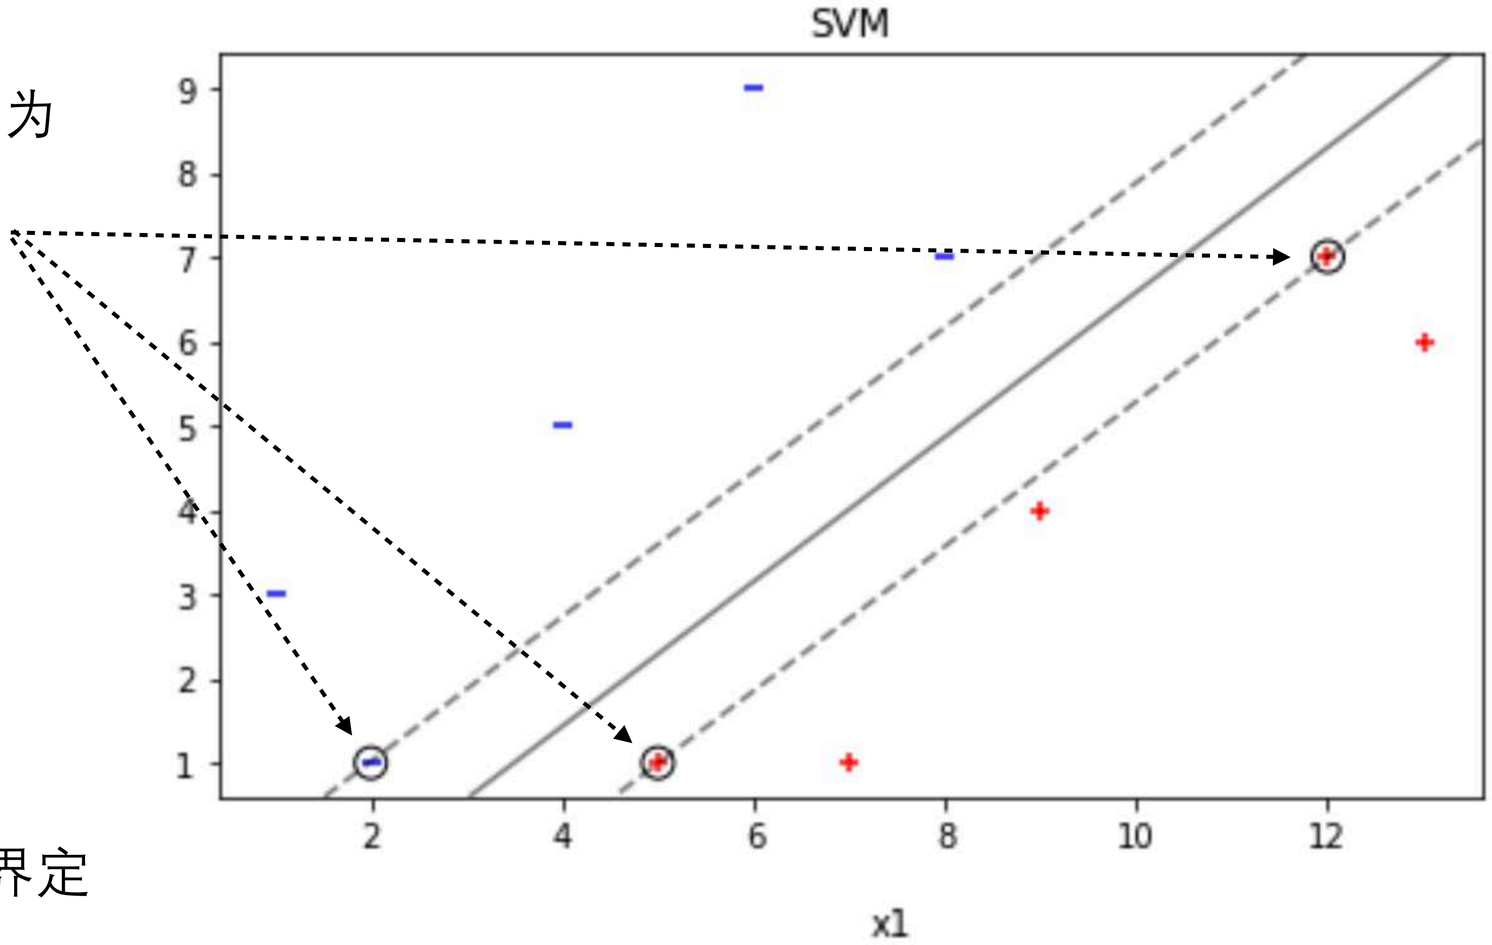

来源：[Rakotomalala]

Classification non-linéaire

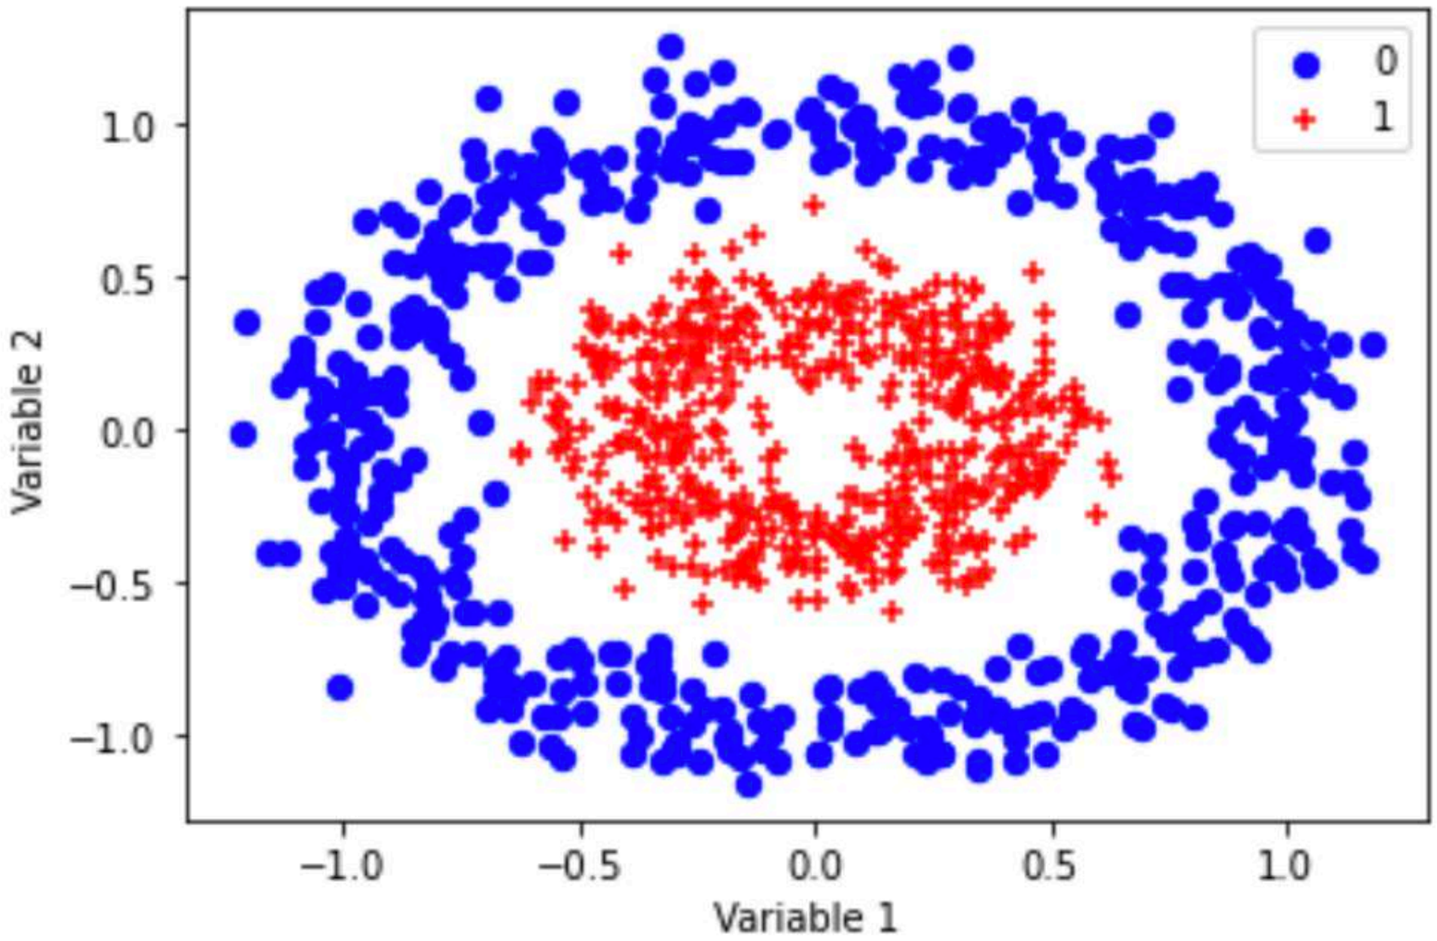

Source : [Biernart&Lutz, 2015]

非线性分类

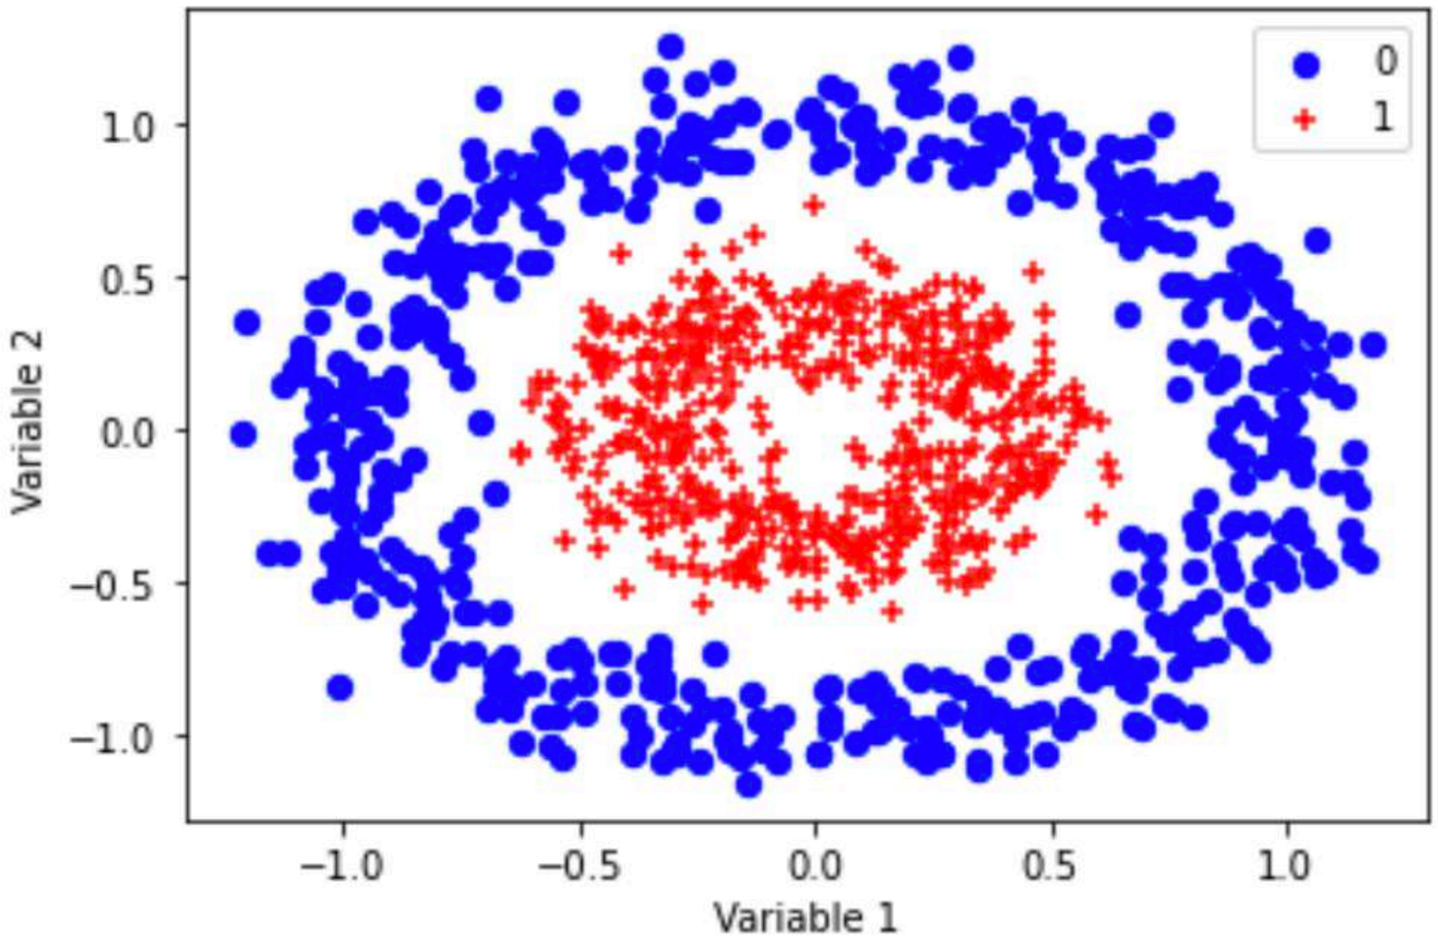

来源：[Biernart&Lutz，2015]

Kernel trick

- Le kernel trick permet de passer dans **un espace de dimension supérieur**, mais **sans avoir à transformer explicitement nos observations** dans cet espace de redescription (trop coûteux) par des observations mathématiques …

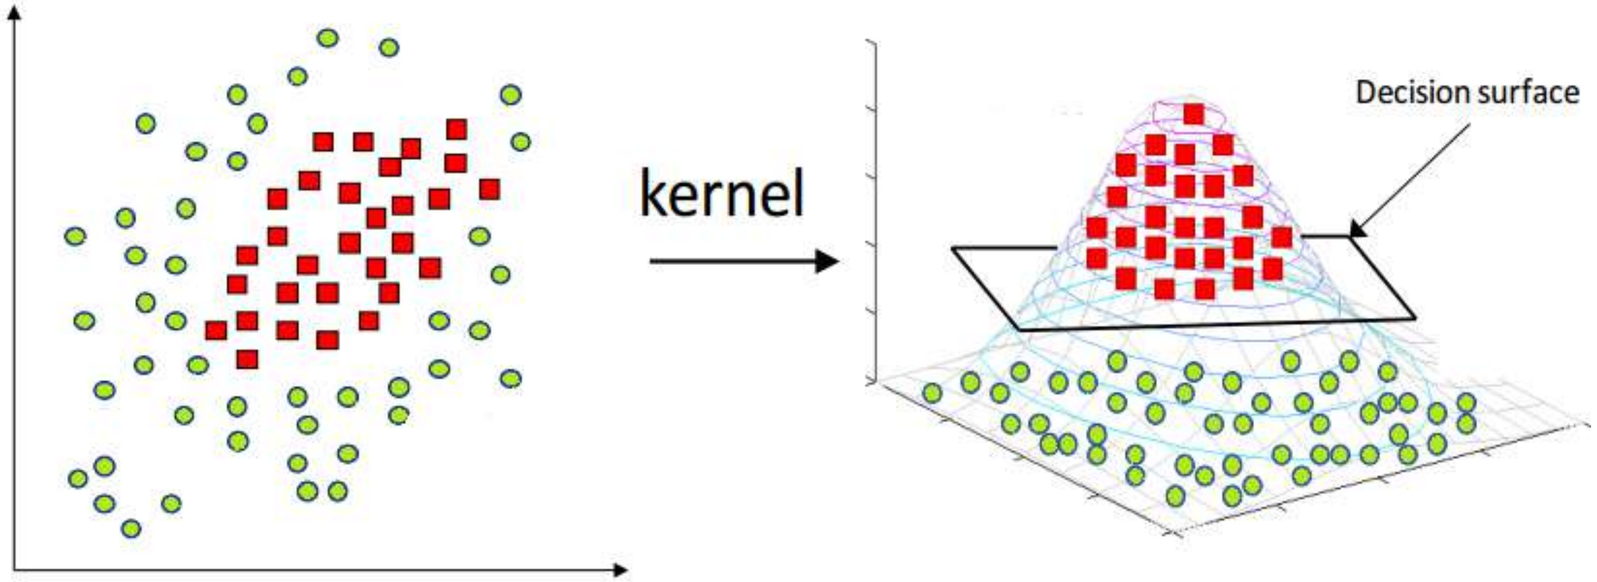

https://medium.com/@zxr.nju/what-is-the-kernel-trick-why-is-it-important-98a98db0961d

内核陷阱

- 核技巧能够将数据转换到**更高维度的空间**，但**无需将观测数据显式转换**到该重描述空间（转换成本过高）中的数学观测值……

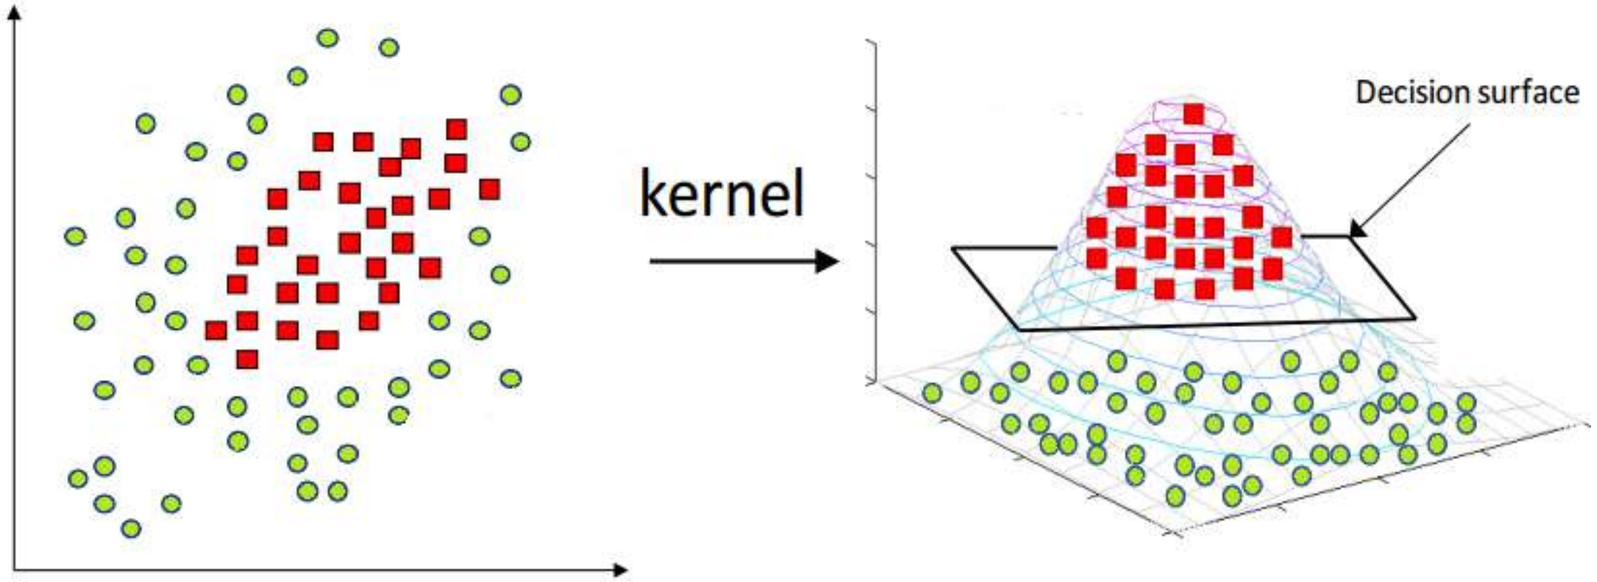

https://medium.com/@zxr.nju/what-is-the-kernel-trick-why-is-it-important-98a98db0961d

Kernel trick : fonctions noyau usuelles

- Il existe différentes formes de kernel, les plus populaires étant :
  - le kernel polynomial :

$$K(x, x') = (1 + x^T x')^q$$

  - le kernel RBF (pour Radial Basis Function) ou Kernel Gaussien

$$K(x, x') = e^{-\gamma x - x'^2}$$

  - le kernel sigmoid

$$K(x, x') = \tanh(kxx' - \delta)$$

Source : [Biernart&Lutz, 2015]

内核技巧：常用内核函数

- 内核有多种类型，其中最常见的是：
  - 核多项式

$$K(x, x') = (1 + x^T x')^q$$

  - 径向基函数（RBF）核或高斯核

$$K(x, x') = e^{-\gamma \|x - x'\|^2}$$

  - S型核

$$K(x, x') = \tanh(kxx' - \boldsymbol{\delta})$$

来源：[Biernart&Lutz，2015]

SVM: Avantages et inconvénients

Avantages

- Efficace dans les espaces de haute dimension
- Robustesse face au sur-apprentissage
- Flexibilité avec les fonctions de noyau
- Solution unique et optimale

Inconvénients

- Choix du noyau et des paramètres
- Complexité computationnelle
- Moins efficace sur de très grands ensembles de données
- Interprétabilité pour les kernels non linéaires
- Sensibilité aux paramètres
- Classification multiclasse

SVM：优势与劣势

优势

- 在高维空间中具有高效性
- 过学习鲁棒性
- 内核函数的灵活性
- 独特且最优的解决方案

缺点

- 内核与参数选择
- 计算复杂度
- 在超大规模数据集上效率较低
- 非线性核函数的可解释性
- 参数敏感性
- 多分类器分类

Decision Tree

决策树

Exemple de Classification - Apprentissage supervisé

- Le but général d'un arbre de décision est **d'expliquer une valeur à partir d'une série de variables discrètes ou continues**.

- On est donc dans un cas très classique de matrice X avec m observations et n variables, associée à un vecteur Y à expliquer. Les valeurs de Y peuvent être de deux sortes :
  - continues : on parle alors **d'arbre de régression**
  - qualitatives : on parlera **d'arbre de classification**

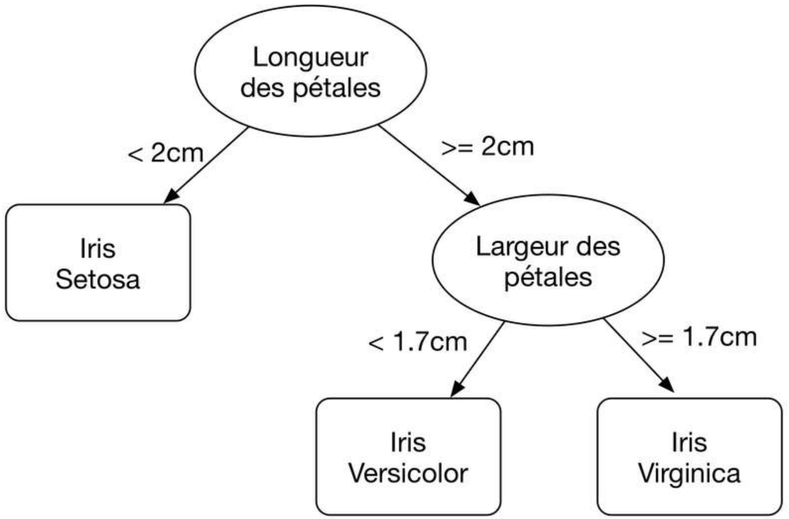

Source : [Biernart&Lutz, 2015]

分类示例 - 监督学习

- 决策树的总体目标是**通过一系列离散或连续变量来解释一个数值。**

- 因此，我们面临一个非常典型的X矩阵案例：包含m个观测值和n个变量，并需要解释一个对应的Y向量。Y的取值可能有两种类型：
  - 继续：此时人们便开始讨论**回归树**
  - 定性分析：我们将讨论**分类树**

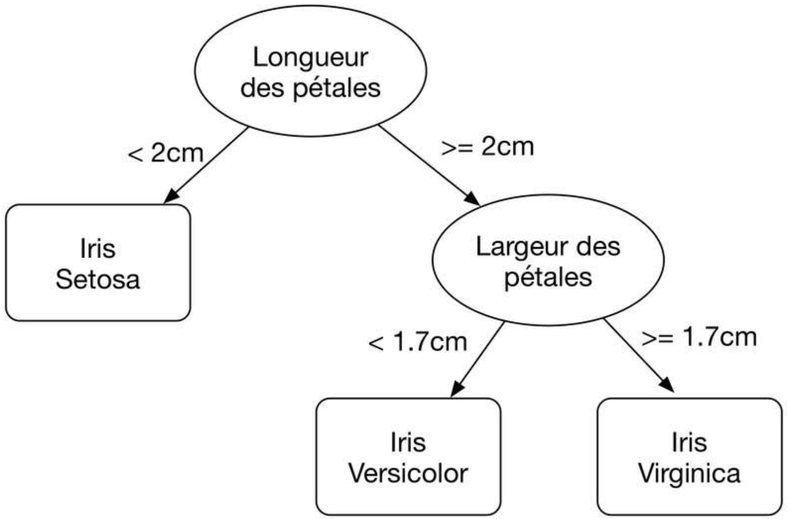

来源：[Biernart&Lutz，2015]

Exemple de Classification - Apprentissage supervisé

- Le dataset d'exemple est **iris**.

	Longueur des sépales	Largeur des sépales	Longueur des pétales	Largeur des pétales	Cible
0	5.1	3.5	1.4	0.2	Iris-setosa
1	7.0	3.2	4.7	1.4	Iris-versicolor
2	6.3	3.3	6.0	2.5	Iris-virginica
3	…	…	…	…	…

Attribut cible : classes que l'on cherche à prédire.

Nouvelle plante

8.0	6.4	1.2	2.3

Quelle est sa classe ?

Dataset Iris (4 attributs, 150 instances)
https://archive.ics.uci.edu/ml/datasets/Iris

Source : Julien Aligon

分类示例 - 监督学习

- 示例数据集为**iris**。

	萼片长度	萼片宽度	花瓣长度	花瓣宽度	靶标
0	5.1	3.5	1.4	0.2	虹膜毛
1	7.0	3.2	4.7	1.4	虹膜花斑症
2	6.3	3.3	6.0	2.5	鸢尾属
3	…	…	…	…	…

目标属性：需要预测的类别。

新植物	8.0	6.4	1.2	2.3	它的等级是什么?

Iris数据集（4个属性，150个实例）
https://archive.ics.uci.edu/ml/datasets/Iris

来源：Julien Aligon

Arbre de décision

- Le dataset d'exemple est **iris**.

	Longueur des sépales	Largeur des sépales	Longueur des pétales	Largeur des pétales	Cible
0	5.1	3.5	1.4	0.2	Iris-setosa
1	7.0	3.2	4.7	1.4	Iris-versicolor
2	6.3	3.3	6.0	2.5	Iris-virginica
3	…	…	…	…	…

Nouvelle plante

8.0	6.4	1.2	2.3

Quelle est sa classe ?

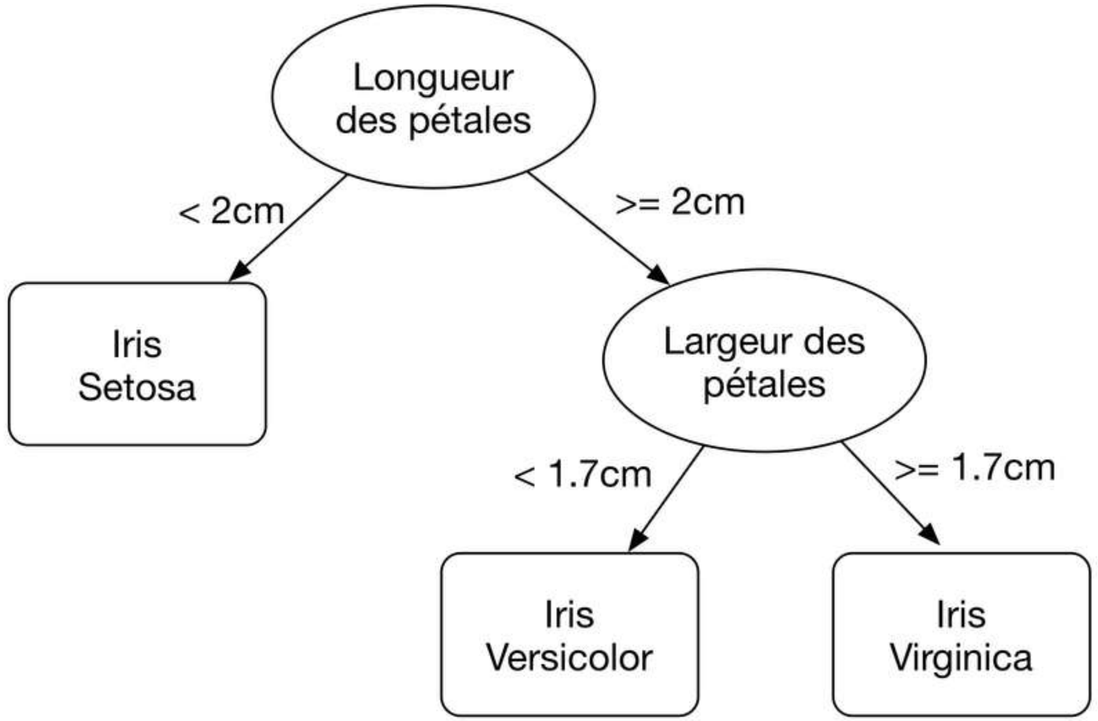

Exemple d'arbre de décision

Source : Julien Aligon

决策树

- 示例数据集为鸢尾花数据集。

	萼片长度	萼片宽度	花瓣长度	花瓣宽度	靶标
0	5.1	3.5	1.4	0.2	虹膜毛
1	7.0	3.2	4.7	1.4	虹膜花斑症
2	6.3	3.3	6.0	2.5	鸢尾属
3	…	…	…	…	…

新植物

8.0	6.4	1.2	2.3

它的等级是什么?

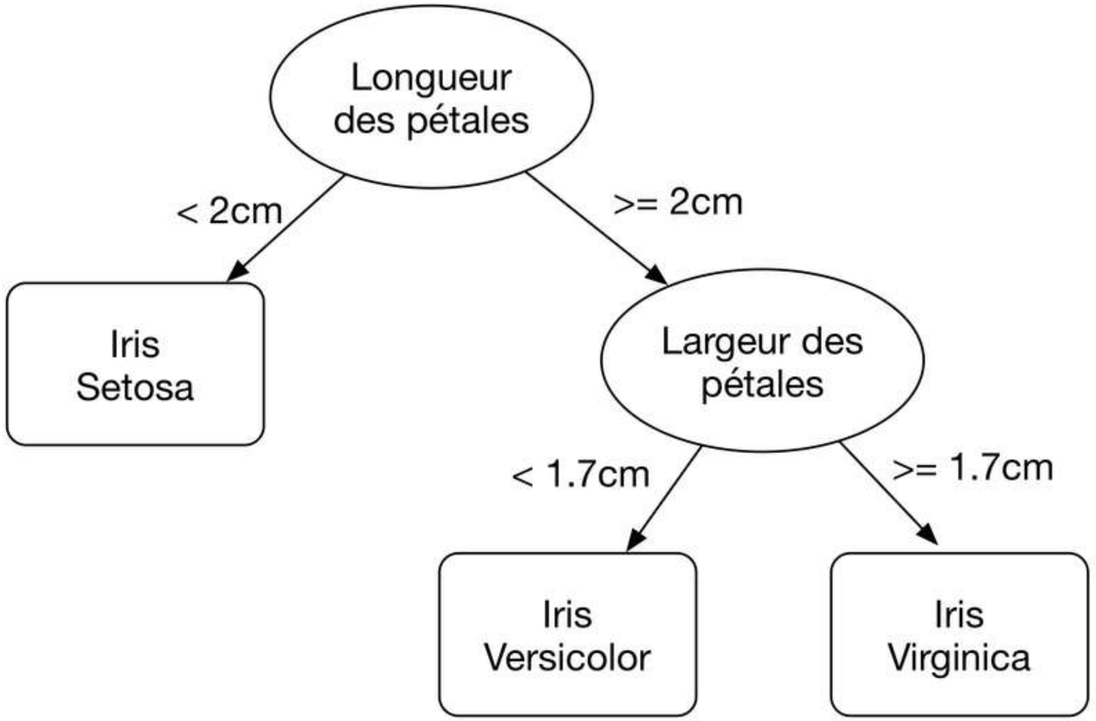

决策树示例

来源：Julien Aligon

Construction d'un arbre : apprentissage par partitionnement

- **Objectif :** on veut construire des sous-groupes les plus « homogènes » du point de vue de la variable à prédire

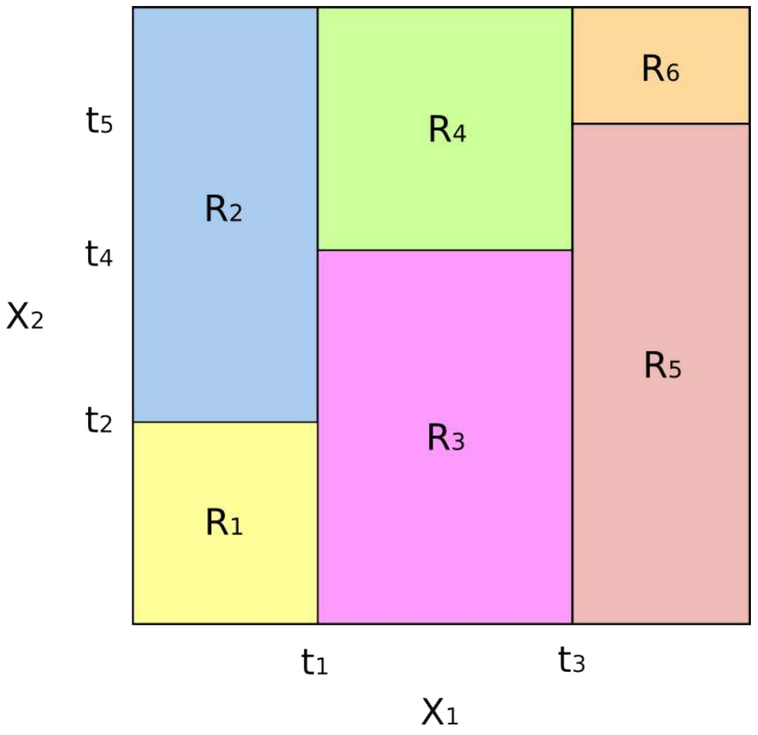

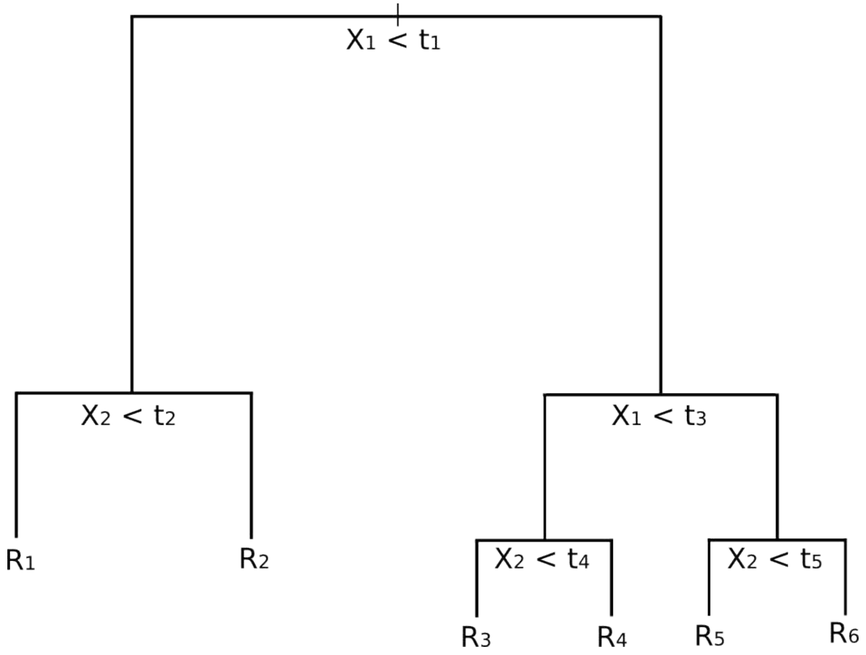

- Le sous-groupe Ri est complètement pur : il ne contient que des éléments +.
- L'idée est de trouver le plus rapidement possible (avec le moins de variables) des groupes où P(Y=+) = 1 ou proche.

Source : Julien Aligon

树结构构建：基于分区学习的方法

- 目标：旨在构建在预测变量维度上最具同质性的子群体

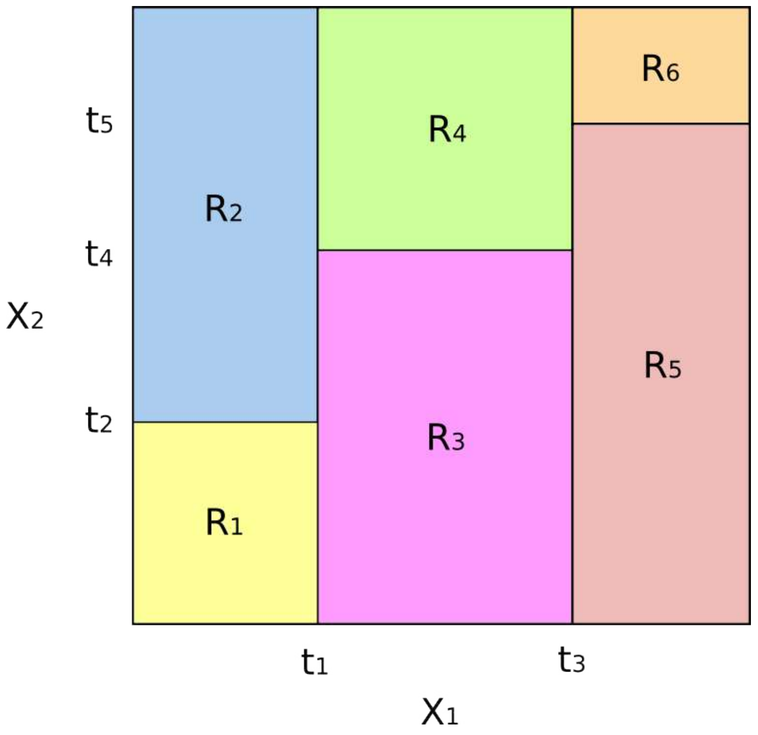

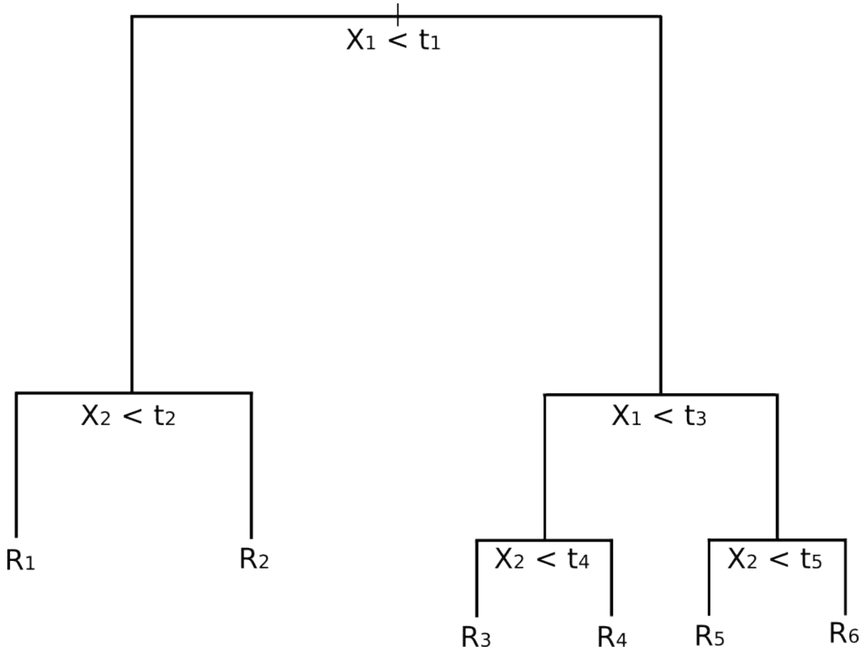

- 子组Ri是完全纯化的，仅包含+元素。
- 核心目标是以最少变量量最快找到P(Y=+)等于1或接近1的群体。

来源：Julien Aligon

Construction d’un arbre : principales questions

- **Comment choisir la variable de division ?**
  On doit en effet pouvoir définir l’arborescence de l’arbre en sélectionnant les variables, de la plus discriminante à la moins discriminante.

- **Comment traiter les variables continues ?**
  Pour définir des noeuds à partir d’une variable continue, l’on doit savoir "couper" la variable continue, pour que ses valeurs inférieures et supérieures à cette coupe puissent caractériser des noeuds distincts.

- **Comment définir la taille de l’arbre ?**
  L’objectif est de situer le niveau de noeuds optimal, pour trouver le juste équilibre entre sur-apprentissage et arbre trivial. Processus de post-élagage.

- Réponse fonction de l’algorithme CHAID (Chi-2), CART et C4.5 sur l’index (on parle aussi de critère de split), de Gini (indice de concentration) et sur la notion d’entropie (théorie de l’information).

Source : [Biernart&Lutz, 2015]

树形结构构建：主要问题

- **如何选择分割变量?**

  实际上，我们应当能够通过选择变量（从最具区分度到最不具区分度）来定义树的树状结构。

- **如何处理连续变量?**

  要从连续变量中定义节点，必须掌握对连续变量进行“截断”的方法，这样才能让截断值上下限所对应的数值分别对应不同的节点特征。

- **如何确定树的规模?**

  目标在于确定最优节点层级，以在过学习与平凡树结构之间找到恰当平衡点。该过程属于后剪枝算法范畴。

- CHAID（卡方检验）、CART和C4.5算法对指标（亦称分割准则）、基尼系数（集中度指标）及熵（信息论）概念的响应函数分析。

来源：[Biernart&Lutz，2015]

Construction avec l'indice Gini

Revision time	Break time	Success
High	Low	No
High	Medium	Yes
Medium	Low	No
Medium	High	Yes
Low	Low	No
Low	High	Yes
High	High	Yes
Medium	Medium	Yes
Low	Medium	No
High	Low	No

1. Calcul de l'indice Gini sur l'ensemble complet:

$$Gini(D) = 1 - \sum_{i=1}^{K} P_i^2$$

$P_i = \frac{Nb_{classe_i}}{Nb_{lignes}}$: probabilité d'avoir la classe i

L'indice Gini mesure donc l'impureté/l'incertitude dans un ensemble de données:

- Si il est nul, l'ensemble est pur (une seule classe)

- Plus il est élevé, plus l'ensemble est diversifié en classes

基尼系数法构建

翻修时间	休息时间	成功
高	低	不
高	中等	是
中等	低	不
中等	高	是
低	低	不
低	高	是
高	高	是
中等	中等	是
低	中等	不
高	低	不

1. 全数据集基尼系数的计算：

$$基尼系数(D) = 1 - \sum_{i=1}^{K} P_i^2$$

$P_i = \frac{Nb_{classe_i}}{Nb_{行}}$：具有类别 i 的概率

基尼系数因此用于衡量数据集中的不纯度/不确定性程度：

- 若该集合为空，则该集合为纯集合（即仅含单一类别）
- 数值越高，整体在类别上的多样性就越大

Construction avec l'indice Gini

Revision time	Break time	Success
High	Low	No
High	Medium	Yes
Medium	Low	No
Medium	High	Yes
Low	Low	No
Low	High	Yes
High	High	Yes
Medium	Medium	Yes
Low	Medium	No
High	Low	No

1. Calcul de l'indice Gini sur l'ensemble complet:

$$P_{oui} = ???$$

$$P_{non} = ???$$

$$Gini(D) = 1 - \frac{5}{10}^{2} - \frac{5}{10}^{2} = 0.5$$

基尼系数法构建

翻修时间	休息时间	成功
高	低	不
高	中等	是
中等	低	不
中等	高	是
低	低	不
低	高	是
高	高	是
中等	中等	是
低	中等	不
高	低	不

1. 全数据集基尼系数的计算：

$P_{是}$ = ？？？

$P_{不}$ ？？？

$$(D) = 1 - \left(\frac{5}{10}\right)^2 - \left(\frac{5}{10}\right)^2 = 0.5$$ 吉尼系数

Construction avec l'indice Gini

Revision time	Break time	Success
High	Low	No
High	Medium	Yes
Medium	Low	No
Medium	High	Yes
Low	Low	No
Low	High	Yes
High	High	Yes
Medium	Medium	Yes
Low	Medium	No
High	Low	No

2. Sélection de l'attribut pour la première division:

1. Evaluation de l'indice Gini pondéré pour chaque attribut:

$$Gini_{pondere} = \sum_{j=1}^{k} \frac{N_j}{N} Gini(j)$$

avec
k : le nombre de noeuds enfants résultant du split
N_j : le nombre d'échantillons dans le noeud enfant j
N : le nombre total d'échantillons dans le noeud parent
$Gini(j)$: l'indice Gini du noeud enfant j

2. Sélection de l'attribut avec l'indice le plus faible

基尼系数法构建

翻修时间	休息时间	成功
高	低	不
高	中等	是
中等	低	不
中等	高	是
低	低	不
低	高	是
高	高	是
中等	中等	是
低	中等	不
高	低	不

2. 第一部分属性选择：

1.加权基尼指数的评估属性：

$$吉尼系数 = \sum_{j=1}^{k} \frac{N_j}{N} 吉尼系数(j)$$

伴

k：分裂产生的子节点数量N_j：子节点中的样本数量j N：父节点中的总样本数量$Gini(j)$：子节点的基尼系数j

2.选择索引值最小的属性

Construction avec l'indice Gini

Revision time	Break time	Success
High	Low	No
High	Medium	Yes
Medium	Low	No
Medium	High	Yes
Low	Low	No
Low	High	Yes
High	High	Yes
Medium	Medium	Yes
Low	Medium	No
High	Low	No

2. Sélection de l'attribut pour la première division

Pour l'attribut « **Revision time** »

High (4 éléments) : $Gini_{High} = 1 - \frac{2}{4}^2 - \frac{2}{4}^2 = 0.5$

Medium (3 éléments) : $Gini_{Medium} = 1 - \frac{2}{3}^2 - \frac{1}{3}^2 = 0.444$

Low (3 éléments) : $Gini_{Low} = 1 - \frac{1}{3}^2 - \frac{2}{3}^2 = 0.444$

$$Gini_{pondere}(RevisionTime) = \frac{4}{10} \times 0.5 + \frac{3}{10} \times 0.444 + \frac{3}{10} \times 0.444$$
$$= 0.4664$$

基尼系数法构建

翻修时间	休息时间	成功
高	低	不
高	中等	是
中等	低	不
中等	高	是
低	低	不
低	高	是
高	高	是
中等	中等	是
低	中等	不
高	低	不

2. 第一部分属性选择：关于“修订时间”属性

高（4个元素）： $Gini_{High} = 1 - \left(\frac{2}{4}\right)^2 - \left(\frac{2}{4}\right)^2 = 0.5$

中等（3个元素）： $Gini_{Medium} = 1 - \left(\frac{2}{3}\right)^2 - \left(\frac{1}{3}\right)^2 = 0.444$

低（3个元素）： $Gini_{Low} = 1 - \left(\frac{1}{3}\right)^2 - \left(\frac{2}{3}\right)^2 = 0.444$

$$Gini_{pondere}\ (\text{修订时间}) = \frac{4}{10} \times 0.5 + \frac{3}{10} \times 0.444 + \frac{3}{10} \times 0.444$$
$$= 0.4664$$

Construction avec l'indice Gini

Revision time	Break time	Success
High	Low	No
High	Medium	Yes
Medium	Low	No
Medium	High	Yes
Low	Low	No
Low	High	Yes
High	High	Yes
Medium	Medium	Yes
Low	Medium	No
High	Low	No

2. Sélection de l'attribut pour la première division

Pour l'attribut « **Break time** »

High (3 éléments) : $Gini_{High} = 1 - \frac{3}{3}^2 - \frac{0}{3}^2 = 0.0$

Medium (3 éléments) : $Gini_{Medium} = 1 - \frac{2}{3}^2 - \frac{1}{3}^2 = 0.444$

Low (4 éléments) : $Gini_{Low} = 1 - \frac{0}{4}^2 - \frac{4}{4}^2 = 0.0$

$$Gini_{pondere}(BreakTime) = \frac{3}{10} \times 0.0 + \frac{3}{10} \times 0.444 + \frac{4}{10} \times 0.0$$
$$= 0.1332$$

基尼系数法构建

翻修时间	休息时间	成功
高	低	不
高	中等	是
中等	低	不
中等	高	是
低	低	不
低	高	是
高	高	是
中等	中等	是
低	中等	不
高	低	不

2. 第一部分属性选择：关于“休息时间”属性

高（3个元素）： $Gini_{High}=1-\left(\frac{3}{3}\right)^2-\left(\frac{0}{3}\right)^2=0.0$

中等（3个元素）： $Gini_{Medium}=1-\left(\frac{2}{3}\right)^2-\left(\frac{1}{3}\right)^2=0.444$

低（4个元素）： $Gini_{Low}=1-\left(\frac{0}{4}\right)^2-\left(\frac{4}{4}\right)^2=0.0$

$$Gini_{pondere}(BreakTime)=\frac{3}{10}\times 0.0+\frac{3}{10}\times 0.444+\frac{4}{10}\times 0.0$$
$$=0.1332$$

Construction avec l'indice Gini

Revision time	Break time	Success
High	Low	No
High	Medium	Yes
Medium	Low	No
Medium	High	Yes
Low	Low	No
Low	High	Yes
High	High	Yes
Medium	Medium	Yes
Low	Medium	No
High	Low	No

2. Sélection de l'attribut pour la première division

Comparaison des indices Gini:

$$Gini_{pondere}(RevisionTime) = 0.4664$$

$$Gini_{pondere}(BreakTime) = 0.1332$$

On sélectionne l'attribut *BreakTime* qui a l'indice le plus faible.

Pour BreakTime, on choisit **Low** comme valeur de split, car $Gini_{Low}$ a la plus petite valeur (0.0) et le plus grand nombre d'éléments (4).

基尼系数法构建

翻修时间	休息时间	成功
高	低	不
高	中等	是
中等	低	不
中等	高	是
低	低	不
低	高	是
高	高	是
中等	中等	是
低	中等	不
高	低	不

2. 第一部分属性选择：基尼系数比较

$$吉尼_{权重}（修订时间）=0.4664$$

$$基尼_{权重}（BreakTime）=0.1332$$

选择索引值最小的属性*BreakTime*。

在BreakTime算法中，我们选择Low作为分割阈值，因为$Gini_{Low}$具有最小值（0.0）和最大样本量(4)。

Construction avec l'indice Gini

Revision time	Break time	Success
High	Low	No
High	Medium	Yes
Medium	Low	No
Medium	High	Yes
Low	Low	No
Low	High	Yes
High	High	Yes
Medium	Medium	Yes
Low	Medium	No
High	Low	No

2. Sélection de l'attribut pour la première division

Attribution des classes par probabilité de valeur

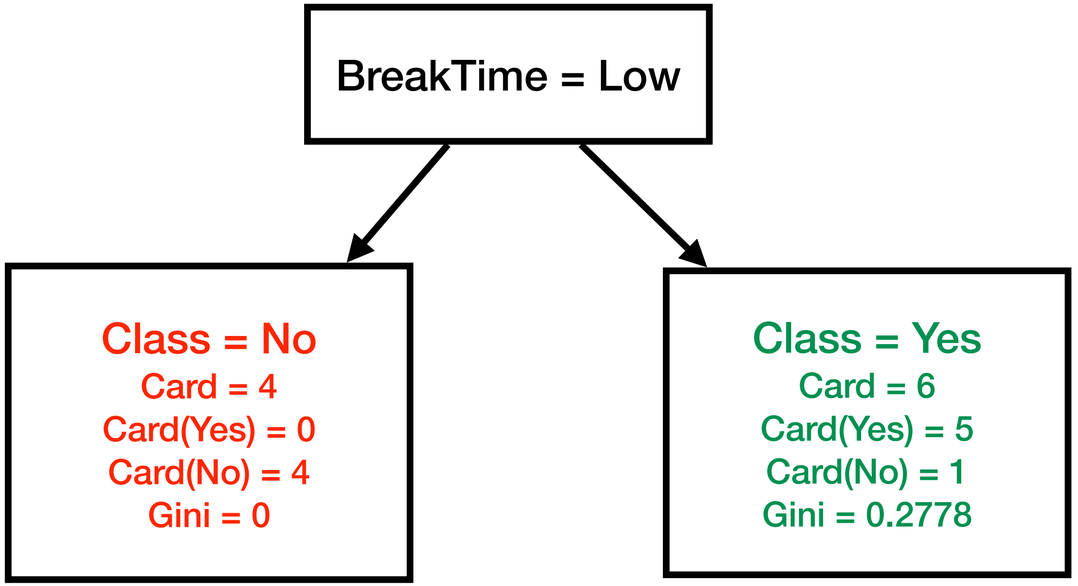

基尼系数法构建

翻修时间	休息时间	成功
高	低	不
高	中等	是
中等	低	不
中等	高	是
低	低	不
低	高	是
高	高	是
中等	中等	是
低	中等	不
高	低	不

2. 第一部分属性选择：基于数值概率的类别归属分析

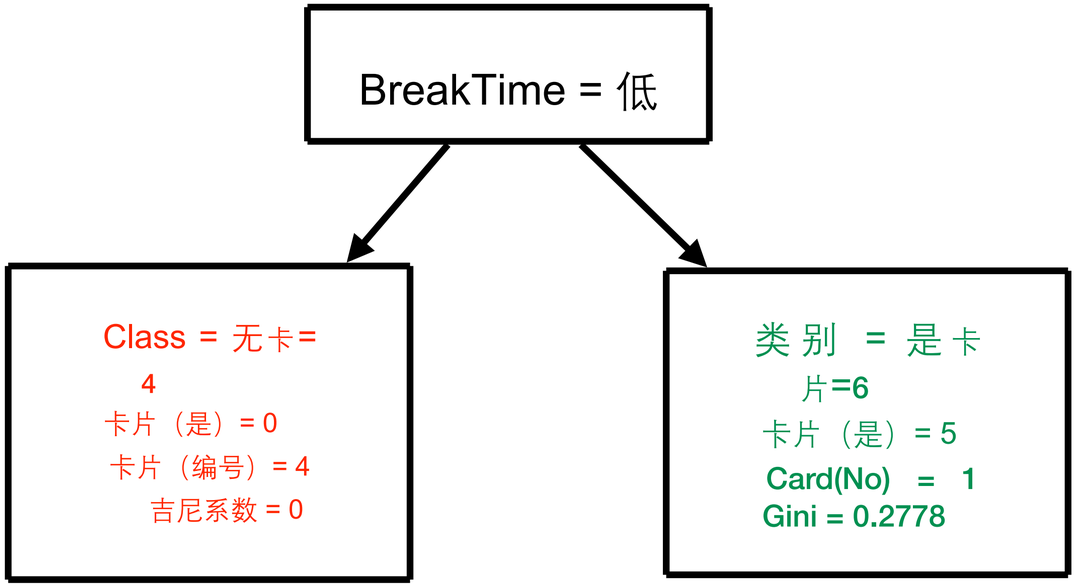

Construction avec l'indice Gini

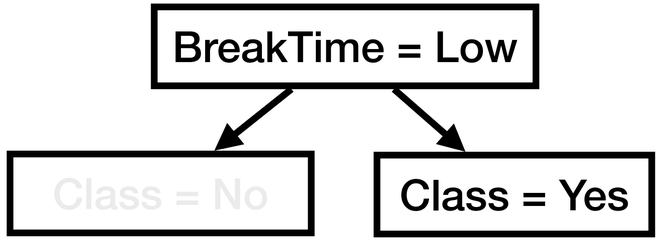

Revision time	Break time	Success
High	Low	No
High	Medium	Yes
Medium	Low	No
Medium	High	Yes
Low	Low	No
Low	High	Yes
High	High	Yes
Medium	Medium	Yes
Low	Medium	No
High	Low	No

2. On recommence sur chacune des feuilles non pures

Calcul de l'indice Gini pour RevisionTime

$$Gini(High) = 1 - \frac{2}{2}^2 - \frac{0}{2}^2 = 0.0$$

$$Gini(Medium) = 1 - \frac{2}{2}^2 - \frac{0}{2}^2 = 0.0$$

$$Gini(Low) = 1 - \frac{1}{2}^2 - \frac{1}{2}^2 = 0.5$$

$$Gini_{pondere}(RevisionTime) = \frac{2}{6} \times 0.0 + \frac{2}{6} \times 0.0 + \frac{2}{6} \times 0.5$$
$$= 0.16667$$

基尼系数法构建

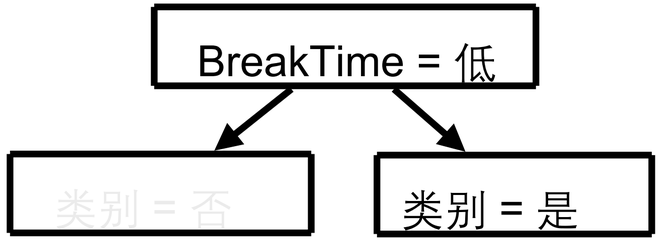

翻修时间	休息时间	成功
高	低	不
高	中等	是
中等	低	不
中等	高	是
低	低	不
低	高	是
高	高	是
中等	中等	是
低	中等	不
高	低	不

2. 在每个非纯度叶片上重新开始计算Gini指数（修订时间）

$$\text{基尼系数（高）} = 1 - \left(\frac{2}{2}\right)^2 - \left(\frac{0}{2}\right)^2 = 0.0$$

$$\text{基尼系数（中等）} = 1 - \left(\frac{2}{2}\right)^2 - \left(\frac{0}{2}\right)^2 = 0.0$$

$$\text{基尼系数（低）} = 1 - \left(\frac{1}{2}\right)^2 - \left(\frac{1}{2}\right)^2 = 0.5$$

$$Gini_{pondere}\text{（修订时间）} = \frac{2}{6} \times 0.0 + \frac{2}{6} \times 0.0 + \frac{2}{6} \times 0.5$$

$$= 0.16667$$

Construction avec l'indice Gini

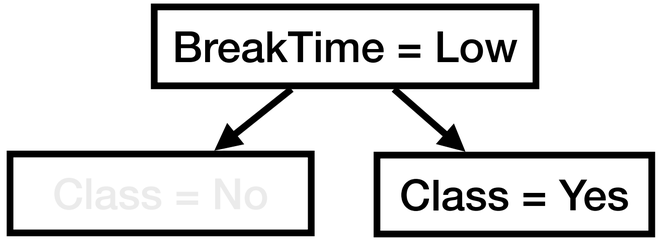

Revision time	Break time	Success
High	Low	No
High	Medium	Yes
Medium	Low	No
Medium	High	Yes
Low	Low	No
Low	High	Yes
High	High	Yes
Medium	Medium	Yes
Low	Medium	No
High	Low	No

2. On recommence sur chacune des feuilles non pures

Calcul de l'indice Gini pour BreakTime

$$Gini(High) = 1 - \frac{3}{3}^2 - \frac{0}{3}^2 = 0.0$$

$$Gini(Medium) = 1 - \frac{2}{3}^2 - \frac{1}{3}^2 = 0.444$$

$$Gini(Low) = 0.0$$

$$Gini_{pondere}(BreakTime) = \frac{3}{6} \times 0.0 + \frac{3}{6} \times 0.444 + \frac{0}{6} \times 0.0$$
$$= 0.2222$$

基尼系数法构建

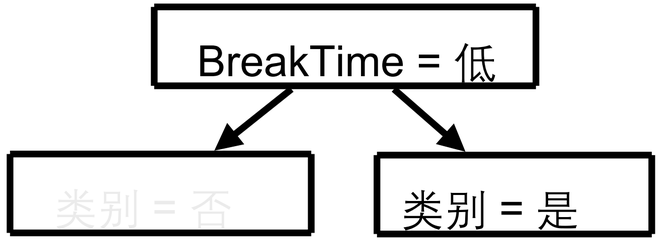

翻修时间	休息时间	成功
高	低	不
高	中等	是
中等	低	不
中等	高	是
低	低	不
低	高	是
高	高	是
中等	中等	是
低	中等	不
高	低	不

2. 在每个非纯度叶片上重新开始计算BreakTime的基尼指数

$$\text{基尼系数（高）} = 1 - \left(\frac{3}{3}\right)^2 - \left(\frac{0}{3}\right)^2 = 0.0$$

$$\text{基尼系数（中等）} = 1 - \left(\frac{2}{3}\right)^2 - \left(\frac{1}{3}\right)^2 = 0.444$$

$$\text{基尼系数（低）} = 0.0$$

$$Gini_{pondere}(BreakTime) = \frac{3}{6} \times 0.0 + \frac{3}{6} \times 0.444 + \frac{0}{6} \times 0.0$$

$$= 0.2222$$

Construction avec l'indice Gini

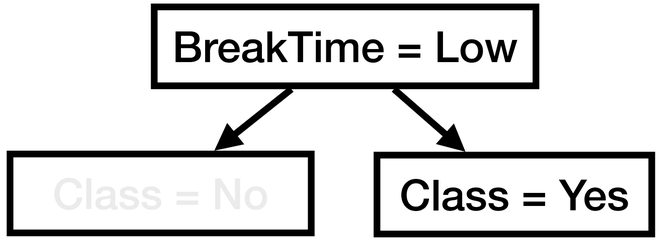

Revision time	Break time	Success
High	Low	No
High	Medium	Yes
Medium	Low	No
Medium	High	Yes
Low	Low	No
Low	High	Yes
High	High	Yes
Medium	Medium	Yes
Low	Medium	No
High	Low	No

2. Sélection de l'attribut pour la première division

Comparaison des indices Gini:

$$Gini_{pondere}(RevisionTime) = 0.16667$$

$$Gini_{pondere}(BreakTime) = 0.2222$$

On sélectionne l'attribut *RevisionTime* qui a l'indice le plus faible

基尼系数法构建

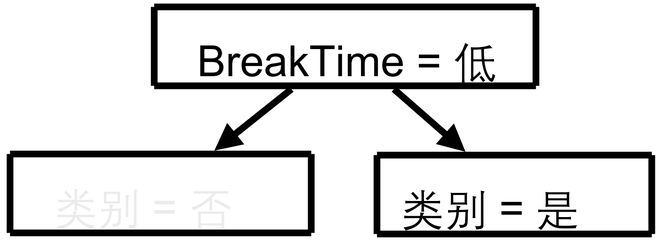

翻修时间	休息时间	成功
高	低	不
高	中等	是
中等	低	不
中等	高	是
低	低	不
低	高	是
高	高	是
中等	中等	是
低	中等	不
高	低	不

2. 第一部分属性选择：基尼系数比较

$$吉尼_{权重}（修订时间）=0.16667$$

$$基尼_{权重}（BreakTime）=0.2222$$

选择索引值最小的属性*RevisionTime*

Construction avec l’indice Gini

Revision time	Break time	Success
High	Low	No
High	Medium	Yes
Medium	Low	No
Medium	High	Yes
Low	Low	No
Low	High	Yes
High	High	Yes
Medium	Medium	Yes
Low	Medium	No
High	Low	No

2. Sélection de l’attribut pour la deuxième division

Attribution des classes par probabilité de valeur

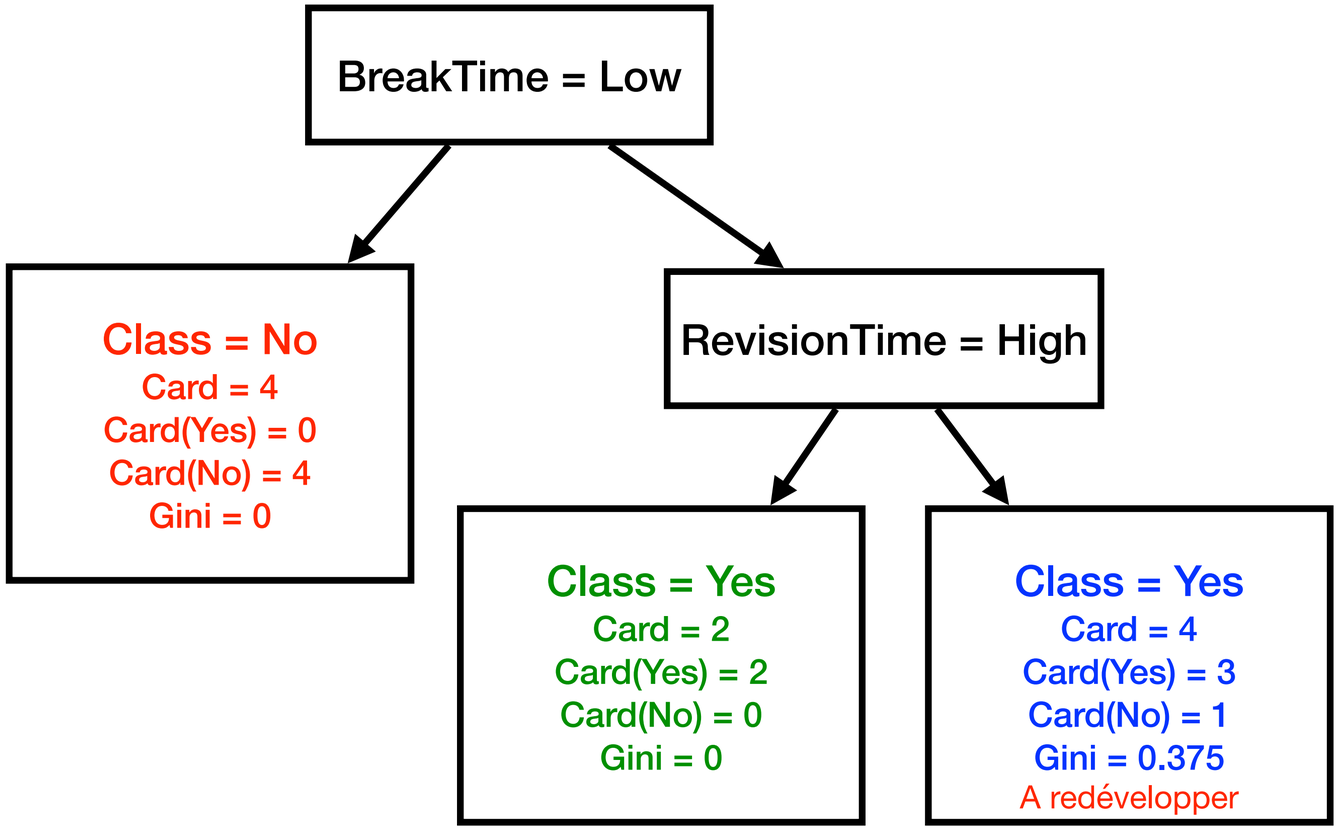

基尼系数法构建

翻修时间	休息时间	成功
高	低	不
高	中等	是
中等	低	不
中等	高	是
低	低	不
低	高	是
高	高	是
中等	中等	是
低	中等	不
高	低	不

2. 第二部分属性选择：基于数值概率的类别归属分配

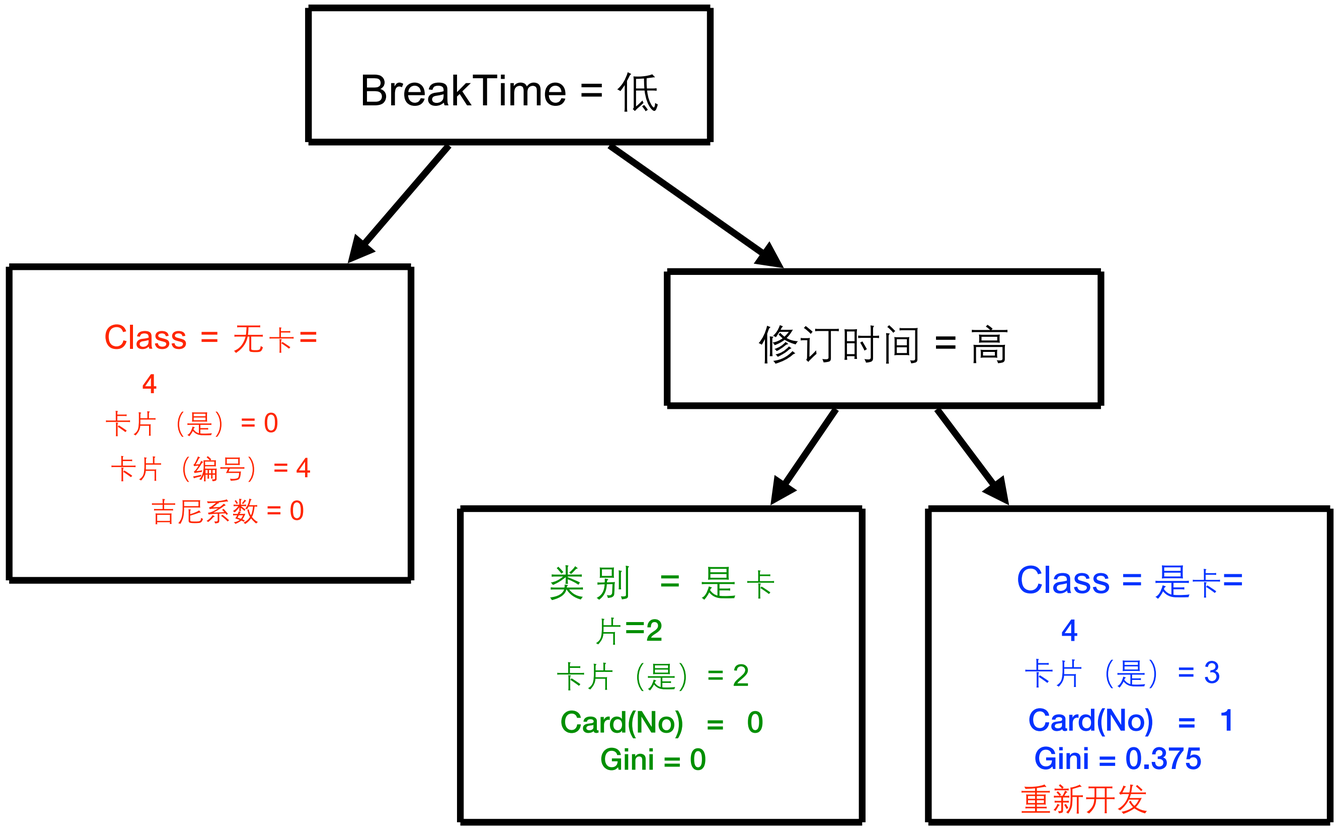

Arbre de décision: Avantages et inconvénients

Avantages

- Facilité d'interprétation
- Pas de normalisation nécessaire
- Gestion des valeurs manquantes
- Flexibilité avec les types de données
- Robustesse aux outliers

Inconvénients

- Forte tendance à sur-apprendre
- Instabilité à la variabilité des données
- Complexité computationnelle
- Sensible au bruit

决策树：优势与劣势

优势

- 易解释性
- 无需标准化处理
- 缺失值管理
- 数据类型灵活性
- 对异常值的稳健性

缺点

- 过度学习倾向
- 数据变异性不稳定性
- 计算复杂度
- 对噪音敏感

Random Forest

随机森林

Introduction aux méthodes ensemblistes

- **Principe**
  - si un médecin (et un seul) vous annonce que vous avez **probablement** une maladie grave qui nécessite une intervention chirurgicale, que ferez-vous ?

Source : [Biernart&Lutz, 2015]

集合论方法导论

- 王子
  - 如果一位医生（且仅有一位）告诉您，您**可能**患有
    如果患上需要手术治疗的严重疾病，你会怎么做？

来源：[Biernart&Lutz，2015]

Introduction aux méthodes ensemblistes

- **Principe**
  - si un médecin (et un seul) vous annonce que vous avez **probablement** une maladie grave qui nécessite une intervention chirurgicale, que ferez-vous ?
  - Fort probable : **demander un second avis à un autre expert.**

Source : [Biernart&Lutz, 2015]

集合论方法导论

- 王子
  - 如果一位医生（而且只有一位）告诉你，你**可能**患有需要手术治疗的严重疾病，你会怎么做？
  - 高概率建议：**向其他专家寻求第二意见。**

来源：[Biernart&Lutz，2015]

Introduction aux méthodes ensemblistes

- **Principe**
  - si un médecin (et un seul) vous annonce que vous avez **probablement** une maladie grave qui nécessite une intervention chirurgicale, que ferez-vous ?
  - Fort probable : **demander un second avis à un autre expert.**
- Méthodes ensemblistes fonctionnent de même :
  - Construction de plusieurs estimateurs (même de qualité moyenne), avec **une vision parcellaire du problème**
  - La décision finale vient de l'agrégation des avis de tous ces estimateurs.

Source : [Biernart&Lutz, 2015]

集合论方法导论

- **王子**
  - 如果一位医生（而且仅有一位）告诉您，您**可能**患有需要手术治疗的严重疾病，您会怎么做？
  - 高概率建议：**向其他专家寻求第二意见。**
- 集合论方法同样适用：
  - 构建多个估计量（即使质量处于中等水平），与**对问题的局部化视角**
  - 最终决策是通过对所有这些评估器的综合意见得出的。

来源：[Biernart&Lutz，2015]

Random Forest ??

- **Forest**
  - On utilise un ensemble d’arbres de décision, formant une forêt…
- **Random**
  - Pour éviter d’avoir plusieurs fois le même arbre, ils sont entraînés sur un sous-ensemble d’observations (*tree bagging*) et de features tirés au hasard (*feature sampling*).
    - *Random forest = tree bagging + feature sampling*
- **Fonction d’agrégation**
  - En classification, **vote**
  - En regression, **moyenne**

Source : [Biernart&Lutz, 2015]

随机森林？？

- **森林**
  - 采用一组决策树，形成森林……
- **随机**
  - 为避免出现重复训练同一棵树的情况，他们采用子集观测数据（*树袋法*）和随机特征抽取（*特征采样*）进行训练。
    - *随机森林=树袋+特征抽样*
- **聚合函数**
  - 在分类中，**投票**
  - 在回归分析中，**平均值**

来源：[Biernart&Lutz，2015]

Exemple de construction d’une forêt aléatoire

Revision time	Break time	Success
High	Low	No
High	Medium	Yes
Medium	Low	No
Medium	High	Yes
Low	Low	No
Low	High	Yes
High	High	Yes
Medium	Medium	Yes
Low	Medium	No
High	Low	No

- Sélection d’un premier sous-ensemble aléatoire

随机森林构建示例

翻修时间	休息时间	成功
高	低	不
高	中等	是
中等	低	不
中等	高	是
低	低	不
低	高	是
高	高	是
中等	中等	是
低	中等	不
高	低	不

- 第一随机子集的选择

Exemple de construction d'une forêt aléatoire

Revision time	Break time	Success
High	Low	No
High	Medium	Yes
Medium	Low	No
Medium	High	Yes
Low	Low	No
Low	High	Yes
High	High	Yes
Medium	Medium	Yes
Low	Medium	No
High	Low	No

- Sélection d'un premier sous-ensemble aléatoire
- Construction du premier arbre

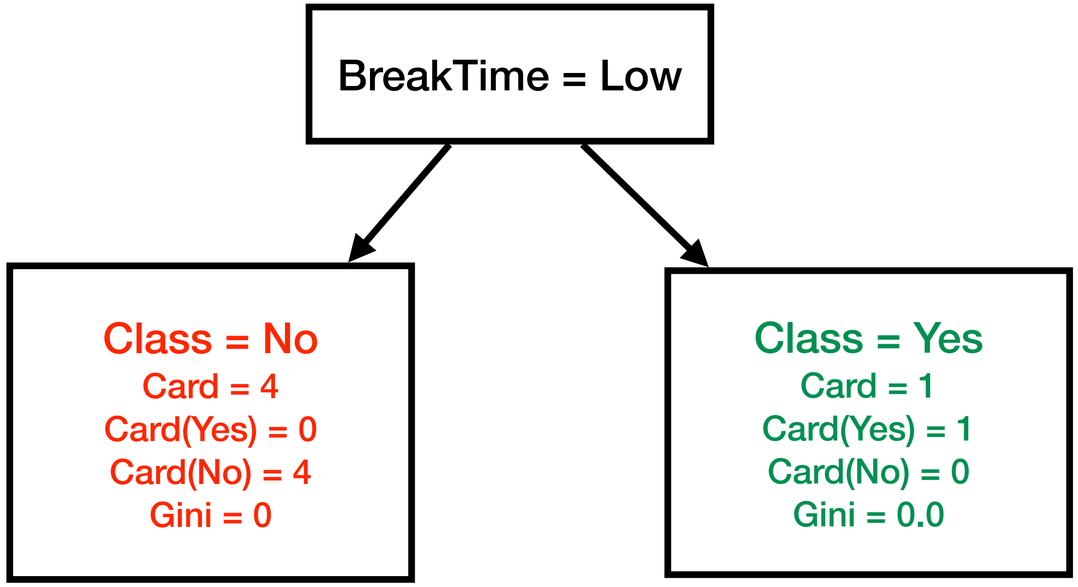

随机森林构建示例

翻修时间	休息时间	成功
高	低	不
高	中等	是
中等	低	不
中等	高	是
低	低	不
低	高	是
高	高	是
中等	中等	是
低	中等	不
高	低	不

- 第一随机子集的选择
- 第一棵树的建造

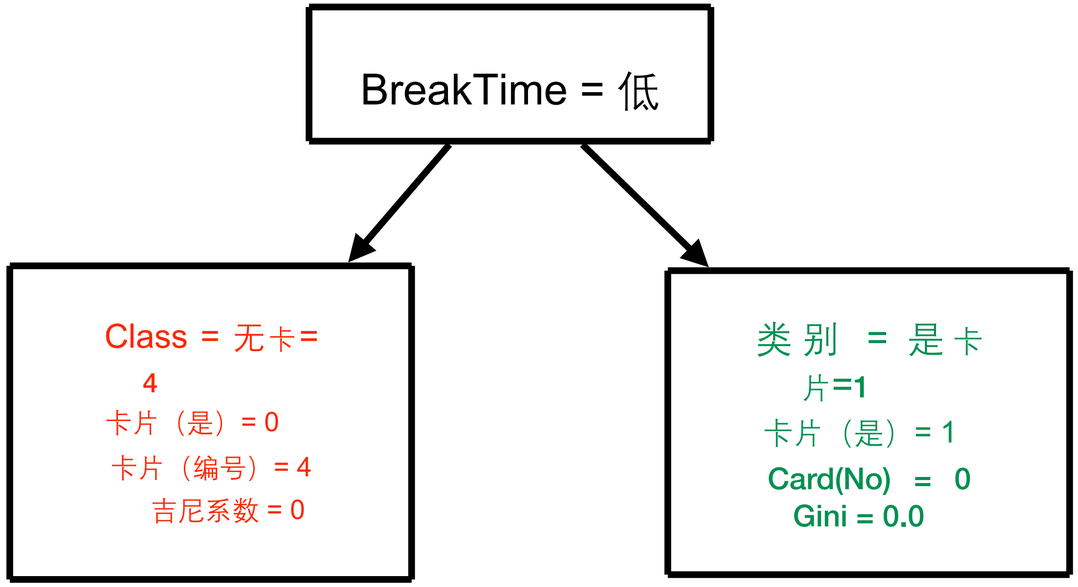

Exemple de construction d’une forêt aléatoire

Revision time	Break time	Success
High	Low	No
High	Medium	Yes
Medium	Low	No
Medium	High	Yes
Low	Low	No
Low	High	Yes
High	High	Yes
Medium	Medium	Yes
Low	Medium	No
High	Low	No

- Sélection d’un premier sous-ensemble aléatoire
- Construction du premier arbre

随机森林构建示例

翻修时间	休息时间	成功
高	低	不
高	中等	是
中等	低	不
中等	高	是
低	低	不
低	高	是
高	高	是
中等	中等	是
低	中等	不
高	低	不

- 第一随机子集的选择
- 第一棵树的建造

Exemple de construction d'une forêt aléatoire

Revision time	Break time	Success
High	Low	No
High	Medium	Yes
Medium	Low	No
Medium	High	Yes
Low	Low	No
Low	High	Yes
High	High	Yes
Medium	Medium	Yes
Low	Medium	No
High	Low	No

- Sélection d'un premier sous-ensemble aléatoire
- Construction du premier arbre
- Sélection d'un second sous-ensemble aléatoire
- Construction du second arbre

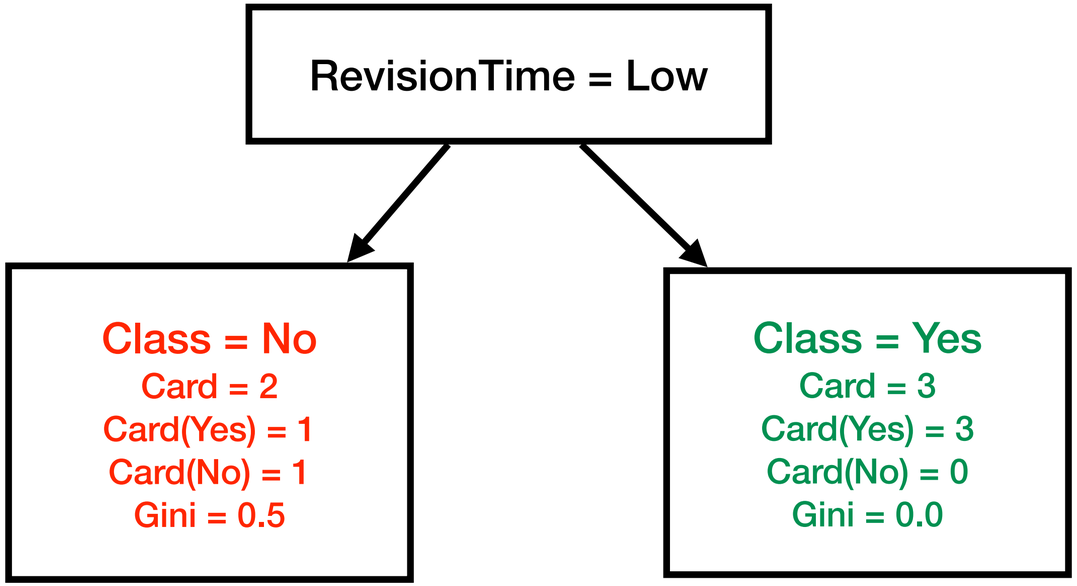

随机森林构建示例

翻修时间	休息时间	成功
高	低	不
高	中等	是
中等	低	不
中等	高	是
低	低	不
低	高	是
高	高	是
中等	中等	是
低	中等	不
高	低	不

- 第一随机子集的选择
- 第一棵树的建造
- 随机第二子集的选择
- 第二根树干的构建

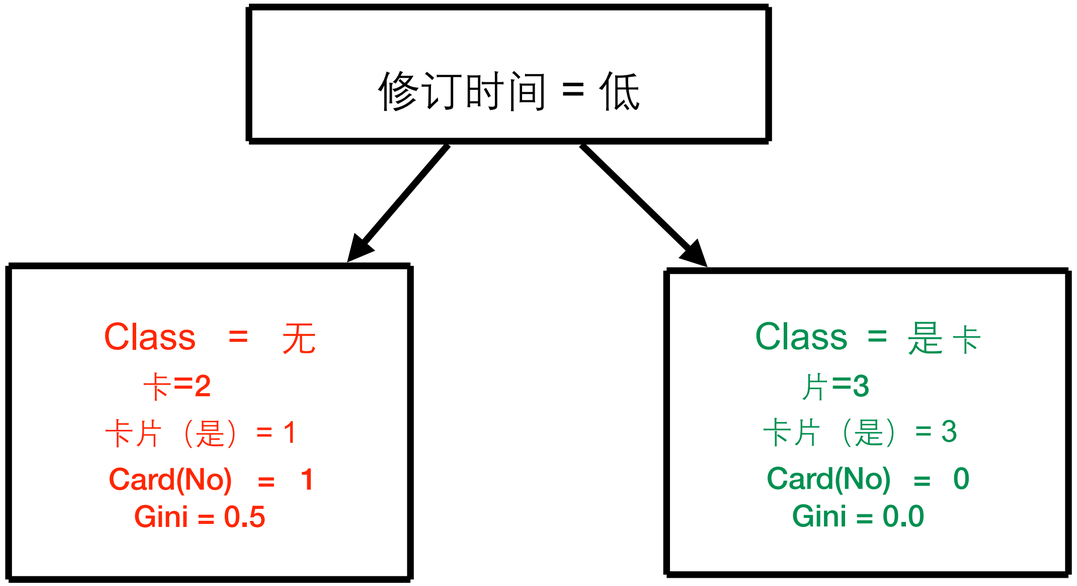

Exemple de construction d'une forêt aléatoire

- Prédiction: vote entre les différents arbres
  - Soit un nouvel étudiant
    RevisionTime = Medium
    BreakTime = Medium

On est d'accord, on classifie YES!

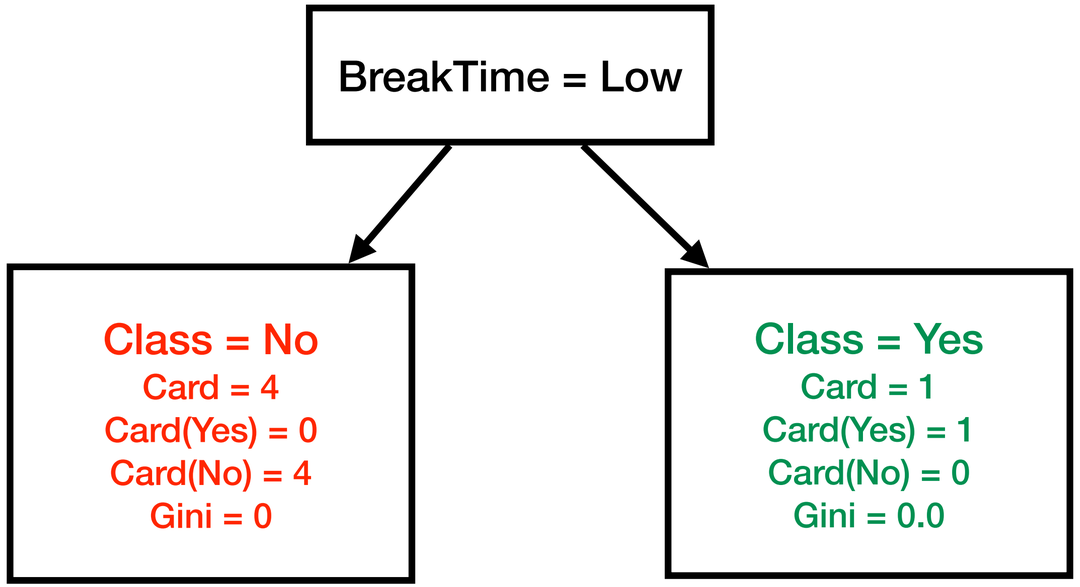

Arbre 1 vote « Yes »

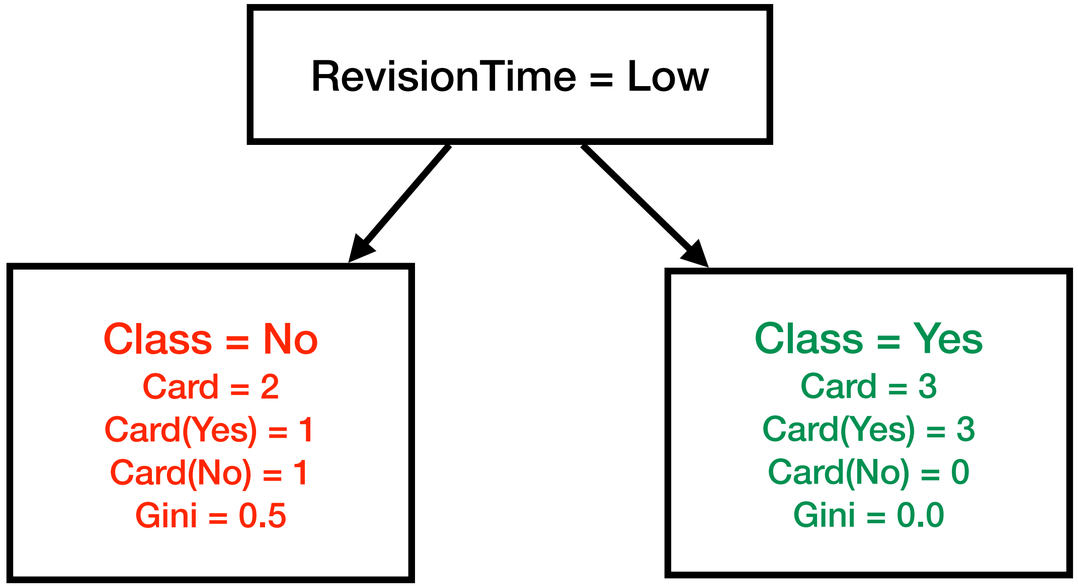

Arbre 2 vote « Yes »

随机森林构建示例

- **预测：不同树之间的投票行为**
  - 新学生需满足以下条件：修订时间（RevisionTime）为中等值，中断时间（BreakTime）为中等值

大家一致同意，我们决定通过！

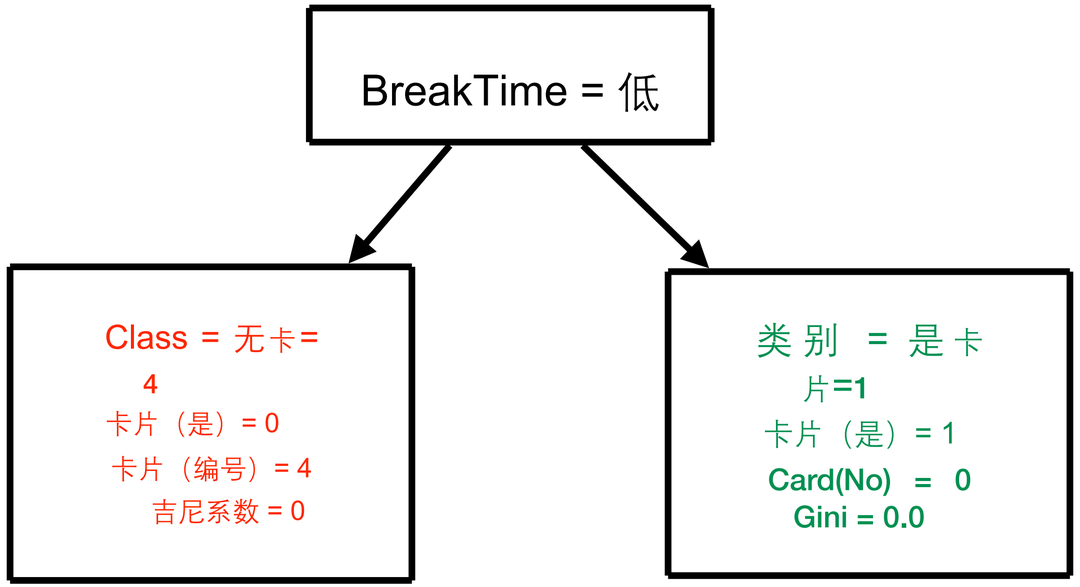

Arbre投1票赞成

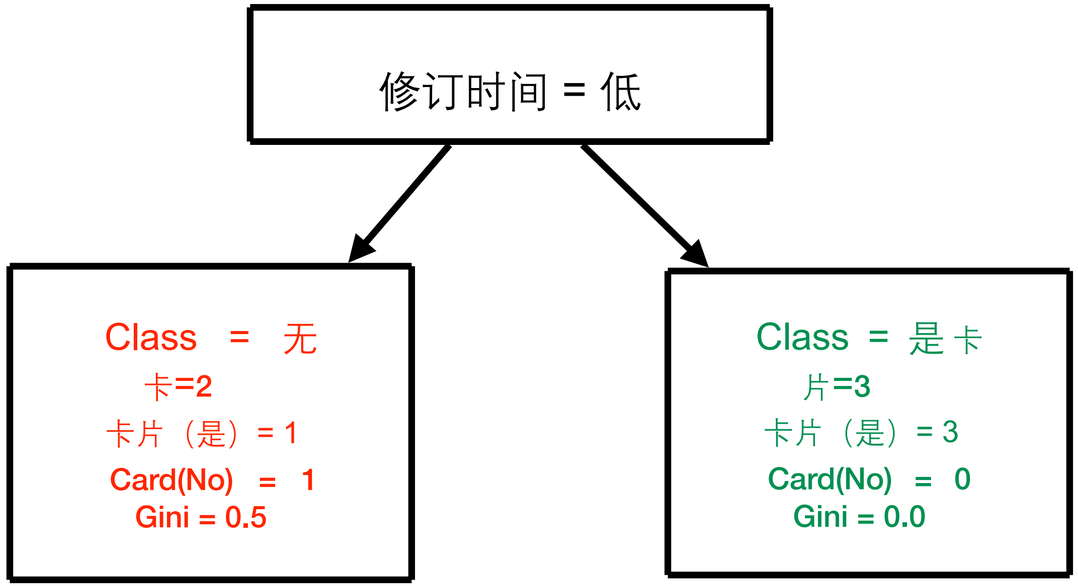

Arbre 2投“赞成票”

Exemple de construction d'une forêt aléatoire

- Prédiction: vote entre les différents arbres
  - Soit un nouvel étudiant
    RevisionTime = High
    BreakTime = Low

On n'est pas d'accord, on choisit au hasard!

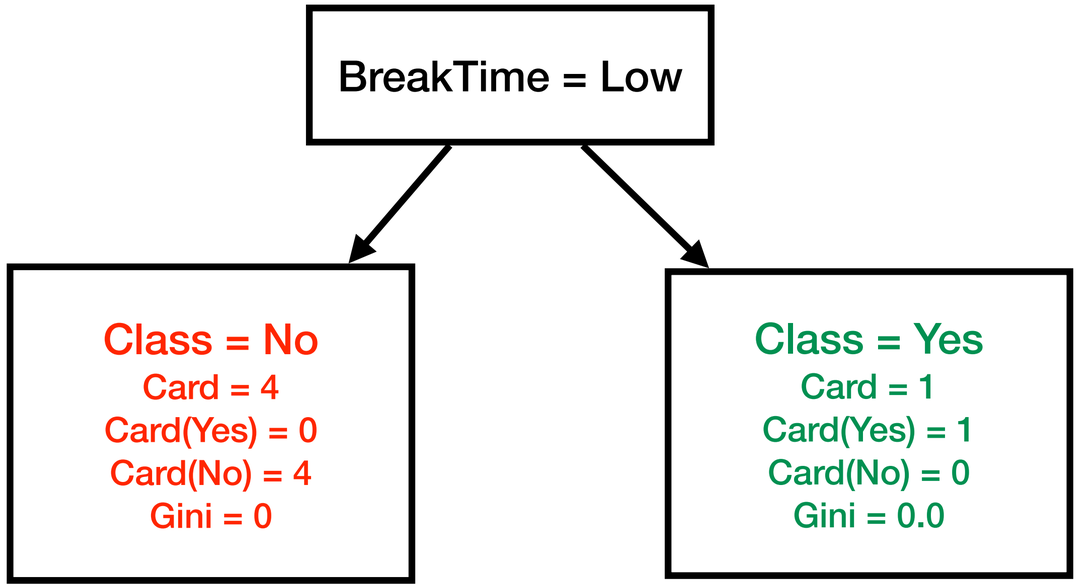

Arbre 1 vote « No »

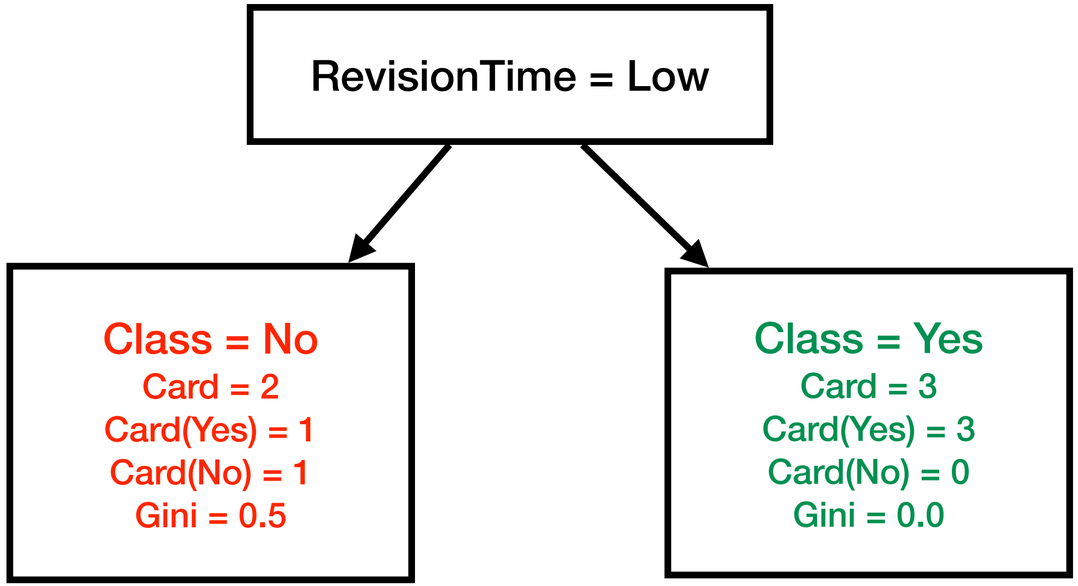

Arbre 2 vote « Yes »

随机森林构建示例

- 预测：不同树之间的投票行为
  - 若为新生，则设置RevisionTime为高值，BreakTime为低值

不同意的话，就随便选吧！

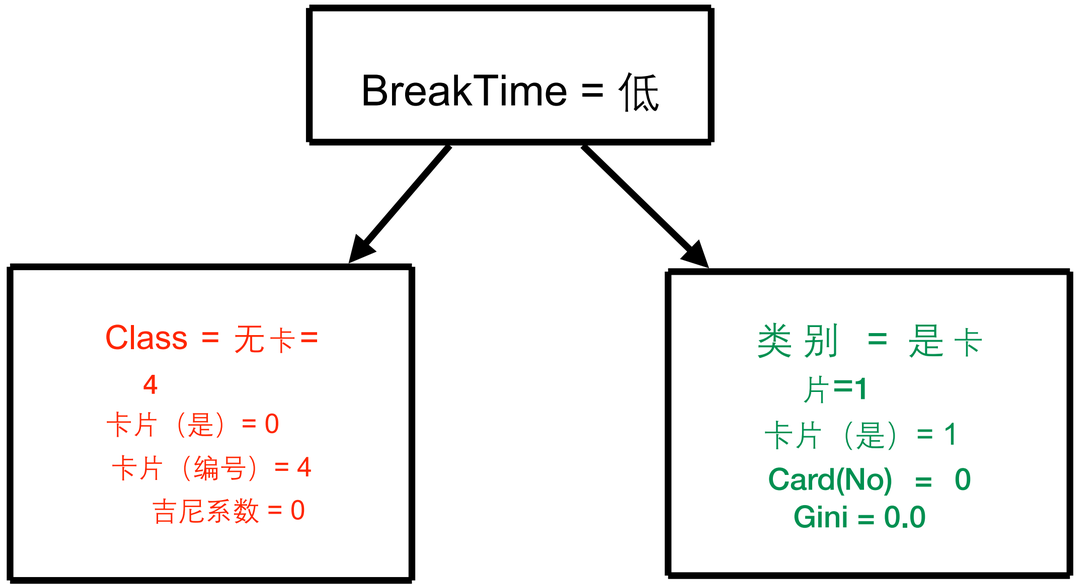

Arbre投下1票反对票

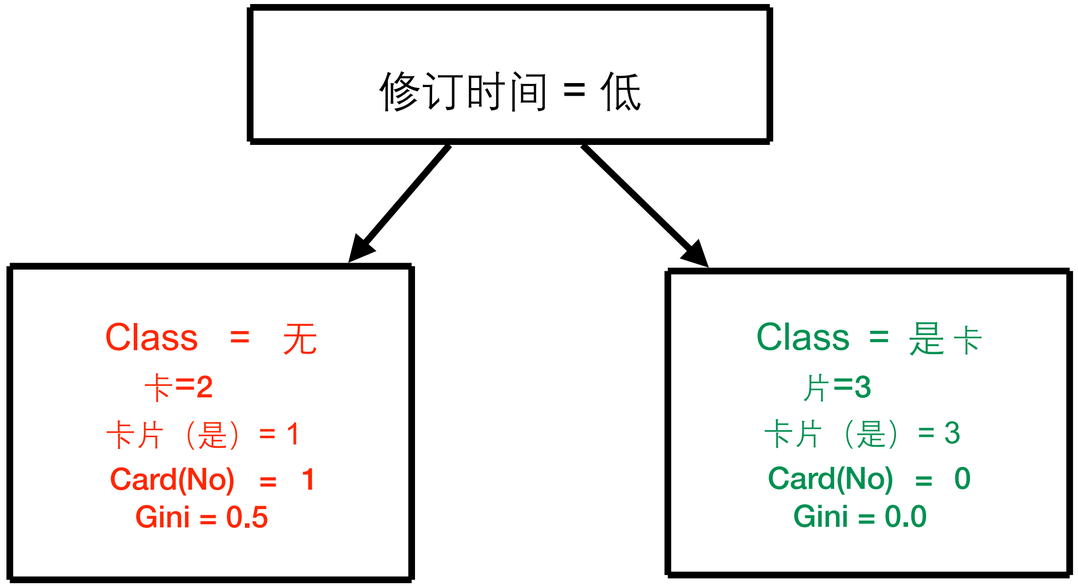

Arbre 2投“赞成票”

Random Forest : à retenir

- Apprentissage supervisé : régression ou classification
- Le *random forest* construit plusieurs arbres de décision indépendants.
- Chaque arbre construit dispose d'une vision parcellaire du problème, conditionnée par un double tirage aléatoire :
  - *tree bagging* : tirage aléatoire avec remplacement sur les lignes (les observations) ;
  - *feature sampling* : tirage aléatoire sur les colonnes (les variables).
- La construction de chaque arbre se base (en classification) sur l'un des deux critères :
  - *Gini*, qui se focalise sur la séparation de la classe la plus représentée ;
  - *entropie*, qui vise à maximiser le gain d'information à chaque étape de réalisation de l'algorithme.
- Les arbres créés sont ensuite assemblés. La prévision pour de nouvelles données est une moyenne (en régression) ou **un vote (en classification).**

Source : [Biernart&Lutz, 2015]

随机森林：要点总结

- 监督学习：回归或分类
- *随机森林* 会构建多棵相互独立的决策树。
- 每个构建的树结构都具备基于双重随机抽样条件的区域问题视图：
  - *树袋法*：在行（观测值）上进行有放回的随机抽样；
  - *特征采样*：对列（变量）进行随机抽样。
- 每棵树的构建过程（在分类层面）基于以下两个标准之一：
  - *基尼系数*，其核心在于区分社会中占比最高的群体；
  - *熵*，其目标是在算法实现的每一步中最大化信息增益。
- 生成的树结构随后被组装完成。对于新数据的预测采用平均值（回归分析）或**投票法（分类分析）**。

来源：[Biernart&Lutz，2015]

Random forrest: Avantages et inconvénients

Avantages

- Sur-apprentissage réduit par rapport aux arbres de décision
- Meilleure précision
- Gestion des valeurs manquantes
- Flexibilité avec les types de données
- Capable de gérer de très grands volumes de données

Inconvénients

- Complexité computationnelle
- Non interprétable
- Beaucoup d’hyper-paramètres
- Sur-apprentissage potentiel

随机森林：优势与劣势

优势

- 相较于决策树的过学习减少量
- 最佳精度
- 缺失值管理
- 数据类型灵活性
- 能够处理海量数据

缺点

- 计算复杂度
- 无法解释的
- 许多超参数
- 潜在过度学习

Optimisation paramétrique

参数优化

Introduction

- Les modèles de machine learning nécessitent le réglage d'un certain nombre de paramètres afin :
  - D'augmenter l'efficacité de l'apprentissage (score / performance)
  - Réduire le temps de l'apprentissage
- Ces paramètres sont appelés des hyperparamètres, paramètres qui contrôlent / orientent le processus d'apprentissage.

导言

- 机器学习模型需要调整若干参数，以实现以下功能：
  - 提高学习效率（分数/表现）
  - 缩短学习时间
- 这些参数被称为超参数，它们用于控制或引导学习过程。

Amélioration d’un modèle

- Améliorer un modèle, c'est rechercher le jeu de paramètres qui obtiendra la meilleure moyenne sur l'ensemble des validations croisées.
  - A la main…
    - Cela peut être long si plusieurs paramètres et de nombreuses valeurs associées.
    - SkLearn : validation_curve
  - Automatiquement par l'algorithme Grid Search
    - Recherche exhaustive de toutes les combinaisons de paramètres
    - SkLearn : GridSearchCV

模型改进

- 优化模型的核心在于寻找能使交叉验证集上平均值达到最优的参数组合。
  - 手工制作的
    - 如果涉及多个参数和大量关联值，处理过程可能会相当耗时。
    - SkLearn：验证曲线
  - 通过网格搜索算法自动实现
    - 对所有参数组合进行穷举搜索
    - SkLearn：GridSearchCV

Optimisation d’hyper-paramètres

- Grid Search (GridSearchCV)
  - Recherche exhaustive du meilleur jeu de paramètres
- Random Search (RandomizedSearchCV)
  - Recherche aléatoire du meilleur jeu de paramètres
  - Le nombre d'itérations est donné, ainsi le temps de calcul ne dépend pas des paramètres
  - Exploration plus diversifiée
- Ces 2 méthodes sont naïves
  - Elles n'exploitent pas les résultats pour améliorer leur exploration des paramètres

超参数优化

- 网格搜索（GridSearchCV）
  - 对最佳参数组合的全面探索
- 随机搜索（RandomizedSearchCV）
  - 随机搜索最优参数集
  - 迭代次数已给出，因此计算时间与参数无关。
  - 探索性与多样化相结合
- 这两种方法都较为简单粗暴
  - 它们并未利用这些结果来优化参数探索过程

Grid vs Random search

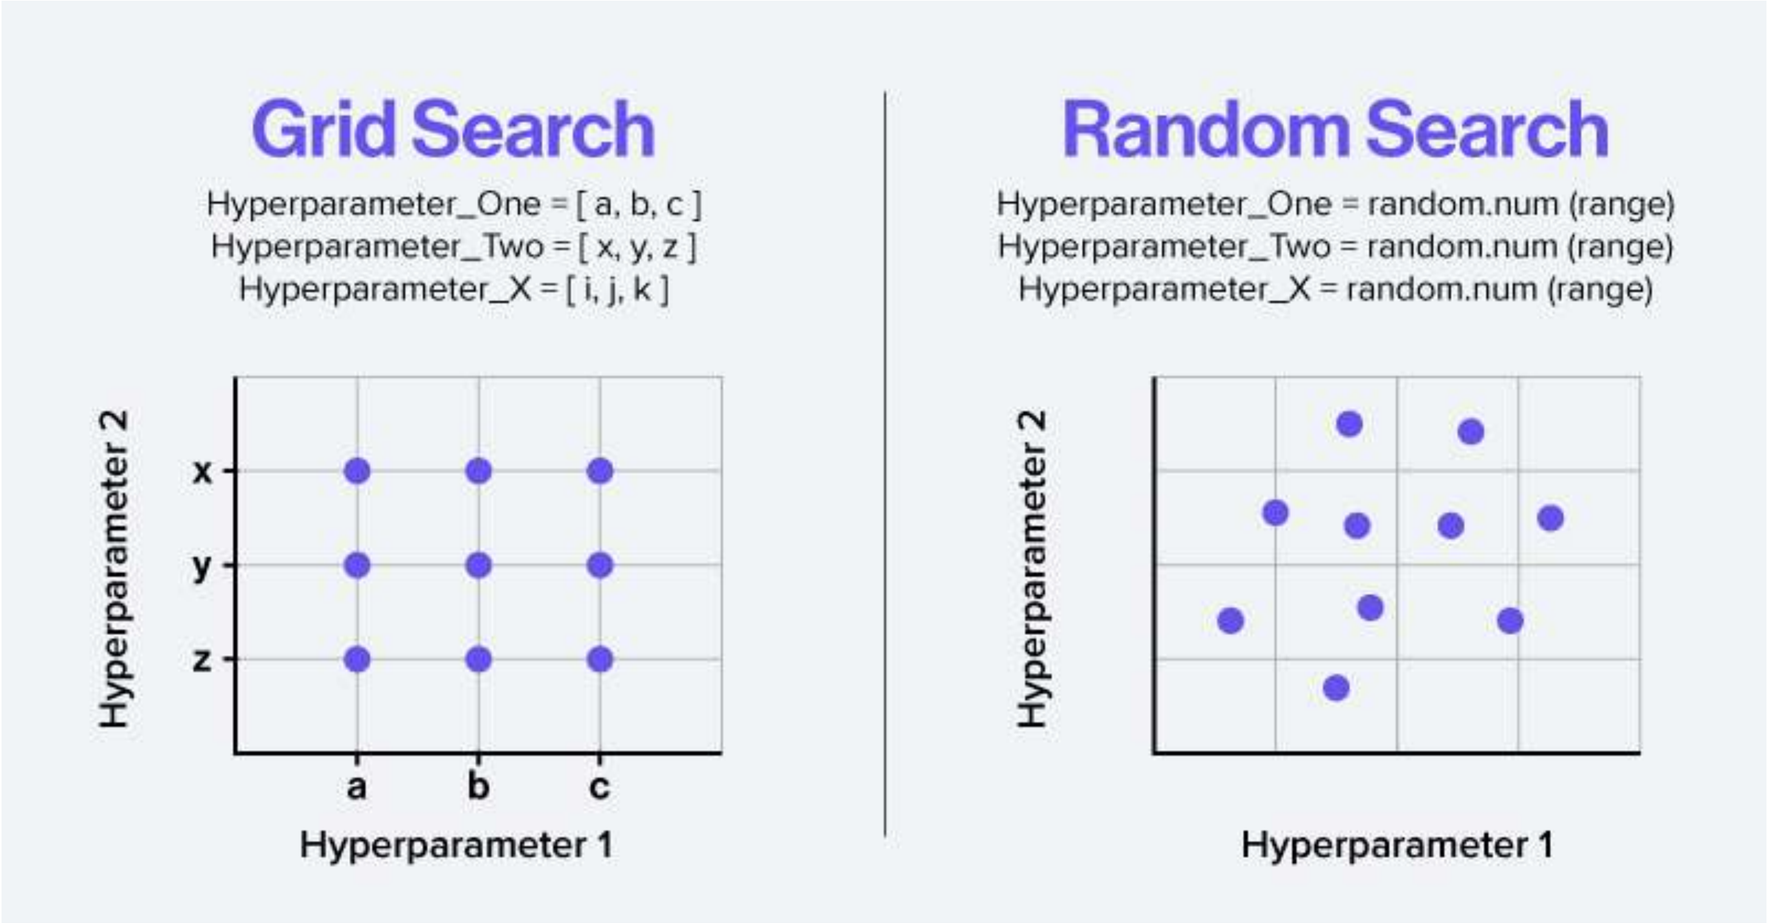

https://www.sabrepc.com/blog/deep-learning-and-ai/grid-search-and-random-search

网格与随机搜索

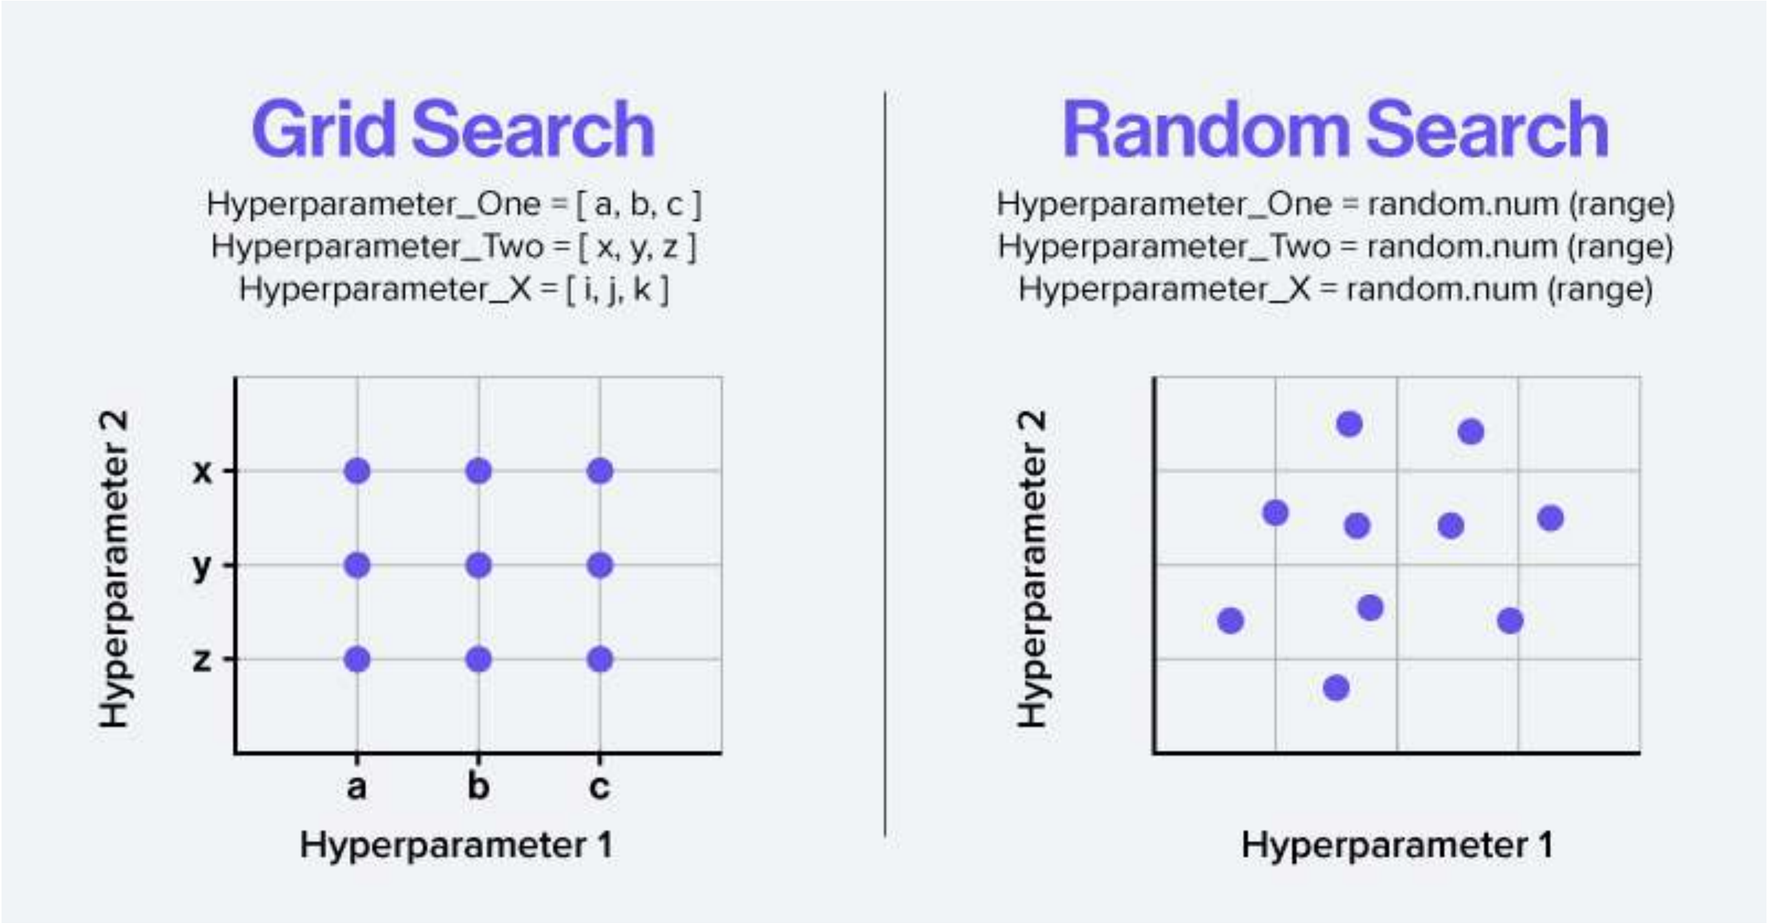

https://www.sabrepc.com/blog/deep-learning-and-ai/grid-search-and-random-search